

Chapitre 3

Découverte des règles d'associations

Motivation

OBSERVER LES ACHATS

Exemple fictif : cinq tickets de caisse

T1	Café	Croissant	Lait
T2	Café	Croissant	
T3	Café	Biscuit	
T4	Café	Croissant	Jus
T5	Thé	Biscuit	

DÉCOUVRIR UNE TENDANCE

CAFÉ → CROISSANT

75 %

des paniers avec café

contiennent un croissant

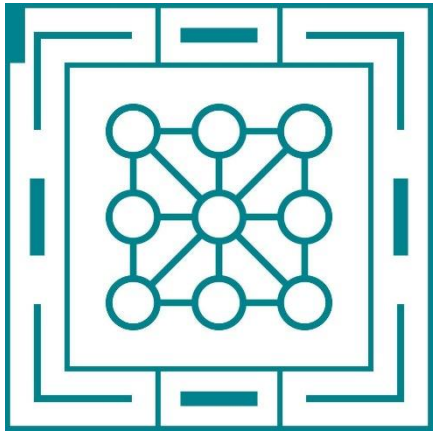
Une association observée, pas une causalité!

À QUOI ÇA SERT ? ☑Recommander ☑Proposer des offres ☑Organiser les rayons

Comment détecter automatiquement ces règles et mesurer leur intérêt ?

Exemple des règles d'association

- Si on baisse le prix du Coca-Cola de 5%, alors on va en augmenter les ventes de 15%
- Puisque j'achète du Coca, il me faut aussi des cacahuètes
- Si on réduit le prix d'un ordinateur portable, on peut s'attendre à une hausse des ventes d'accessoires comme des souris, des claviers ou des sacoches
- Si on baisse le prix d'une paire de chaussures de sport cela entraînera probablement une hausse des ventes de chaussettes de sport



Représentation binaire

- Exemple: Chercher des associations entre produits sur les tickets de caisse **!**

- Soit la base de données suivante de 5 transactions (tickets)

$$T=\{t_1, t_2, t_3, t_4, t_5\}$$

Descripteurs= liste de produits

Observations= Liste d'achats

	A	B	C	D	E
t_1	1	0	0	1	0
t_2	1	1	1	0	0
t_3	1	0	0	0	1
t_4	1	0	0	1	1
t_5	0	1	0	1	0

t_1= AD / t_2= ABC / t_3= AE / t_4= ADE / t_5= BD

Ensemble des items

t_1= AD / t_2= ABC / t_3= AE / t_4= ADE / t_5= BD

Un ensemble d'items **X** de cardinalité **k** est appelé un **k-itemset**

1-itemset : Ensemble de descripteurs

X ={x_1=**A**, x_2=**B**, x_3=**C**, x_4=**D**, x_5=**E**}

2-itemset : Transactions de deux descripteurs C_5^2=10

X ={x_1=**AB**, x_2=**AC**, x_3=**AD**, x_4=**AE**, x_5=**BC**, x_6=**BD**, x_7=**BE**, x_8=**CD**, x_9=**CE**, x_{10}=**DE**}

3-itemset : Transactions de trois descripteurs C_5^3=10

X ={x_1=**ABC**, x_2=**ABD**, …}

Nombre d'items dans un k-itemset= $C_m^k = \frac{m!}{(m-k)! \times k!}$

avec m= nombre de descripteurs dans la base de transactions

Calcul de support

- Support (x_i) : le pourcentage de toutes les transactions qui supportent l'item x_i

$$supp(x_i) = \frac{card(t_j | x_i \subseteq t_j,\ t_j \in T)}{n} ;\ i \in [1..m], j \in [1..n]$$

avec $card(t_j | x_i \subseteq t_j,\ t_j \in T)$ = le nombre de transaction qui supportent x_i

n = le nombre de transactions dans la base

- Soit S_{min}, le seuil minimal des supports acceptés
- Si $supp(x_i) \geq S_{min}$ Alors l'item x_i est dit fréquent

Calcul de support Propriétés

- Toutes les transactions qui supportent **y** supportent nécessairement **x**

  Soit les items **x** et **y**, Si **x** ⊆ **y** alors $supp(\mathbf{x}) \geq supp(\mathbf{y})$

- Les sous-ensembles d'ensembles fréquents sont fréquents

  Si l'item **ABC** est fréquent alors ses sous-ensembles **AB**, **AC** et **BC** sont aussi fréquents



X1={AB, AC}

X2={ABC}

X1 est un sous ensemble de X2

X2 est un sur ensemble de X1

- Les sur-ensembles d'ensembles non fréquents sont non fréquents

  AB est non fréquent alors **ABC** est aussi non fréquent

Activité (calcul du support)

Soit t_1= **AC**, t_2= **BC**, t_3= **ABC** avec S_{min}=40%

1/ Calculer les supports supp(**AB**), supp(**AC**) et supp(**BC**)?

supp(**AB**)= 1/3= 0.33

supp(**AC**)= 2/3= 0.66

supp(**BC**)= 2/3= 0.66

2/ Est-ce que les items **A** et **C** sont fréquents? (sans faire le calcul de support)

supp(**AC**)= 0.66≥ S_{min} alors **AC** est fréquent → **A** fréquent et **C** fréquent

3/ Est-ce que l'item **ABC** est fréquent? (sans faire le calcul de support)

supp(**AB**)= 0.33≤ S_{min} alors **AB** est non-fréquent → **ABC** non-fréquent

Règles d'association

- Application de la forme **R : x → y**

  x et **y** sont des items disjoints (**x** ∩ **y** =∅)

  Antecedent — Consequent

  Condition — Résultat

  x → **y**

  "**Puisque j'achète du Coca**, **il me faut aussi des cacahuètes**"

- Une règle d'association traduit une cooccurrence et non une causalité

- La force d'une règle d'association est mesurée en utilisant
  - son Support, $supp(\mathbf{x} \rightarrow \mathbf{y})$
  - et sa Confiance, $conf(\mathbf{x} \rightarrow \mathbf{y})$

  R :x → y[supp%, conf%]

Règles d'association

- Support $supp(\mathbf{x} \rightarrow \mathbf{y})$: le pourcentage de toutes les observations qui supportent $\mathbf{x}$ et $\mathbf{y}$ ensemble

$$supp(\mathbf{x} \rightarrow \mathbf{y}) = supp(\mathbf{xy})$$

$$supp(\mathbf{x}) = \frac{card(t_j | \mathbf{x} \subseteq t_j,\ t_j \in T)}{n};\ j \in [1..n] \qquad [\mathbf{0}, \mathbf{1}]$$

n est le nombre de transactions dans la base
$card(t_j | \mathbf{x} \subseteq t_j,\ t_j \in T)$ est le nombre de transaction qui supportent $\mathbf{x}$

- Confiance $conf(\mathbf{x} \rightarrow \mathbf{y})$: indique combien de fois $\mathbf{y}$ est présent parmi les observations où $\mathbf{x}$ est présent = probabilité de $\mathbf{y}$ sachant que $\mathbf{x}$ $P(\mathbf{y}|\mathbf{x})$

$$conf(\mathbf{x} \rightarrow \mathbf{y}) = \frac{supp(\mathbf{xy})}{supp(\mathbf{x})} \quad [\mathbf{0}, \mathbf{1}]$$



Extraction des règles d'association

Extraire les règles d'association revient à choisir les règles ayant un `support suffisant` et une `confiance maximale`

$\text{Support} \geq S_{min}$ $\text{Confiance} \geq Conf_{min}$

La plupart des méthodes d'extraction procèdent :

1/ Génération de tous les itemsets possibles

2/ Génération de toutes les règles possibles

3/ Filtrage avec S_{min} et $Conf_{min}$

Algorithme général

Entrée T : Base de n transactions de m descripteurs

S_{min} : support minimum / $Conf_{min}$: confiance minimale

Sortie Ensemble des règles d'association retenu E_r

1/ Déterminer l'ensemble 1-itemset X_1 de m éléments à partir de T

2/ $k \leftarrow 2$

3/ $E_r \leftarrow \emptyset$ #Initialiser l'ensemble des règles d'association à retenir

4/ Répéter

a. Déterminer l'ensemble k-itemset X_k

b. Déterminer les combinaisons de règles d'association possibles pour chaque item de X_k

c. Pour chaque règle d'association obtenue R

Calculer $supp(R)$ et $conf(R)$

Si $supp(R) \geq S_{min}$ et $conf(R) \geq Conf_{min}$ alors

$E_r \leftarrow E_r \cup \{R\}$

d. $k \leftarrow k + 1$

Jusqu'à $k = m$

Algorithme général

Exemple :

Déterminer les règles d'association associées à la base de transactions suivantes :

$t_1 = AD, t_2 = ABC, t_3 = BC, t_4 = AC$

avec S_{min}=40% et $conf_{min}$=60%

A **B** **C** **D** 1-itemset

$k = 2$

$E_r = \emptyset$

AB **AC** **AD** **BC** **BD** **CD** 2-itemset C_4^2=6

R : A → B $supp(R) = \frac{1}{4}$ =0.25 $conf(R) = \frac{1}{3}$ =0.33

R : B → A $supp(R) = \frac{1}{4}$ =0.25 $conf(R) = \frac{1}{2}$ =0.5

$E_r = \emptyset$

⋮

Algorithme général

❌ Très couteux en termes de calcul

💡 **Solution :** `A_priori`

- Réduire le nombre des articles et de leurs combinaisons prises en considération
- Considérer que les règles ayant un support supérieur à un `taux fixé` a priori

ALGORITHME

A_PRIORI



Algorithme A_priori

Entrée T : Base de $\mathbf{n}$ transactions de $\mathbf{m}$ descripteurs

S_{min} : support minimum

Sortie Ensemble des items fréquents $\mathbf{F}$

1/ $\mathbf{k} \leftarrow 1$

2/ Déterminer l'ensemble $\mathbf{k}$-itemset $\mathbf{X_k}$ à partir de T ($\mathbf{X_k} = \mathbf{X_1}$)

3/ $\mathbf{F} \leftarrow \emptyset$ # Initialiser l'ensemble des items fréquents à retenir

4/ Tant que $\mathbf{X_k} \neq \emptyset$

a. $\mathbf{F_k} \leftarrow \emptyset$ # Initialiser l'ensemble des items fréquents de $\mathbf{X_k}$

b. Pour chaque item $\mathbf{x_i}$ de $\mathbf{X_k}$

Calculer $supp(\mathbf{x_i})$

Si $supp(\mathbf{x_i}) \geq S_{min}$ alors

$\mathbf{F_k} \leftarrow \mathbf{F_k} \cup \{\mathbf{x_i}\}$

c. $\mathbf{k} \leftarrow \mathbf{k} + 1$

d. Déterminer l'ensemble $\mathbf{k}$-itemset $\mathbf{X_k}$ à partir de $\mathbf{F_k}$

e. Si $\mathbf{k} > \mathbf{1}$ alors $\mathbf{F} \leftarrow \mathbf{F} \cup \mathbf{F_k}$

Algorithme A_priori

Exemple : Déterminer l'ensemble d'item fréquents associés à la base de transactions suivantes : $t_1 = AD$, $t_2 = ABC$, $t_3 = BC$, $t_4 = AC$ avec S_{min}=40%

$k = 1$

X_1 { A B C D }

F $\emptyset$

F_1 $\emptyset$

$supp(A) = \frac{3}{4}$=0.75 $supp(B)$=0.5 $supp(C)$=0.75 $supp(D)$=0.25

F_1 { A B C }

$k = \cancel{1}$ 2

X_2 { AB AC BC } C_3^2=3

$supp(AB)$=0.25 $supp(AC)$=0.5 $supp(BC)$=0.5

F_2 { AC BC }

F { AC BC }

⋮

Sélection des règles d'association pertinentes

À partir de l'ensemble des items fréquents $\mathbf{F}$:

- Calculer toutes les combinaisons possibles de règles
- Garder celles avec une confiance $\geq Conf_{min}$



Exemple :

Déterminer les règles d'association pertinentes associées à la base de transactions suivantes : $\mathbf{t_1 = AD}$, $\mathbf{t_2 = ABC}$, $\mathbf{t_3 = BC}$, $\mathbf{t_4 = AC}$ sachant que l'ensemble des items fréquents $\mathbf{F=\{AC, BC\}}$ et $Conf_{min}=70\%$

AC

$\mathbf{R : A \rightarrow C}$

$\mathbf{R : C \rightarrow A}$

BC

$\mathbf{R : B \rightarrow C}$

$\mathbf{R : C \rightarrow B}$

~~$conf(A \rightarrow C) = \frac{2}{3} = 0.666\ (66.6\%)$~~

~~$conf(C \rightarrow A) = \frac{2}{3} = 0.666\ (66.6\%)$~~

$conf(B \rightarrow C) = 1\ (100\%)$

~~$conf(C \rightarrow B) = 0.666\ (66.6\%)$~~

Règles d'association redondantes

Étant donnée deux règles **R1 :** $x_1 \rightarrow y_1$ et **R2 :** $x_2 \rightarrow y_2$

R2 est redondante par rapport à R1 ssi :

$y_1 = y_2$ (même résultat)

y_1 et y_2 correspond à 1-item

$x_1 \subseteq x_2$

$x_1 = x_2$ (même condition)

x_1 et x_2 correspond à 1-item

$y_2 \subseteq y_1$

Exemple :

R1 : $A \rightarrow C$

~~**R2 :** $AB \rightarrow C$~~

R1 : $A \rightarrow BCD$

~~**R2 :** $A \rightarrow C$~~



Éliminer R2

Activité1

Soit l'ensemble des règles d'association **Ω**

Éliminer les règles d'association redondantes**?**

Ω		
	Antecedent	Consequent
1	A	D
2	D	E
3	D	C
4	A	E
5	C, D	A
6	A, C	D
7	A, D	C
8	A	B, C, E

lift (interset)

Étant donnée **R : x → y**

$$\mathbf{lift(R)} = \frac{\mathbf{supp(R)}}{\mathbf{supp(x)} \times \mathbf{supp(y)}} = \frac{\mathbf{conf(R)}}{\mathbf{supp(y)}} \quad [0, \infty[$$

Mesure la force de l'association entre l'antécédent **x** et le conséquent **y** = compare la probabilité d'apparition conjointe de deux items à ce qu'on attendrait si ces items étaient indépendants

- $\mathbf{lift(R) > 1}$: Présence de **x** augmente la probabilité de présence de **y**=association positive entre **x** et **y** = **Règle intéressante**
- $\mathbf{lift(R) < 1}$: Présence de **x** dimunie la probabilité de présence de **y**=association négative entre **x** et **y** = **Règle non intéressante**
- $\mathbf{lift(R) = 1}$: indépendance= **Règle non intéressante**

Activité2

Supposons que l'on dispose des données représentant 6000 transactions.

Étant donnée le nombre de transactions qui supportent $\mathbf{Pain(P)}$ et $\mathbf{Eau(E)}$=3000;

$\mathbf{supp(P)}$=1 et $\mathbf{supp(E)}$=0.5 avec $Conf_{min}$=40%

1/ Calculer la confiance de la règle d'association $\mathbf{P \rightarrow E}$

$\mathbf{conf(P \rightarrow E)} = \frac{\mathbf{supp(PE)}}{\mathbf{supp(P)}} = \frac{\frac{3000}{6000}}{1} = 0.5 \geq 0.4$ →Règle pertinente

50% des clients qui achètent du pain achètent également de l'eau

2/ Est-ce que la règle d'association $\mathbf{P \rightarrow E}$ est intéressante ?

$\mathbf{lift(P \rightarrow E)} = \frac{\mathbf{conf(P \rightarrow E)}}{\mathbf{supp(E)}} = \frac{0.5}{0.5} = 1$ → Règle non intéressante= **indépendance**

3/ Quelle est la conclusion que l'on peut tirer à partir des résultats précédents ?

Une règle pertinente n'est pas nécessairement intéressante!

Quiz

1. Étant donnée les deux transactions $\mathbf{t_1 = CVKB}$ et $\mathbf{t_2 = KJE}$ (plusieurs réponses)
   - ☑ Le nombre de descripteurs est égal à **6**
   - ☑ Le nombre de transactions comportant deux descripteurs est égal à **15**
   - ☑ Le nombre de transactions comportant trois descripteurs est égal à **20**
   - ☑ $\mathrm{supp}(\mathbf{KJ}) = \mathbf{0.5}$

2. Soit $\mathrm{conf}(\mathbf{y} \rightarrow \mathbf{x})$=1, $\mathrm{supp}(\mathbf{yz}) > \mathbf{s}$ et $\mathrm{conf}(\mathbf{y} \rightarrow \mathbf{z}) > \mathbf{c}$, donc (seule réponse)
   - ☑ $\mathrm{supp}(\mathbf{yx}) = \mathrm{supp}(\mathbf{y})$
   - ☐ $\mathrm{conf}(\mathbf{x} \rightarrow \mathbf{z}) = \mathrm{conf}(\mathbf{xz})$
   - ☐ $\mathrm{supp}(\mathbf{x} \rightarrow \mathbf{z}) >$s
   - ☐ $\mathrm{conf}(\mathbf{x} \rightarrow \mathbf{z}) >$c

3. Étant donnée $\mathrm{Conf}_{\mathtt{min}}$**=0.6** et $\mathrm{conf}(\mathbf{R})$**=0.8**, alors **R** est nécessairement intéressante (seule réponse)
   - ☑ Faux
   - ☐ Vrai

leverage

Étant donnée $R : x \rightarrow y$

$$leverage(R) = \underbrace{supp(R)}_{\text{co-occurrence réelle}} - \underbrace{supp(x) \times supp(y)}_{\text{co-occurrence attendue}} \quad [-1, 1]$$

Mesure la différence entre la fréquence réelle d'apparition conjointe de deux items (**co-occurrence réelle**) et la fréquence attendue si ces items étaient indépendants (**co-occurrence attendue**)

- $leverage(R) > 0$: x et y apparaissent ensemble plus souvent que ce que l'on attendrait s'ils étaient indépendants (association entre x et y est forte)
- $leverage(R) < 0$: x et y apparaissent ensemble moins souvent que prévu (la présence de x est associée à l'absence de y ou vice versa
- $leverage(R) = 0$: pas de relation entre x et y

conviction

Étant donnée R : $x \rightarrow y$

$$\textbf{conviction}(R) = \frac{1-\textbf{supp}(y)}{1-\textbf{conf}(R)} \quad [0, \infty[$$

Mesure à quel point la présence de l'antécédent (x) implique l'absence du conséquent (y) — autrement dit, elle indique à quel point une règle d'association $x \rightarrow y$ est `fiable`

- $\textbf{conviction}(R) > 1$: la présence de x augmente la probabilité que y soit également présent= Forte dépendance directionnelle de y par rapport à x =**Règle fiable**
- $\textbf{conviction}(R) < 1$: indique une relation négative : quand x apparaît, y tend à ne pas apparaître = **Règle non fiable**
- $\textbf{conviction}(R) = 1$: indique que x et y sont indépendants (aucune relation)
- $\textbf{conviction}(R) = \textbf{inf}$: se produit lorsqu'une règle est **"parfaite"**=chaque fois que x est présent, y est également présent, sans exception

zhangs_metric

Étant donnée $R : x \rightarrow y$

$$\text{Zhang_metric}(R) = \frac{(\text{supp}(R) - \text{supp}(x) \times \text{supp}(y))}{\max(\text{supp}(x) \times (1 - \text{supp}(y)), 1 - \text{supp}(x) \times \text{supp}(y))} \quad [-1, 1]$$

Mesure la force ou la dépendance entre des items dans une règle d'association tout en minimisant l'influence de la fréquence d'occurrence des items

- $\text{Zhang_metric}(R) > 0$: association positive entre les items x et y
- $\text{Zhang_metric}(R) < 0$: association négative (répulsion)= les items x et y apparaissent ensemble moins souvent que prévu
- $\text{Zhang_metric}(R) = 0$: pas de dépendance notable entre x et y

Recap

Mesure	Interprétation principale
Support	Fréquence d'apparition conjointe de A et B.
Confiance	Probabilité d'avoir B sachant A.
Lift	Force de la corrélation entre A et B (valeur > 1 : relation positive, < 1 : négative).
Conviction	Fiabilité de la règle : à quel point A implique B sans contradiction.
Leverage	Différence entre la cooccurrence réelle et celle attendue si A et B étaient indépendants.
Zhang Metric	Mesure la **force et la direction** de la relation entre A et B, **indépendamment du support** ; plus robuste que le lift pour les données déséquilibrées.

Inconvénients des règles d'association

- Coût de la méthode : la méthode d'extraction des règles est très couteuse en temps de calcul
- Le choix des articles : il est difficile de fixer le bon niveau (support) des articles
- Qualité des règles produites : la méthode peut dans certains cas produire des règles triviales ou inutiles

Choix de S_{min} et $Conf_{min}$ dépend de nombre de transactions & reflète sur l'extraction des règles d'association



mlextend 1/2

$t_1 = AD, t_2 = ABC, t_3 = AE, t_4 = ADE, t_5 = BD$

```
pip install mlxtend
```

```
from mlxtend.frequent_patterns import apriori
```

df=

```
df=df.astype('bool')
```

	A	B	C	D	E
0	1	0	0	1	0
1	1	1	1	0	0
2	1	0	0	0	1
3	1	0	0	1	1
4	0	1	0	1	0

```
A     bool
B     bool
C     bool
D     bool
E     bool
dtype: object
```

```
freq_items= apriori(df, min_support=0.4, max_len=3,
                    use_colnames=True)
```

```
freq_items['length']= freq_items['itemsets'].apply(lambda x: len(x))?
```

freq_items

	support	itemsets
0	0.8	(A)
1	0.4	(B)
2	0.6	(D)
3	0.4	(E)
4	0.4	(D, A)
5	0.4	(A, E)

mlextend 2/2

```
from mlxtend.frequent_patterns import apriori, association_rules
```

```
rules= association_rules(freq_items, metric="confidence",
                                        min_threshold=0.6)
```

```
metric="confidence" / metric="lift" / metric="leverage" /
metric="conviction" / metric="zhangs_metric"
```

rules

	antecedents	consequents	antecedent support	consequent support	support	confidence	lift	leverage	conviction	zhangs_metric
0	(D)	(A)	0.6	0.8	0.4	0.666667	0.833333	-0.08	0.6	-0.333333
1	(E)	(A)	0.4	0.8	0.4	1.000000	1.250000	0.08	inf	0.333333