North American Private University | SFAX TUNISIA
TECHNOLOGY . BUSINESS . ARCHITECTURE

الجامعة الشمالية الأمريكية الخاصة- صفاقس
المدرسة العليا الدولية الخاصة للتكنولوجيا
UNIVERSITE NORD-AMERICAINE PRIVEE
INSTITUT INTERNATIONAL DE TECHNOLOGIE
DEPARTEMENT INFORMATIQUE

IIT INSTITUT INTERNATIONAL TECHNOLOGIE
Université Nord Américaine Privée

DEVOIR SURVEILLÉ ©

Matière : Fouille de données
Discipline : 2ème année Génie Informatique
Enseignants : Tarek Ben Said/ Taoufik Ben Abdallah
Documents autorisés / PC & Internet non autorisés

Année Universitaire : 2024-2025
Semestre : 1 (07/11/2024)
Nombre de page : 6
Feuille d'énoncé / Durée : 1h30

Prénom & Nom : _____ **Groupe**_____

Note /20	Commentaires	Signature

NB.
- Le barème est fourni à titre indicatif et peut être ajusté
- La durée de l'examen est de 1h30, et les étudiants doivent répondre directement sur la feuille de l'énoncé
- Les ordinateurs, l'accès à Internet, et l'utilisation d'IDE Python sont strictement interdits

Cocher la ou les réponse(s) correcte(s) (Une réponse incorrecte sera notée 0 pour cette question)

Question (une seule réponse) **(1 pt)**

Dans le processus ECD, quel est *l'ordre correct* des étapes suivantes ?
- ○ Compréhension–Sélection–Nettoyage–Transformation–Data Mining–Validation
- ○ Sélection–Compréhension–Nettoyage–Data Mining–Transformation–Validation
- ○ Compréhension–Sélection–Data Mining–Nettoyage–Validation–Transformation
- ○ Sélection–Data Mining–Compréhension–Nettoyage–Transformation–Validation

Question (plusieurs réponses) **(1 pt)**

Parmi les affirmations suivantes, lesquelles sont correctes ?
- ☐ Un attribut appelé "Type d'animal" ayant les valeurs *Chat* et *Chien est de type ordinal asymétrique*
- ☐ Il est recommandé d'appliquer *OrdinalEncoder* pour encoder un attribut comportant les valeurs *Homme* et *Femme*
- ☐ Un attribut appelé "niveau d'expérience" ayant les valeurs *Débutant*, *Intermédiaire* et *Avancé* est de type *ordinal*
- ☐ Un attribut appelé "état" ayant les valeurs *Présent* et *Absent* est de type *nominal asymétrique*
- ☐ Il est recommandé d'appliquer *OneHotEncoder* pour encoder un attribut continu de type *nominal*

Question (plusieurs réponses) **(1.5 pts)**

En quoi consiste le processus d'Extraction des Connaissances à partir des Données (ECD) ?
- ☐ Identifier des modèles et des informations utiles à partir de grandes quantités de données
- ☐ Améliorer la prise de décision basée sur les données
- ☐ Donner un contexte aux informations
- ☐ Assurer la sécurité des données
- ☐ Analyser des données pour découvrir des patterns

Question (plusieurs réponses) **(1 pt)**

Parmi les affirmations suivantes, lesquelles représentent un problème de classification ?
- ☐ À partir des symptômes d'un patient, le modèle doit déterminer la catégorie de maladie (*Grippe*, *Rhume* ou *Allergie*)
- ☐ Le modèle doit prévoir le nombre de visiteurs dans un parc d'attractions en fonction de la météo
- ☐ Le modèle doit estimer le prix de vente d'une maison en fonction de ses caractéristiques
- ☐ Le modèle doit segmenter les clients d'un magasin de vente en ligne en fonction de leurs transactions effectuées
- ☐ Le modèle doit prédire le sentiment d'un commentaire en ligne (*Positif*, *Négatif* ou *Neutre*)

Question (une seule réponse) (0.5 pt)

Quelle affirmation est correcte concernant la réduction de la dimensionnalité ?

○ Les méthodes *"Wrappers"* réalisent une recherche exhaustive de combinaisons d'attributs
○ Les méthodes *"Filtres"* utilisent des algorithmes d'apprentissage pour évaluer les attributs
○ La réduction de dimension par la variance élimine les descripteurs ayant une forte variance
○ L'extraction de caractéristiques consiste à sélectionner un ensemble réduit de descripteurs directement à partir des données initiales, sans transformation

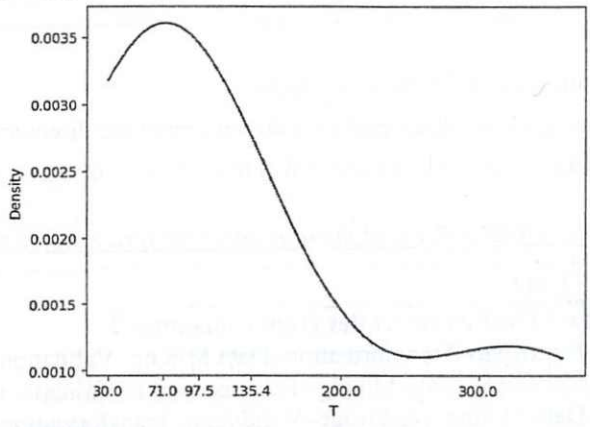
Question (plusieurs réponses) (1 pt)

Quel est le rôle de l'analyse exploratoire des données (EDA) ?

☐ Examiner les relations entre les variables, comme la corrélation, afin d'identifier des liens ou des redondances dans les données
☐ Automatiser le nettoyage des données en supprimant toutes les valeurs manquantes
☐ Identifier et analyser les valeurs manquantes dans les données
☐ Obtenir des prédictions précises simplement en observant les distributions et les relations
☐ Détecter et gérer les valeurs aberrantes de chaque variable

Question (plusieurs réponses) (1 pt)

Étant donnée une distribution `T=[30,90,69,71,74,85,300,360]`, en calculant la densité pour chaque valeur, on obtient la courbe KDE suivante :



Quelles sont les affirmations correctes ?

☐ Pour la variable `T` : la médiane est égale à `71.0` et le mode à `97.5`
☐ Pour la variable `T` : la moyenne est égale à `134.875`
☐ Les valeurs entre `30` et `96` sont aberrantes
☐ La distribution présentée est asymétrique positive
☐ Il est recommandé d'appliquer le `MinMaxScaler` pour normaliser les valeurs de `T`

Question (une seule réponse) (1 pt)

Soit un dataset formé de 7 descripteurs (X1, ..., X7) et un objectif (Y). La *matrice de corrélation* relative à ce dataset est la suivante :

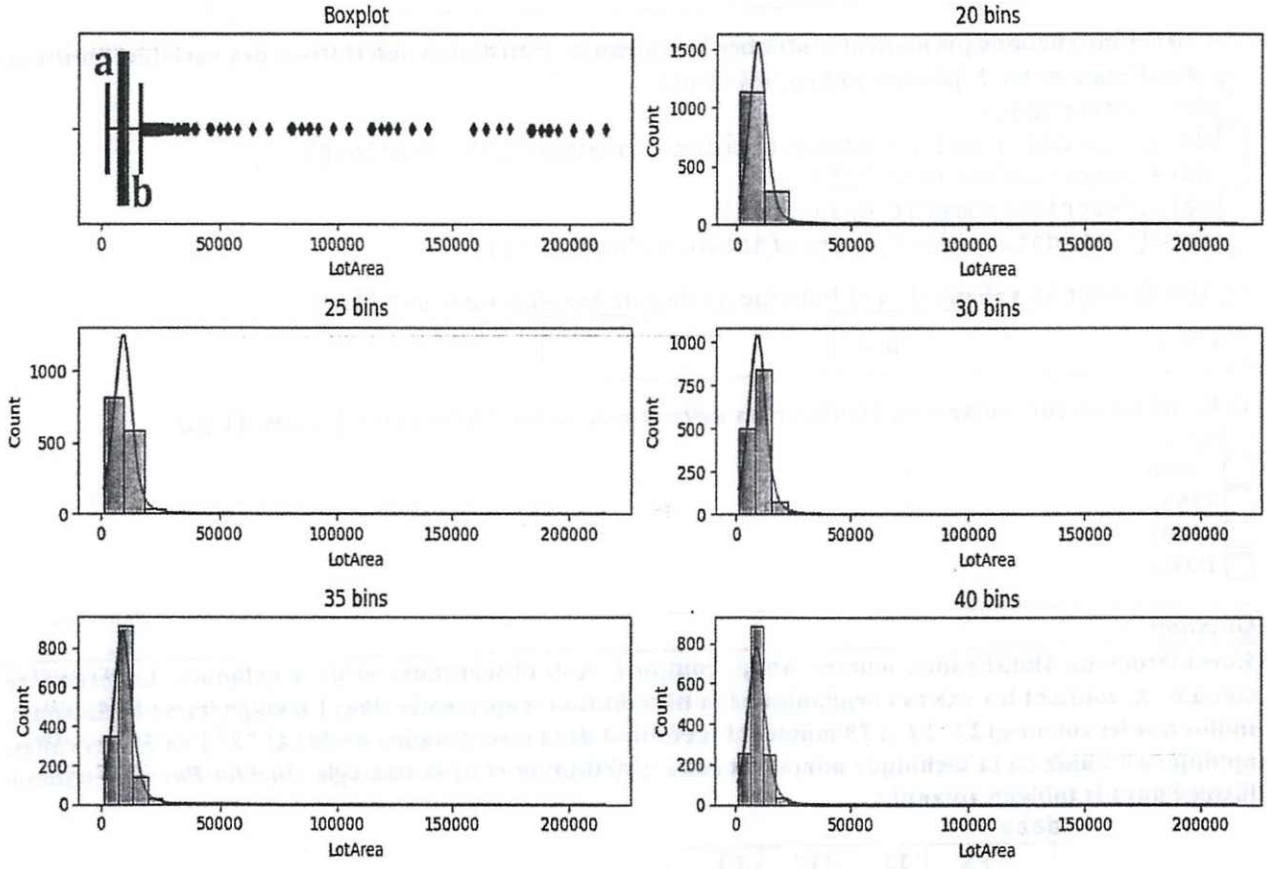
	X1	X2	X3	X4	X5	X6	X7	Y
X1	1	0.7	0.3	0.1	-0.4	0.6	-0.1	0.5
X2		1	0.1	0.2	-0.2	0.4	0.1	-0.2
X3			1	0.4	-0.1	-0.1	0.2	0.4
X4				1	0.3	0.2	-0.3	-0.1
X5					1	0.9	0.5	0.7
X6						1	0.6	0.8
X7							1	0.2
Y								1

Quelles sont les 3 descripteurs les plus importants dans un *ordre décroissant* ?

- O X6 - X5 - X1
- O X6 - X3 - X1
- O X6 - X1 - X3
- O X1 - X5 - X6
- O Y - X6 - X5

Questions

Considérons un jeu de données, présenté sous forme de DataFrame nommé `data`, contenant `1460` observations et visant à prédire le prix de construction d'une maison en fonction de plusieurs caractéristiques (telles que `LotFrontage`, `LotArea`, `Street`, `LotShape`, etc.). L'utilisation de *Boxplot* et de *KDE* avec différents *nombres de bins* (`20`, `25`, `30`, `35` et `40`) appliqués à la variable `LotArea` donne les résultats suivants :



A- Quelle technique est recommandée pour normaliser les valeurs de la variable `LotArea` ? *(une seule réponse)* (1 pt)

- O Effectuer une standardisation *MinMaxScaler*
- O Traiter les valeurs aberrantes, puis appliquer une standardisation *StandardScaler*
- O Utiliser *QuantileTransformer* pour obtenir une distribution uniforme, puis appliquer *StandandScaler*
- O Utiliser *OneHotEncoder*
- O Utiliser une standardisation *RobustScaler*

B- En observant les histogrammes dans la figure *ci-dessus*, quel est le *nombre de bins* le plus approprié ? *(une seule réponse)* (1 pt)

- O `20` *bins*
- O `25` *bins*
- O `30` *bins*
- O `35` *bins*
- O `40` *bins*

Étant donné un extrait du tableau de statistiques descriptives obtenu pour les variables continues du jeu de données utilisé :

	LotFrontage	LotArea	...
count	1201	1460	...
mean	70	10516	...
std	24	9981	...
min	21	1500	...
25%	59	7553	...
50%	69	9478	...
75%	80	11601	...
max	313	215245	...

C-Quelles instructions permettent d'afficher le tableau de statistiques descriptives des variables continues du DataFrame `data` ? *(plusieurs réponses)* **(1 pt)**

- ☐ `data.describe()`
- ☐ `data[list(data.select_dtypes(include="number"))].describe()`
- ☐ `data.describe(include="all")`
- ☐ `data.describe(numeric_only=True)`
- ☐ `data[list(data.select_dtypes(include="number"))]`

D- Quelles sont les valeurs de a et b indiquées dans le *boxplot* ci-dessus ? (1 pt)

a =		b =	

E-Parmi les valeurs suivantes, identifier les *valeurs aberrantes* ? *(plusieurs réponses)* **(1 pt)**

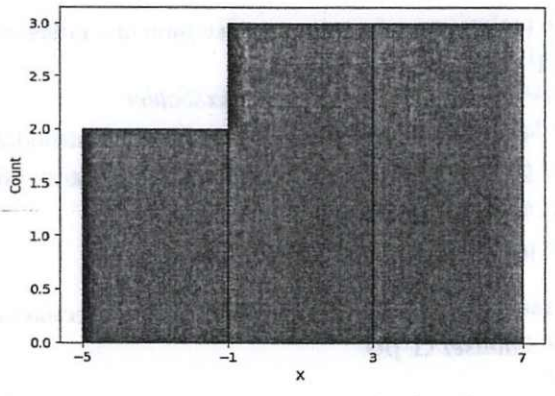
- ☐ 9478
- ☐ 25000
- ☐ 7553
- ☐ 11601
- ☐ 18000

Question

Considérons un DataFrame, nommé `data`, composé de 8 observations et de 4 colonnes. La première colonne, X, contient les valeurs originales de la distribution (représentée dans l'histogramme ci-dessous), tandis que les colonnes I1, I2 et I3 montrent le résultat de la discrétisation de `data["X"]` en 3 intervalles, appliquée à l'aide de la technique adaptée à cette distribution et de la stratégie *OneHot Encoder*, comme illustré dans le tableau suivant :

`data`

	X	I1	I2	I3
0	1	0.0	1.0	0.0
1	3	0.0	0.0	1.0
2	-5	1.0	0.0	0.0
3	-1	?	?	?
4	0	0.0	1.0	0.0
5	5	0.0	0.0	1.0
6	7	0.0	0.0	1.0
7	-3	1.0	0.0	0.0



A- Quelles sont les valeurs de I1, I2 et I3 pour l'observation 3 ? *(une seule réponse)* **(1 pt)**

- ○ `I1=0.0/ I2=0.0/ I3=0.0`
- ○ `I1=0.0/ I2=1.0/ I3=0.0`
- ○ `I1=1.0/ I2=0.0/ I3=0.0`
- ○ `I1=0.0/ I2=0.0/ I3=1.0`

B- Étant donné le code suivant :

```
from sklearn.preprocessing import KBinsDiscretizer
enc=KBinsDiscretizer(n_bins=3,encode=__(1)__,strategy=__(2)__, subsample=__(3)_)
data[['I1','I2','I3']]=enc.fit_transform(data.loc[:,___(4)___]).toarray()
```

Quelle est *l'affirmation correcte (une seule réponse)* (1 pt)

- O **(1)** 'onehot' / **(2)** strategy='quantile'/ **(3)** len(data)/ **(4)** 'X'
- O **(1)** 'onehot' / **(2)** strategy='uniform'/ **(3)** None/ **(4)** 'X'
- O **(1)** 'onehot' / **(2)** strategy='uniform'/ **(3)** None/ **(4)** ['X']
- O **(1)** 'ordinal' / **(2)** strategy='quantile'/ **(3)** len(data)/ **(4)** ['X']
- O **(1)** 'ordinal' / **(2)** strategy='uniform'/ **(3)** len(data)/ **(4)** ['X']

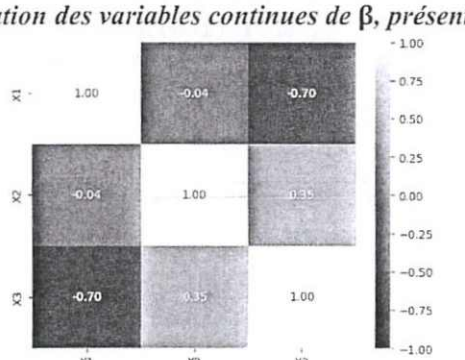
Questions

Considérons un jeu de données β avec les 4 descripteurs suivants : X1, X2, X3 et X4 :

	X1	X2	X3	X4
0	1.0	1.0	NaN	a
1	-2.0	6.0	3.0	b
2	3.0	4.0	4.0	a
3	5.0	7.0	0.0	NaN
4	0.0	2.0	2.0	c
5	6.0	0.0	-2.0	a
6	2.0	-2.0	1.0	b
7	4.0	5.0	NaN	a

A- Quelle stratégie de remplissage convient le mieux dans *SimpleImputer* de *Scikit-Learn* pour traiter les valeurs manquantes dans la colonne X4 ? (0.5 pt)

Étant donnée la matrice de corrélation des variables continues de β, présentée comme suit :



A- Quelle est *l'instruction* qui affiche la *matrice de corrélation* comme montré dans la figure ci-dessus, en supposant que `seaborn` et `matplotlib` sont déjà importés ? *(une seule réponse)* (0.5 pt)

- O `sns.heatmap(df.corr(numeric_only=True), annot=True, fmt=".3f", vmin=-1, vmax=1)`
- O `sns.heatmap(df.corr(numeric_only=True), annot=True, fmt=".2f")`
- O `sns.heatmap(df.corr(), annot=True, fmt=".2f")`
- O `sns.heatmap(df.corr(numeric_only=True), annot=True, fmt=".2f", vmin=-1, vmax=1)`

B- En vous référant à la *matrice de corrélation*, quelles sont les valeurs de remplacement des valeurs NaN pour l'observation d'indice 0 et celle d'indice 7 dans la colonne X3, en appliquant un remplissage vers l'avant ? *(une seule réponse)* (1 pt)

- O X3_observation d'indice 0=NaN / X3_observation d'indice 7=**1.0**
- O X3_observation d'indice 0=**3.0** / X3_observation d'indice 7=NaN
- O X3_observation d'indice 0=**2.0** / X3_observation d'indice 7=**4.0**
- O X3_observation d'indice 0=**3.0** / X3_observation d'indice 7=**1.0**

Questions

Considérons df le DataFrame du jeu de données suivant :

	ID	A	B	C	D	E
0	XB01	NaN	10	NaN	1	True
1	XB02	NaN	16	NaN	NaN	NaN
2	XB03	NaN	8	10	0	False
3	XB05	NaN	22	7	1	True

A.1- Quelle(s) colonne(s) doit-on supprimer du dataset (0.5 pt) ?

A.2- Compléter le code pour effectuer la suppression demandée : (0.5 pt)

```
df._____
```

B- En supposant qu'aucun changement n'a été effectué sur df, quelles sont les instructions permettant de supprimer uniquement la ligne d'indice 1 ? *(plusieurs réponses)* (1 pt)

- ☐ `df.dropna(how="all", thresh=2, inplace=True)`
- ☐ `df.dropna(thresh=3, inplace=True)`
- ☐ `S=df.isnull().sum() ; df.dropna(subset=S[S!=0].index, how="all", inplace=True)`
- ☐ `df.dropna(how="all", inplace=True)`
- ☐ `df.dropna(subset=["A","C","D","E"], axis=0)`

C- Parmi les instructions suivantes, lesquelles permettent de remplacer la valeur NaN de la colonne C ? *(plusieurs réponses)* (1 pt)

- ☐ `df['C'].fillna(df['E'].mean())`
- ☐ `df['C']=df['C'].fillna(df['E'].apply(lambda x: df['B'].mean() if x else 0))`
- ☐ `df['C']=df['C'].fillna(df[['B','E']].apply(lambda x: x.iloc[0] if x.iloc[1]==True else 0))`
- ☐ `df.loc[df["C"].isnull(),'C']=df.loc[df["C"].isnull(),'C'].fillna(df["B"].mean())`
- ☐ `df['C']=np.where(df["E"],df["B"].mean(),0)`

Bon Travail♣