ENONCE DE PROJET ©

Matière : Data Mining & ML
Discipline : 2ème année Génie Informatique
Année Universitaire : 2026-2027 / S1

Enseignants : Taoufik Ben Abdallah
Radhouane Guermazi

1. Présentation et objectifs

Réaliser une étude complète de Data Mining et de Machine Learning à partir de données réelles, depuis la formulation d'une problématique jusqu'à la proposition d'un scénario crédible d'exploitation du modèle. La qualité de la démarche, la justification des choix et l'interprétation des résultats seront prises en compte dans l'évaluation du projet.

2. Constitution des groupes

Le projet est réalisé en groupe de **4 étudiants. Les responsabilités et contributions de chaque membre doivent être identifiables dans chaque étape du projet** (dans le rapport et le notebook). Chaque étudiant reste responsable de la compréhension de l'ensemble du projet.

3. Choix et présentation des données

- **Source des données** : Il est obligatoire d'utiliser un jeu de données réel, provenant d'une source fiable, identifiable et dûment référencée. Toutefois, des modifications ou adaptations du jeu de données original restent envisageables, à condition qu'elles soient clairement documentées et justifiées, tout en préservant la cohérence et la pertinence des données pour la problématique étudiée.
- **Taille et descripteurs :** Le jeu de données doit comporter au minimum **3000 observations** et **10 variables explicatives exploitables**.
- **Qualité et distribution des données :** Le jeu de données doit contenir au moins **100 valeurs manquantes** (`NaN`) et présenter au moins une variable numérique dont la distribution est *asymétrique*.
- **Problématique d'apprentissage** : Définir une problématique pertinente d'apprentissage supervisé, relevant de la classification ou de la régression.

4. Travail demandé

A. Exploration des données (EDA)

Réaliser au moins quatre analyses exploratoires différentes, adaptées à la nature du jeu de données, en mobilisant des techniques telles que les statistiques descriptives, l'analyse des distributions, les visualisations graphiques, l'étude des corrélations ou les analyses comparatives par groupes. Cette exploration devra également permettre d'identifier les éventuels problèmes de qualité des données, notamment les valeurs manquantes, les doublons, les incohérences, les valeurs aberrantes, le déséquilibre des classes et les attributs redondants. Chaque analyse devra être clairement documentée en précisant son objectif, sa justification, les résultats obtenus, leur interprétation et les conclusions qui en découlent. Pour chaque anomalie identifiée, il conviendra de décrire la méthode de détection, de quantifier son importance, de la visualiser si nécessaire et d'évaluer son impact potentiel, afin d'orienter les choix de nettoyage et de prétraitement.

B. Nettoyage et prétraitement

Appliquer au moins quatre techniques pertinentes et distinctes comme l'imputation, la gestion des doublons/outliers, l'encodage, la mise à l'échelle, la sélection ou la construction de variables, etc.

Documenter pour chaque action : problème → technique → justification → résultat → interprétation.

D. Apprentissage supervisé

Entraîner et comparer au moins quatre algorithmes d'apprentissage supervisé, adaptés à la problématique étudiée. Pour chaque modèle, présenter brièvement son principe de fonctionnement, justifier son choix, explorer et optimiser les hyperparamètres pertinents, puis analyser les résultats obtenus en mettant en évidence ses avantages et ses limites. Les étudiants sont également encouragés à explorer des méthodes d'apprentissage ensembliste (**Ensemble Learning**), notamment le ***Bagging***, le ***Boosting*** et/ou le ***Stacking***, afin de combiner plusieurs modèles et d'étudier leur apport potentiel en matière de performance et de robustesse.

E. Validation et comparaison

Définir une stratégie d'évaluation cohérente (séparation entraînement/test et, si approprié, validation croisée). Choisir des mesures adaptées : `Accuracy`, `précision`, `rappel`, F1, `ROC-AUC` pour la *classification* ; `MAE`, `RMSE` ou R^2 pour la *régression*. Comparer les modèles dans des conditions équitables et commenter les écarts. Justifier le modèle retenu au regard des performances, de la généralisation, de la stabilité, de l'interprétabilité, du coût de calcul et des contraintes métier.

G. Etude comparative avec la littérature (recommandée, non obligatoire)

Consulter, lorsque cela est possible, des travaux scientifiques ayant exploité le même jeu de données ou étudié une problématique similaire. Présenter brièvement les approches et les résultats obtenus, puis les comparer à ceux de votre projet dans les mêmes conditions expérimentales (échantillonnage et métriques d'évaluation). Cette démarche, facultative, permet de situer votre travail par rapport aux études existantes et d'enrichir l'analyse des résultats.

H. Proposition de déploiement

Proposer un scénario concret d'utilisation du modèle final dans un contexte réel ou professionnel, en expliquant comment les prédictions pourraient répondre à un besoin spécifique. Préciser les utilisateurs concernés, les données qu'ils devront fournir, les résultats générés par le modèle ainsi que les bénéfices attendus. Décrire également comment le modèle pourrait être intégré dans une solution informatique, par exemple une application web permettant de saisir des données et d'obtenir une prédiction, une API accessible à d'autres applications ou un tableau de bord facilitant la prise de décision. Illustrer le fonctionnement envisagé à l'aide d'un schéma simple présentant le parcours des données, depuis leur saisie jusqu'à l'affichage des prédictions.

5. Livrables

Échéance	Contenu attendu
15 Novembre 2026 — remise intermédiaire	Dataset et problématique ; exploration ; nettoyage et prétraitement réalisés.
13 Décembre 2026 — remise finale	**Rapport final au format PDF** (20 pages maximum) ; **notebook Jupyter (`.ipynb`) intégralement complété, exécutable et conforme au template fourni** ; jeu de données avant et après prétraitement.

NB : Le notebook `Jupyter` fourni constitue un modèle de référence pour la structuration du projet. Chaque groupe doit le compléter et l'adapter à sa problématique en intégrant les données, le code Python fonctionnel, les expérimentations, les visualisations, les justifications méthodologiques et les interprétations des résultats. Le notebook doit être intégralement complété, exécuté et déposé avant la soutenance, en complément des autres livrables exigés.

6. Evaluation & Soutenance

En complément du `notebook Jupyter` et du `rapport écrit`, chaque groupe devra préparer une présentation PowerPoint structurée en trois parties :

- **Contexte et motivation :** présenter le cadre du projet.
- **Travail réalisé** : décrire les tâches effectuées, en détaillant les étapes suivies, les choix réalisés, et en interprétant les résultats obtenus à l'aide de diverses métriques et études comparatives.
- **Conclusion et perspectives :** proposer des pistes d'amélioration pouvant être utiles pour optimiser les résultats obtenus.

Barème indicatif (/21)

Choix & compréhension du dataset	**Exploration & analyse**	**Prétraitement des données**	**Apprentissage supervisé**	**Validation & comparaison**	**Qualité de la justification**	**Proposition de déploiement**	**Rapport & reproductibilité**	**Etude comparative avec la littérature**	**Soutenance**
1.5pts	1.5 pts +1 innovation	2pts +1 innovation	1.5pts +1 innovation	2.5pts	2pts	1.5pts	1.5pts	1pt	3pts

NB :

- ***Présentation orale*** **:** La durée de la présentation ne doit pas dépasser **8 minutes**. Il est recommandé de privilégier les explications, les résultats et les analyses plutôt que les captures d'écran du code.
- ***Originalité et maîtrise du travail*** **:** Chaque groupe doit réaliser un travail original et être capable d'expliquer et de justifier son code, ses résultats et ses analyses. Toute similarité significative et injustifiée entre plusieurs projets (`code`, `analyses`, `résultats` ou `rapport`) pourra entraîner une sanction pouvant aller jusqu'à **0/20** pour les projets concernés.
- ***Contribution individuelle et évaluation*** **:** Chaque membre du groupe peut se voir attribuer **une note individuelle différente**, en fonction de sa contribution effective au projet, de sa maîtrise du travail réalisé et de sa capacité à défendre ses résultats. Les contributions de chaque membre doivent être ***clairement précisées*** dans le `notebook`**, à l'emplacement prévu, ainsi que dans le** `rapport final`.
- ***Innovation et créativité*** **:** L'innovation peut se traduire par l'application de techniques non abordées en classe ou par la proposition d'une combinaison originale et pertinente de différentes méthodes.
- ***Barème d'évaluation*** **:** Le barème est fourni à titre indicatif et peut faire l'objet d'ajustements. Il comporte **21 points au total, dont 20 points pour les critères principaux et 1 point bonus** attribué à la réalisation d'une étude comparative pertinente avec les travaux de la littérature.

Bon Travail ♣