Travaux pratiques n°1 — #numpy/ pandas/matplotlib & seaborn

Matière : Data Mining & ML
Enseignants : Taoufik Ben Abdallah
Discipline : 2ème année Génie Informatique SDIA
Radhouane Guermazi
Année Universitaire : 2026-2027 / S1

L'objectif de ce TP est de revoir les prérequis essentiels pour introduire les concepts de data mining et de machine learning, en mettant l'accent sur l'utilisation des bibliothèques `numpy`, `pandas`, `matplotlib` et `seaborn`. Au cours de ce TP, vous explorerez, traiterez et visualiserez les données d'un jeu de données contenant des informations sur 213 athlètes, disponible dans le fichier **`"athlete.csv"`**. Chaque athlète est décrit par les attributs suivants : `Gender`, `Age`, `Height/Weight` et `Sport`. Le sexe peut être soit `"M"` pour Homme, soit `"F"` pour Femme, et le sport peut être `"Athlétisme"`, `"Gymnastique"`, `"Football"`, `"Basketball"` ou `"Judo"`. L'attribut `Age` peut contenir des valeurs *indéfinies*, marquées par « `X` ».

Le **Tableau 1** montre un extrait du jeu de données présent dans le fichier `"athlete.csv"`

	Gender	**Age**	**Height/ Weight**	**Sport**
0	M	24	180.0/80.0	Basketball
1	M	23	170.0/60.0	Judo
2	M	28	175.0/64.0	Gymnastics
3	M	28	175.0/64.0	Gymnastics
4	M	X	175.0/64.0	Basket
...	...	...	...	...

Tableau 1 : Extrait du jeu de données `athlete.csv`

Travail à Faire :

1/ Charger le jeu de données **`"athlete.csv"`** dans un DataFrame nommé **df_athlete**, puis afficher sa taille et les types de données de chaque attribut

2/ Diviser les valeurs de la colonne **`Height/Weight`** dans **df_athlete** en deux colonnes distinctes en utilisant le caractère **`"/"`** comme séparateur. Ajouter ensuite ces deux nouvelles colonnes, nommées **`Height`** et **`Weight`**, à **df_athlete** en les plaçant en troisième et quatrième position (**NB.** Ces colonnes remplaceront la colonne **`Height/Weight`** existante)

3/ Remplacer les valeurs «`Basket`» par «`Basketball`» dans la colonne **`Sport`** de **df_athlete**. Afficher les `5` premières lignes de **df_athlete**

4/ Renommer la colonne **`"Gender"`** en **`"Sex"`** dans **df_athlete**. Afficher les `3` dernières lignes de **df_athlete**

5/ Afficher le sport l*e plus fréquemment pratiqué* pour chaque sexe (`M` et `F`)

6/ Créer une série, nommé **S_HW**, en utilisant les valeurs de hauteur (**`Height`**) et de poids (**`Weight`**) selon la formule suivante : `Height-Weight-100`. Ensuite, ajouter une colonne nommée `"State"` en dernière position dans **df_athlete**. Cette colonne doit contenir `3` valeurs discrètes : «`perfect`» si la valeur correspondante dans **S_HW** est comprise entre `0` et `10` inclus, «`Excessive`» si la valeur est supérieure à `10`, et «`Insufficiency`» si la valeur est inférieure à `0`

7/ Créer une figure de taille `3×11` pouces comprenant deux axes alignés *horizontalement*. Le premier axe, intitulé «`HIST`», doit afficher un histogramme montrant la répartition des athlètes *selon leur sport*. Le deuxième axe, intitulé «`PIE`», doit afficher un diagramme en secteurs illustrant la distribution des athlètes *en fonction de leur état* (**`State`**)

8/ Remplacer les valeurs « `X` » dans la colonne **`Age`** par la moyenne des âges des athlètes ayant le même sexe et le même sport que l'athlète concerné. Convertir la colonne **`Age`** de **df_athlete** en type *entier*. Afficher ensuite **df_athlete**

9/ Trier les observations de **df_athlete** par ordre *décroissant* selon la colonne **`Age`** et réinitialiser les indices des lignes

10/ Écrire une fonction **`tracer_courbe(age=16)`** qui prend un paramètre **`age`** (par défaut age**`=16`**) et retourne un graphique montrant le *poids maximum* des athlètes en fonction de leur âge à partir de **df_athlete**. La fonction doit également **marquer la valeur du poids maximum** des athlètes pour l'âge spécifié (*si cet âge existe dans les données*). Tester cette fonction avec **`age=34`**

11/ Tracer un histogramme montrant la distribution des athlètes en fonction de `4` intervalles d'âge. Indiquer les valeurs des intervalles sur les axes des `x` (*xticks*) du graphique

12/ Supprimer les athlètes dont l'âge appartient à l'intervalle d'âge ayant le moins d'occurrences

13/ Tracer le nuage de points (*scatter*) de **`Height`** en fonction de **`Weight`** ainsi que de **`Height`** en fonction d'**`Age`**. Ajouter une légende à la figure et supprimer les titres des axis

14/ Transformer les colonnes **`Height`** et **`Weight`** de **df_athlete** en deux tableaux (*ndarray*) : le premier, un tableau `1D` nommé **X**, pour la colonne **`Height`**, et le second, un tableau `2D` nommé **Y**, pour la colonne **`Weight`**

Bon Travail ♣