Travaux pratiques n°2 — #Prétraitement de données

Matière : Data Mining & ML
Enseignants : Taoufik Ben Abdallah
Radhouane Guermazi

Discipline : 2ème année Génie Informatique SDIA

Année Universitaire : 2026-2027 / S1

L'objectif de ce TP est d'explorer et d'étudier les données, ainsi que d'appliquer des techniques de prétraitement sur le jeu de données décrit dans le fichier ***titanic.csv***. Ce jeu de données est constitué de **891** observations décrivant 9 attributs (**Sex, Age, SibSp, Parch, Ticket, Fare, Cabin, Embarked** et **Survived**).

Le **Tableau 1** montre un extrait du jeu de données ***titanic.csv***

Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived
male	22.0	1	0	A/5 21171	7.25	**NaN**	S	**no**
female	38.0	1	0	PC 17599	71.2833	C85	C	**yes**
female	26.0	0	0	STON/O2. 3101282	7.925	**NaN**	S	**yes**
female	35.0	1	0	113803	53.1	C123	S	**yes**
male	35.0	0	0	373450	8.05	**NaN**	S	**no**
male	**NaN**	0	0	330877	8.4583	**NaN**	Q	**no**

Tableau 1 : Extrait de jeu de données titanic.csv

Travail à Faire :

1/ Charger le jeu de données titanic.csv dans une variable nommée **df_titanic**. Afficher le nombre total d'observations ainsi que les **5** premières lignes de **df_titanic**

2/ Afficher le type de chaque attribut de **df_titanic** en indiquant le nombre d'observations *non-null* pour chaque attribut

3/ Afficher un résumé statistique de toutes les colonnes de **df_titanic**

4/ Déterminer le nombre total de valeurs manquantes (**NaN**) ainsi que celui pour chaque attribut

5/ Créer deux listes, **l_discret** et **l_num**, qui contiennent respectivement les noms des colonnes avec des valeurs *catégorielles* et *numériques* dans **df_titanic**

6/ Présenter la matrice de corrélation de Pearson entre les différents attributs numériques de **df_titanic**

7/ Représenter les *boxplots* de l'attribut **"Fare"** de **df_titanic**, en fonction des valeurs de l'attribut numérique qui présente la corrélation la plus élevée. Ensuite, remplir les valeurs manquantes de l'attribut **"Fare"** avec les valeurs appropriées

8/ Trier **df_titanic** *en ordre décroissant* en fonction de l'attribut ayant une forte corrélation positive avec **"Age"**. Ensuite, remplir les valeurs manquantes de l'attribut **"Age"** de **df_titanic** avec les valeurs de la cellule précédente dans la même colonne

9/ Remplir les valeurs manquantes de l'attribut **"Cabin"** de **df_titanic** avec l'élément le *plus fréquent*

10/ Supprimer les observations ayant des valeurs manquantes dans l'attribut **"Embarked"** de **df_titanic**

11/ Créer une figure avec **4** axes où chaque ligne comporte 2 axes : chacun de ces axes affiche l'*histogramme de la distribution* d'un attribut catégoriel à partir de **df_titanic**. Ensuite, supprimer l'attribut ou les attributs *discret(s)* **que vous jugez inutiles** à partir de **df_titanic**

12/ Vérifier que **df_titanic** ne comporte aucune valeur manquante et traiter les données aberrantes de tous les attributs *numériques* de **df_titanic**

13/ Encoder les valeurs des attributs **"Sex"** (**female**, **male**) et **"Embarked"** (**C**, **Q** et **S**) de **df_titanic** en valeurs numériques ordinales

14/ Afficher un histogramme illustrant la *distribution des âges* de **df_titanic** selon 4 intervalles, avec une *courbe de densité gaussienne* intégrée dans la même figure. Ensuite, discrétiser les valeurs en utilisant un encodage ordinal, en choisissant la technique appropriée

15/ Sélectionner les descripteurs les plus importants à partir de **df_titanic** en appliquant la technique de la variance, avec un seuil ne dépassant pas 0.1

Bon Travail ♣