IIT
INSTITUT
INTERNATIONAL
TECHNOLOGIE
Université Nord Américaine Privée

Cours
Entrepôt de données

Dr. Salma DAMMAK & Dr. Taher LAABIDI

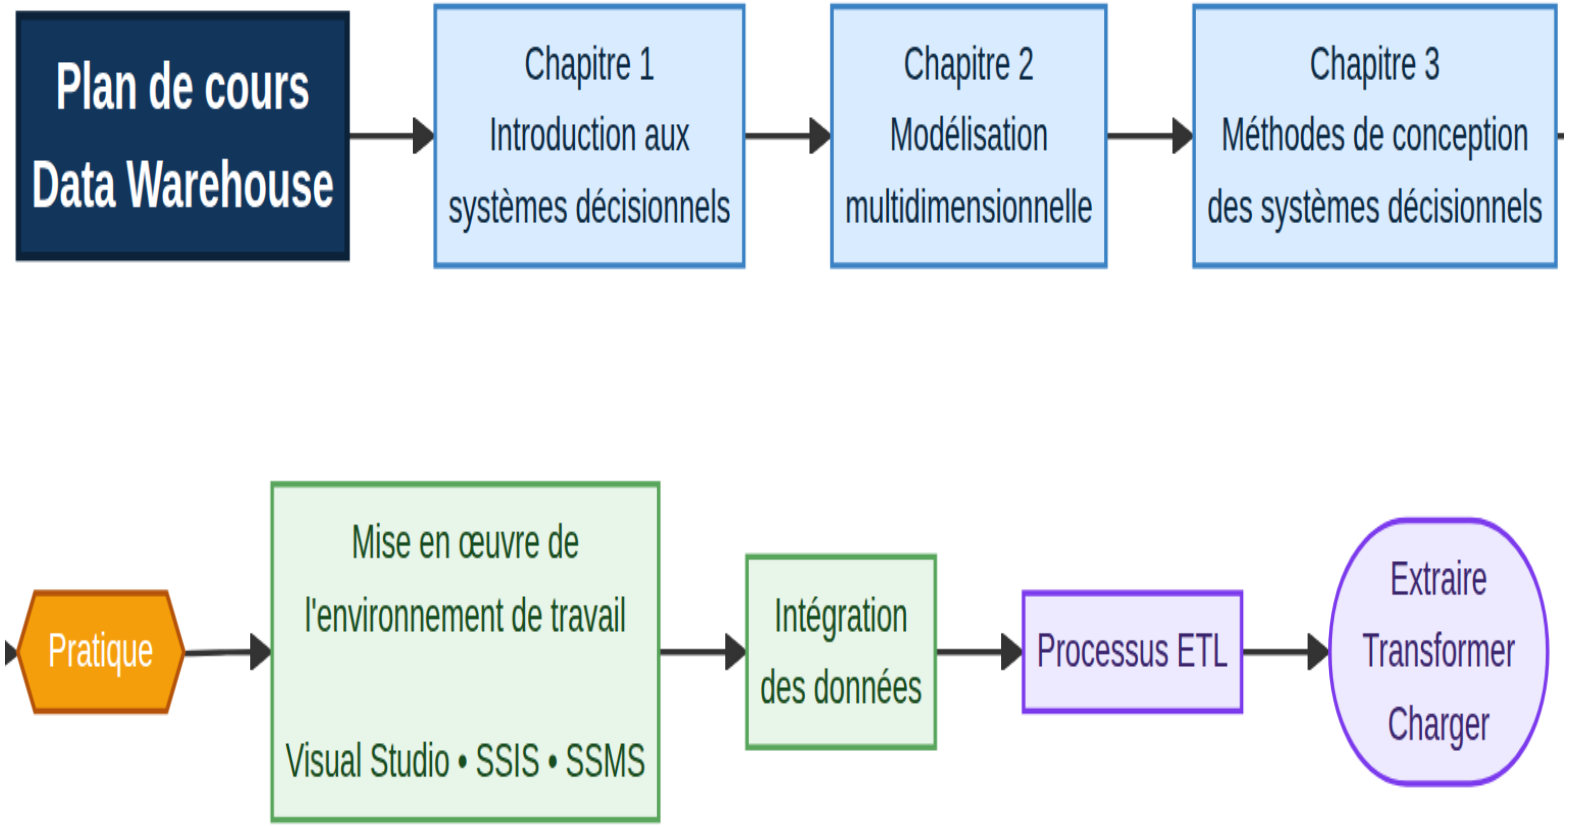
2ème année GLID -SDIA

damak.salma@iit.ens.tn & taher.laabidi@iit.ens.tn

Objectif du cours

- Comprendre le rôle du Data Warehouse dans la Business Intelligence (BI)
- Connaître les concepts fondamentaux de modélisation
- Apprendre à modéliser un entrepôt de données
- Étudier les processus d’intégration des données (ETL)
  - Application sur un projet d’intégration

Plan du cours



MÉTIER D'INGÉNIEUR EN GÉNIE LOGICIEL ET INFORMATIQUE DÉCISIONNELLE



MÉTIERS

- Ingénieur logiciel
- Data engineer
- Data scientist
- Ingénieur BI
- Architecte cloud
- Ingénieur IA
- Data analyst
- ML engineer
- Testeur logiciel

MÉTIERS D'INGÉNIEUR EN SCIENCE DES DONNÉES ET INTELLIGENCE ARTIFICIELLE



MÉTIERS

- Data engineer
- Data scientist
- Ingénieur IA
- Ingénieur machine learning
- Ingénieur data
- Ingénieur en vision par ordinateur
- Ingénieur en informatique décisionnelle
- Ingénieur en big data

MÉTIER D'INGÉNIEUR EN ADMINISTRATION RÉSEAU ET SÉCURITÉ INFORMATIQUE



- Ingénieur en intelligence artificielle
- Ingénieur en tests d'intrusion (pentesting)
- Ingénieur en cryptographie
- Ingénieur réseaux et systèmes
- Ingénieur DevOpsSec
- Ingénieur en cybersécurité

Chapitre 1

Introduction aux Systèmes décisionnels

Objectif du chapitre

- Comprendre le rôle et les enjeux des systèmes décisionnels dans le processus de prise de décision.
- Découvrir l'architecture d'un système décisionnel ainsi que les différentes étapes de sa modélisation.
- Maîtriser les principales étapes de conception et d'implantation d'un système décisionnel.
- Explorer les nouvelles générations d'entrepôts de données et leurs principales évolutions.

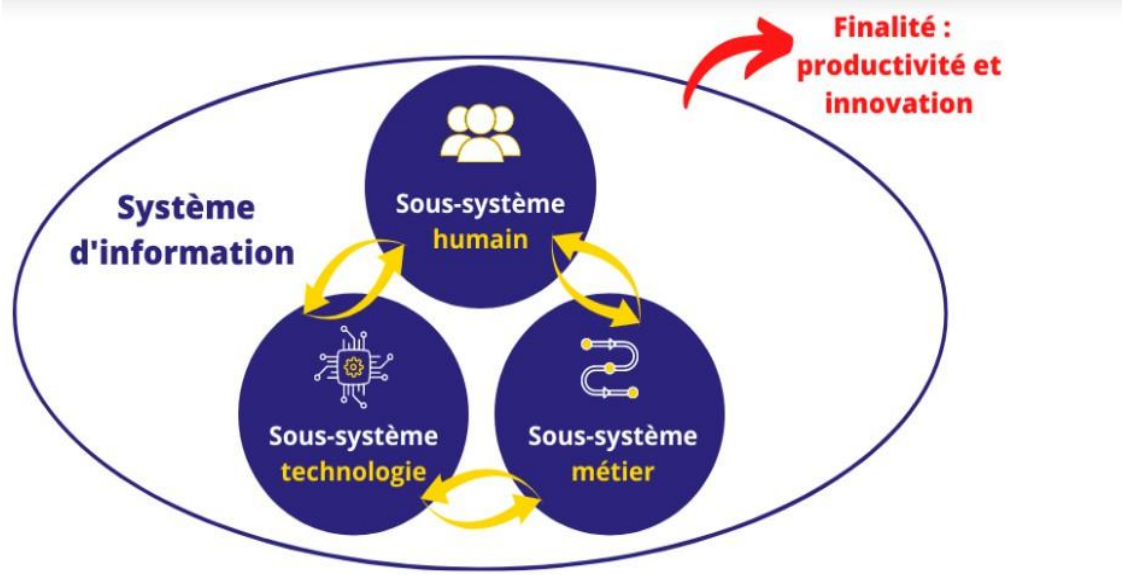
Contenu

1) **Introduction**
2) **Définition du concept décisionnel**
3) **Architecture des systèmes décisionnels**
   a. **Sources des données**
   b. **Processus ETL**
   c. **Entrepôt des données et magasins**
   d. **Exploitation des données**
4) **Comment implanter un système décisionnel?**
5) **Evolution des entrepôts de données**

Introduction

Introduction

- SI est le véhicule de la communication dans l'entreprise



- Permet aux différents acteurs de véhiculer des informations et de communiquer grâce à un ensemble de ressources matérielles, humaines et logicielles
- Principales fonctions d'un SI: Saisie, Mémorisation, Traitement, Communication

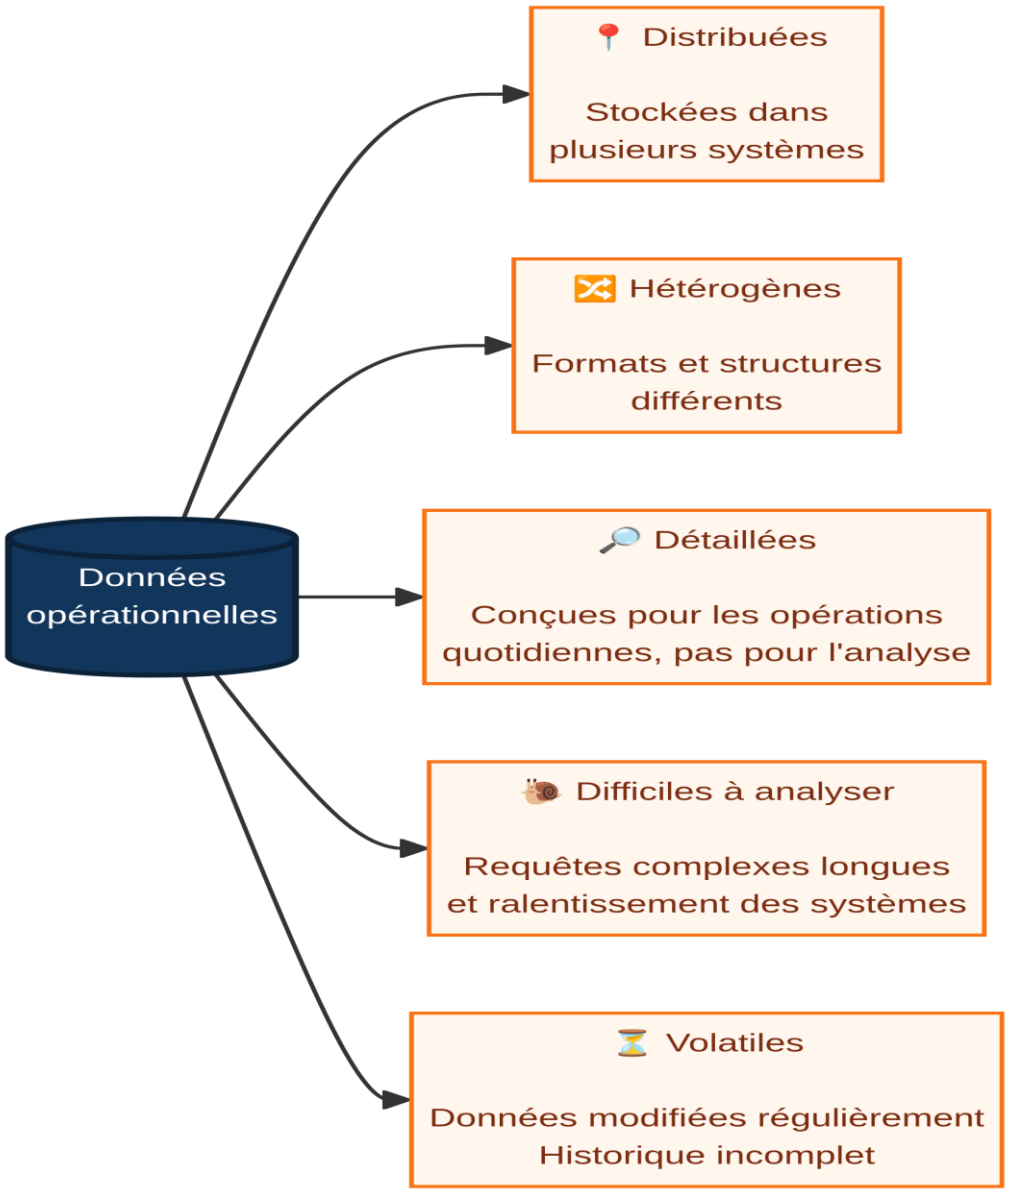
Introduction

Les données de l'entreprise : une richesse difficile à exploiter

Une entreprise produit et collecte **une grande quantité de données** à partir de différente sources :

- 🗄️ Bases de données
- 📄 Fichiers Excel, CSV, etc.
- 👥 Systèmes de gestion des ressources humaines
- 🏢 Applications métiers
- 🌐 Sources externes

Introduction



😕 **Beaucoup de données ≠ beaucoup d'informations utiles**

L'entreprise dispose d'une **grande quantité de données**, mais il est parfois difficile de les exploiter pour répondre rapidement aux questions des décideurs.

💡 **Comment transformer ces données en informations utiles à la décision ?**

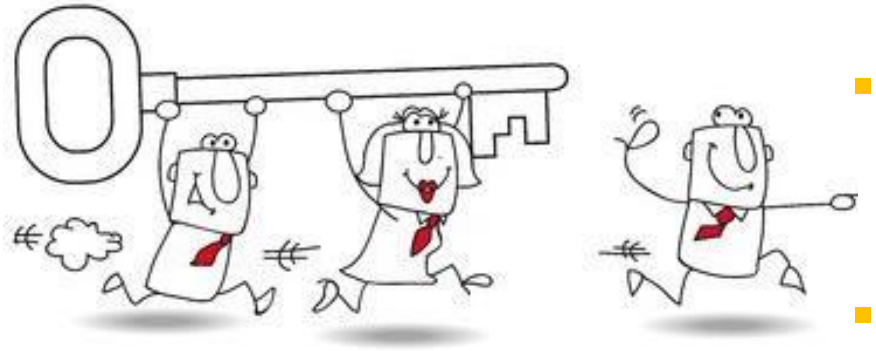
Introduction



Améliorer les performances décisionnelles de l'entreprise en répondant aux demandes d'analyse des décideurs non informaticiens et non statisticiens.



Introduction



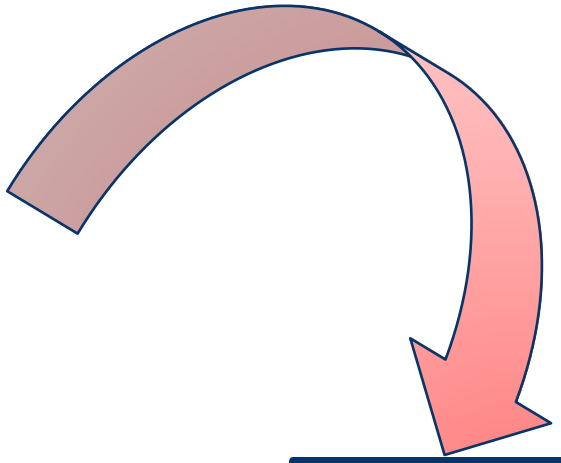
- Solution
  - Passer du système d'information qui avait une vocation de production à **un SI décisionnel** dont la vocation de **pilotage** devient majeure.
  - L'entreprise a besoin:
    - ✓ Accès rapide et simple à l'information stratégique
    - ✓ Vision transversale des données de l'entreprise
    - ✓ Extraire, grouper, organiser, transformer les données

Définition du concept décisionnel

Définition du concept décisionnel

Base données transactionnelle:

Une BD classique destinée à assumer des transactions en temps réel Ajout, mise à jour suppression de données



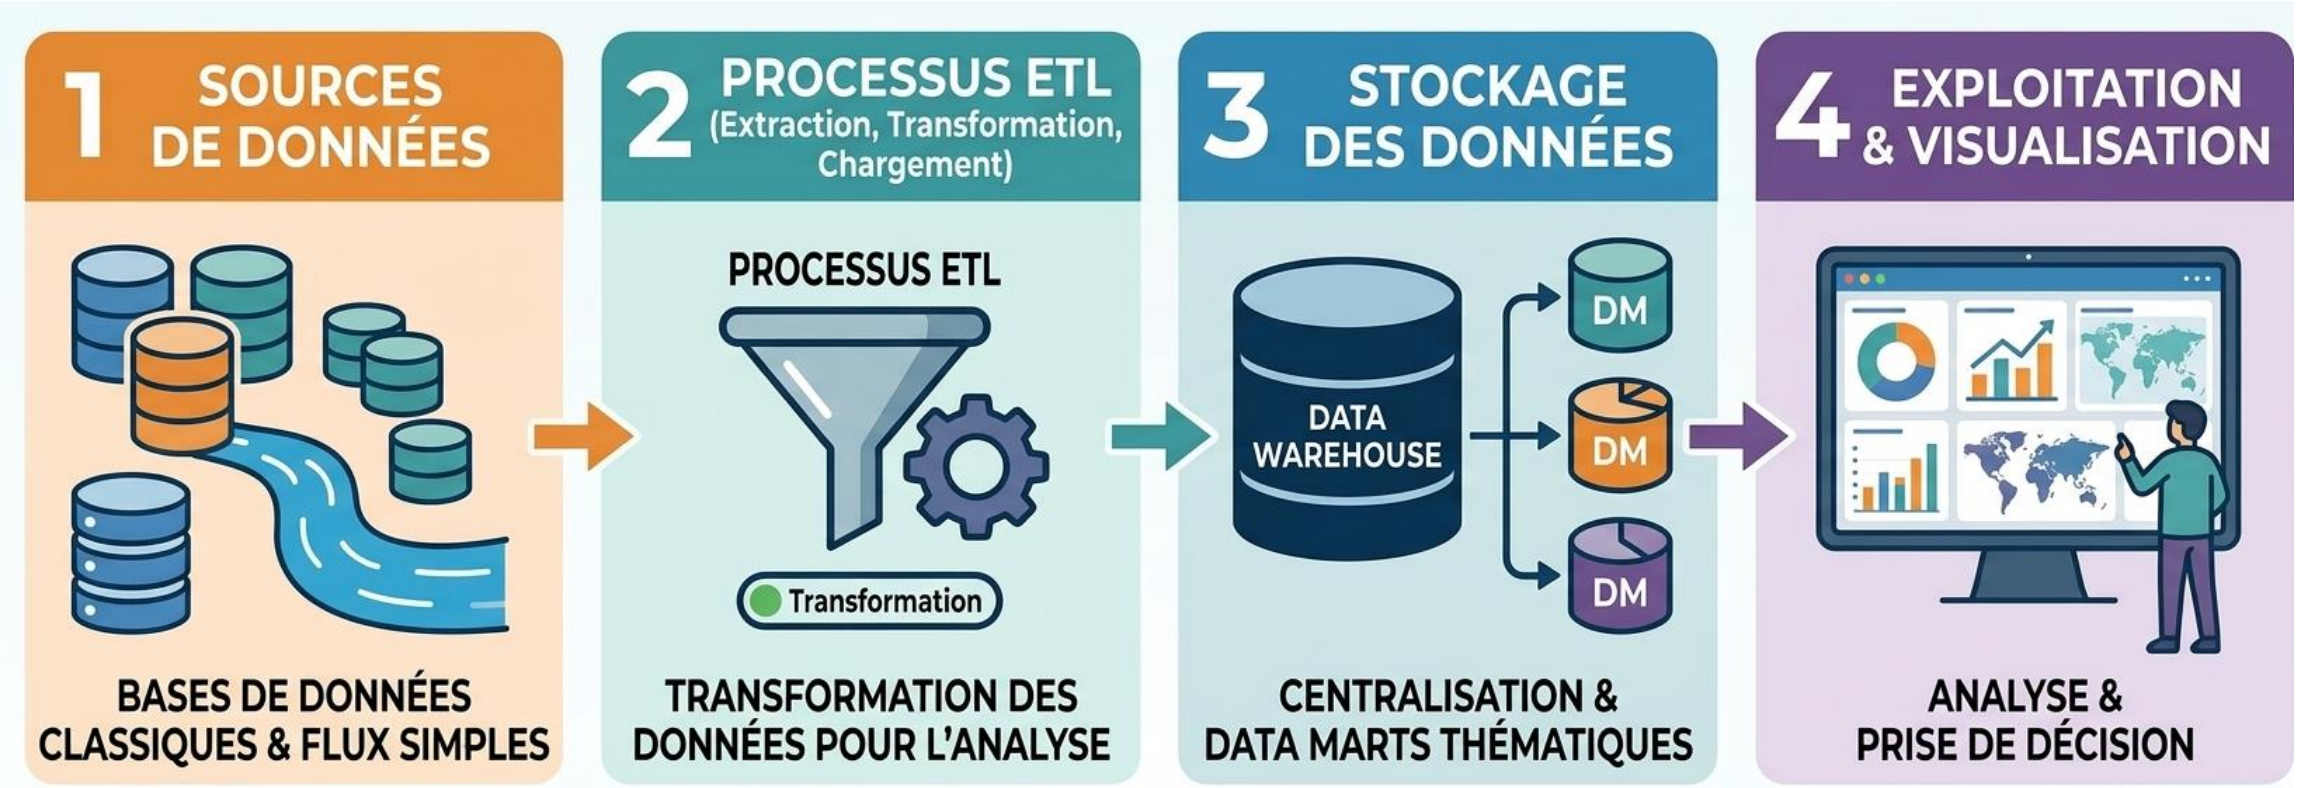
Data warehouse:

Un DW destiné uniquement à l'exécution de questions statistiques sur des données statiques (ou faiblement dynamiques).

Définition du concept décisionnel

- Fonctions d'un DW :
  - ✓ Systèmes pour l'aide à la prise de décisions (OLAP)
  - ✓ Regrouper, organiser des informations de sources diverses
  - ✓ Intégrer et stocker les données pour une vue orientée métier
  - ✓ Retrouver et analyser l'information rapidement et facilement

Définition du concept décisionnel



Architecture d'un système décisionnel

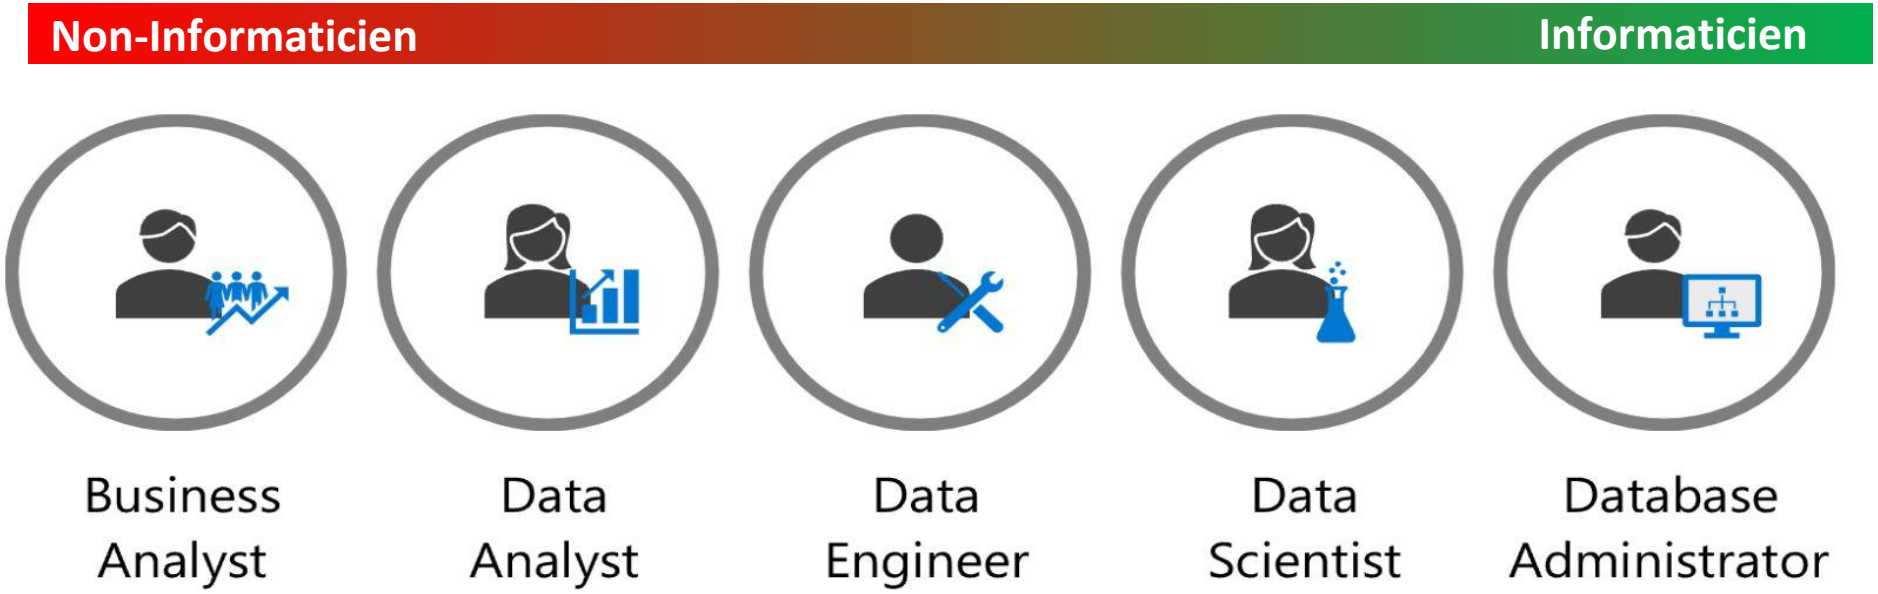
Définition du concept décisionnel



Les rôles dans la BI

- Initialement, les outils BI étaient principalement utilisés par les analystes de données et les professionnels informatiques qui se chargeaient d'analyser les données et de produire des rapports.

- Aujourd'hui, de plus en plus les exécutifs et les employés utilisent eux-mêmes les logiciels BI, notamment grâce à l'essor du self-service BI et des outils de découverte de données.



Les rôles dans la BI

Métier	Rôle principal	Principales responsabilités
Administrateur de bases de données (DBA)	Assurer le bon fonctionnement des bases de données	Gérer les bases de données, surveiller leurs performances, assurer leur disponibilité et leur sécurité.
Data Scientist	Extraire de la valeur à partir des données	Réaliser des analyses avancées, appliquer des méthodes statistiques et de Machine Learning pour identifier des tendances et faire des prédictions.
Data Engineer	Collecter, intégrer et préparer les données	Développer des pipelines de données, intégrer des données provenant de différentes sources et les transformer pour les rendre exploitables.
Data Analyst	Transformer les données en informations exploitables	Nettoyer et transformer les données, concevoir des modèles de données, créer des rapports et des tableaux de bord pour faciliter l'analyse.
Business Analyst	Relier les données aux besoins de l'entreprise	Comprendre les besoins métier, interpréter les résultats des analyses et formuler des informations utiles à la prise de décision.

Les rôles dans la BI

La chaîne de valeur de la donnée



Chaque métier joue donc un rôle complémentaire dans la transformation des **données brutes** en **informations utiles à la prise de décision**.

Définition du concept décisionnel

- ✓ Intégration des données à partir de sources multiples et Hétérogènes
- ✓ Répondre aux requêtes du système d'aide à la décision.
- ✓ Plus efficace en coût d'exécution des requêtes

On-Line Analytical Processing OLAP

Définition du concept décisionnel

- ✓ **OLTP**: consultent et mettent à jour les données des BD opérationnelles.
  - Exécution en temps réel des transactions, pour l'enregistrement des opérations quotidiennes : inventaires, commandes, paye, comptabilité

- ✓ **OLAP**: lisent les données seulement pour avoir de nouvelles informations à partir des données sources.
  - Rapports, Etats, Tableaux de Bord, Graphiques, Synthèses, Groupement,...
  - Traitement efficace des requêtes d'analyse pour la prise de décision.

Définition du concept décisionnel



Peut on partager la même BD entre OLAP et OLTP?

Définition du concept décisionnel

Tableau Comparatif OLTP VS OLAP

Critère	OLTP – Système transactionnel	OLAP – Système décisionnel
🎯 **Objectif**	Gérer les opérations quotidiennes de l'entreprise	Analyser les données pour aider à la décision
💡 **Question principale**	« Que se passe-t-il maintenant ? »	« Que s'est-il passé et pourquoi ? »
📊 **Type de données**	Données détaillées, actuelles et dynamiques	Données historiques, agrégées et volumineuses
⚙️ **Opérations**	Ajouter, modifier, supprimer et consulter des données	Consulter, analyser, comparer et explorer les données
🗂️ **Organisation des données**	Nombreuses tables normalisées	Modèles en étoile ou en flocon
🔍 **Requêtes**	Courtes et fréquentes	Complexes et souvent longues
👥 **Utilisateurs**	Nombreux utilisateurs simultanés	Généralement moins nombreux
⚡ **Priorité**	Rapidité des transactions	Rapidité et performance de l'analyse
🕐 **Historique**	Principalement les données courantes	Conservation de l'historique sur plusieurs périodes

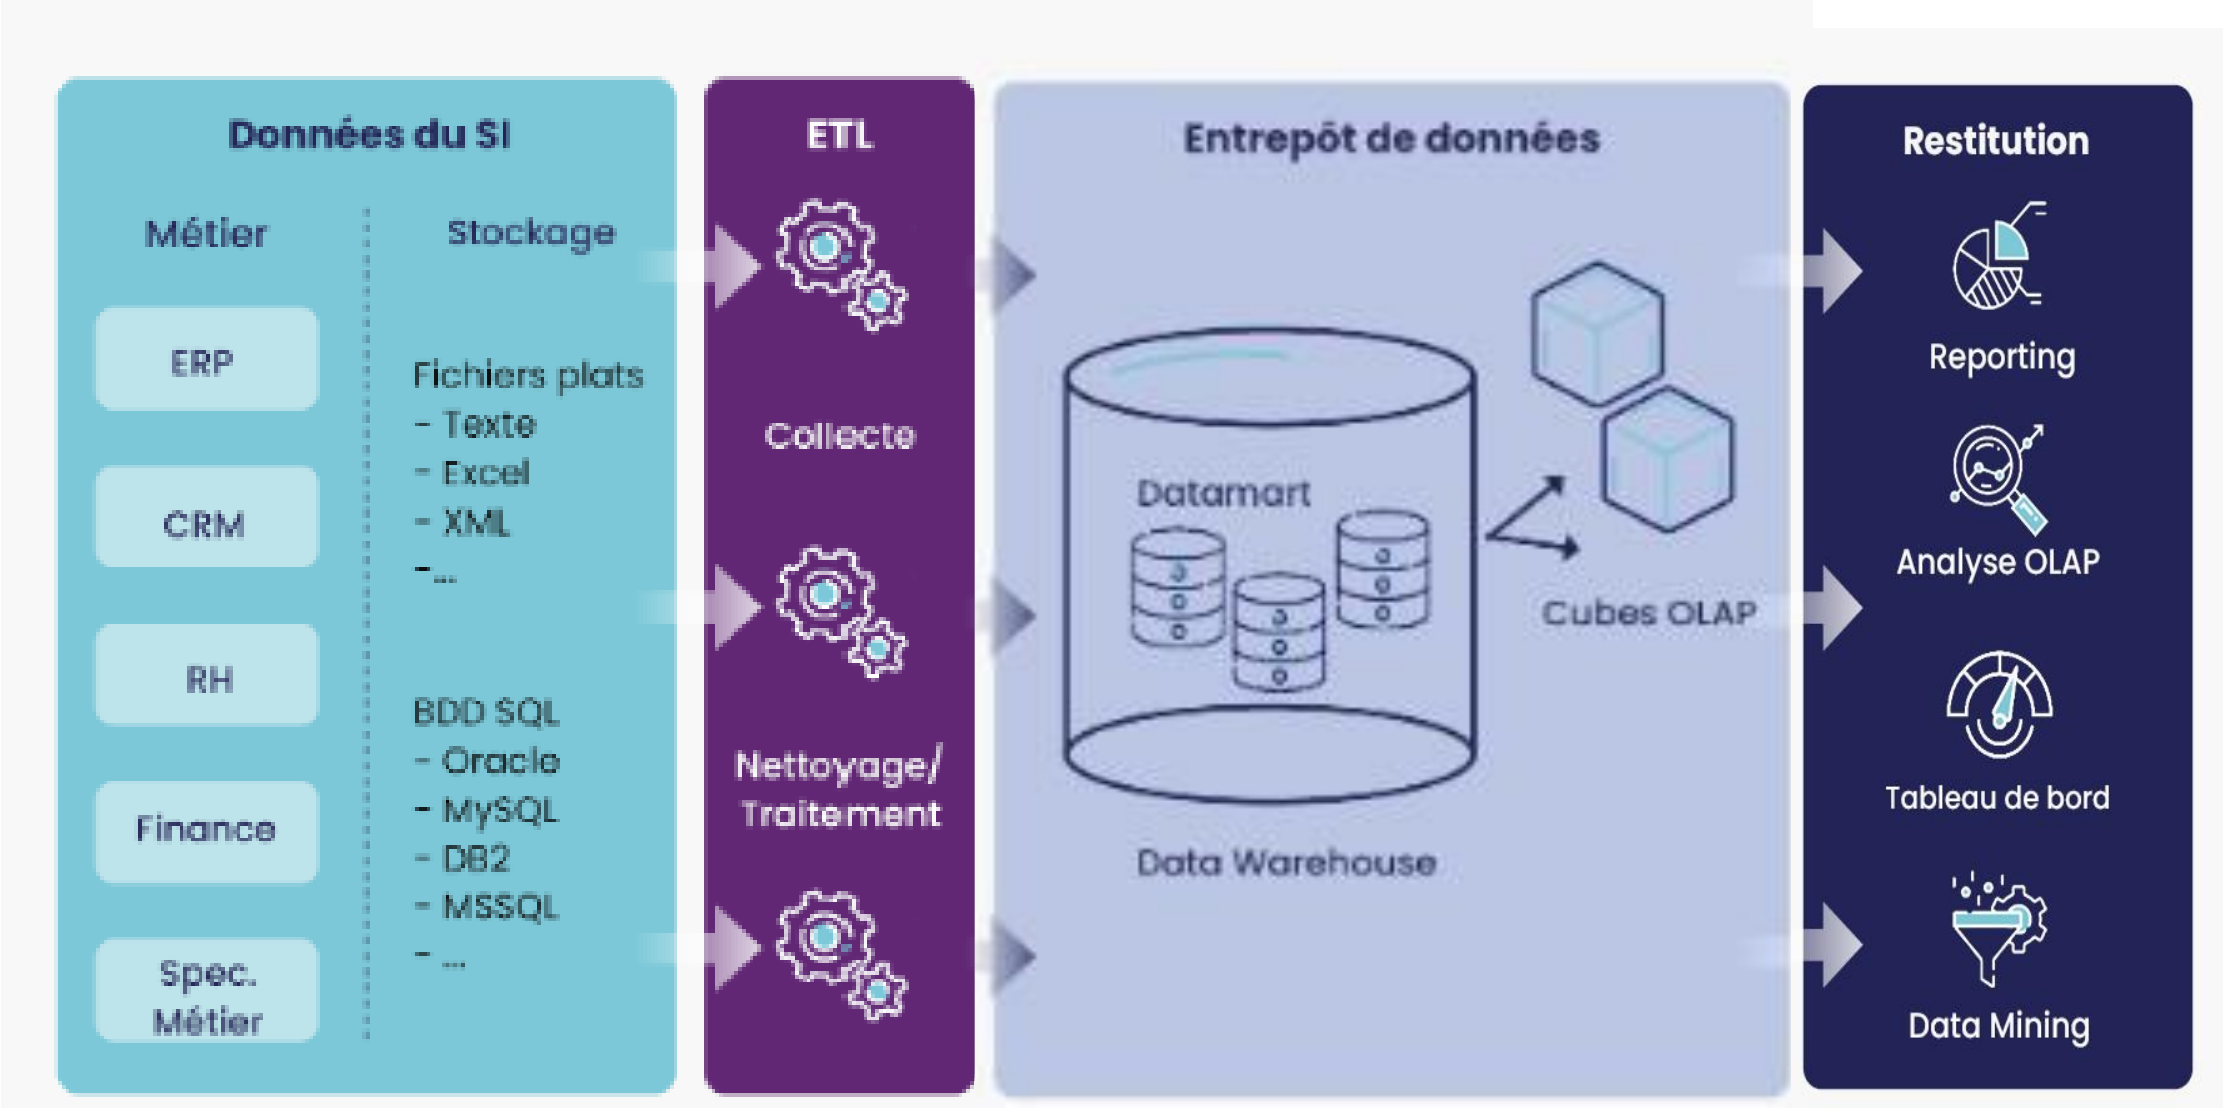
Définition du concept décisionnel

Exemple concret : une entreprise de vente

Situation	OLTP	OLAP
Un client achète un produit	✅ Enregistre la vente	—
Mise à jour du stock	✅	—
Consultation d'une commande	✅	—
Analyse des ventes mensuelles	—	✅
Comparaison des ventes 2025 / 2026	—	✅
Identifier le produit le plus vendu	—	✅
Analyser les ventes par région	—	✅
Préparer un tableau de bord pour le directeur	—	✅

Architecture des systèmes décisionnels

Architecture des systèmes décisionnels



Architecture des systèmes décisionnels

- ✓ Les sources de données
  - Enterprise Resource Planning (ERP): Gèrent les processus opérationnels d'une entreprise (ex: ressources humaines, finances, distribution, approvisionnement, etc.).
  - Customer Relationship Management (CRM): Gèrent les interactions d'une entreprise avec ses clients (ex: marketing, ventes, après-vente, assistance technique, etc.).
  - Point of sale (POS): Matériels et logiciels utilisés dans les caisses de sorties d'un magasin.
  - WEB: Clickstreams (fichier log), structure site web.
  - Externes: données concurrentielles achetées, données démographiques

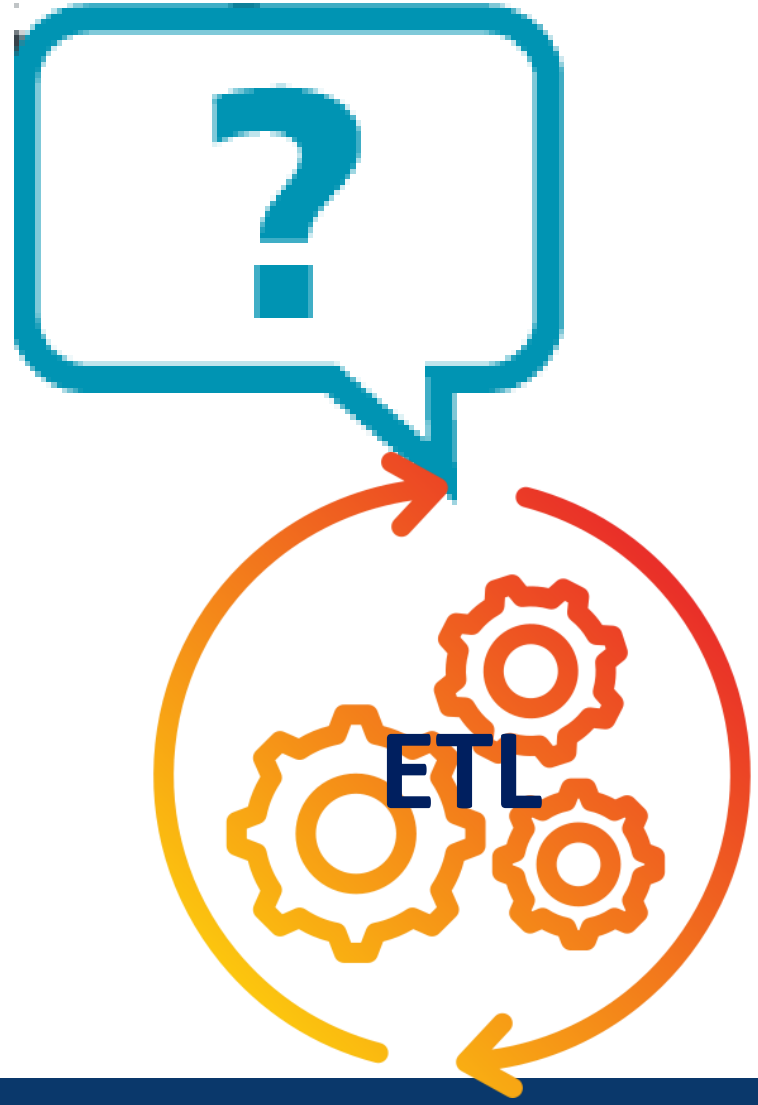
Architecture des systèmes décisionnels

- ✓ Les sources de données
  - ✓ ***DSA:*** ***Data Staging Area***
    - Zone de préparation des données
    - Base de données intermédiaire qui stocke les données issues des systèmes de production opérationnelle dans un format proche de ces derniers.
    - Un stockage tampon avant l'intégration des données dans l'ED.

Architecture des systèmes décisionnels

- ✓ Les sources de données

  - Sources diverses et disparates (ex: BD, fichier texte, etc.)
  - Sources sur différentes plateformes et OS (operating system)
  - Qualité de données douteuse et changeante dans le temps
  - Incohérence entre les différentes sources
  - Données dans un format difficilement interprétable ou ambigu.



Architecture des systèmes décisionnels

- ✓ Les processus ETL: Extract Transform Load

  - Résume généralement les données afin de réduire leur taille et d'améliorer leur performance pour des types d'analyse spécifiques.
  - Partie la plus complexe du développement (jusqu'à 70% du temps total).

Architecture des systèmes décisionnels

- Les processus ETL: Extract Transform Load
  - **Extrait** l'information nécessaire à l'analyse
    - Identifier les données sources utiles
    - Déterminer tous les changements survenus durant une période donnée (ex: heure, jour, semaine, mois).
  - **Transforme** : Consolider les données
    - Données redondantes, manquantes, incohérentes, etc.
    - Découpage, fusion, conversion, aggrégation, ..
  - **Charge** (Load) les données dans l'ED
    - Faire les chargements en lot dans une période creuse (entrepôt de données non utilisé);
    - Avoir un plan pour évaluer la qualité des données chargées dans l'entrepôt;
    - Commencer par charger les données des tables de dimension

Architecture des systèmes décisionnels

- ✓ Entrepôt de données (DataWarehouse)
  - Lieu de stockage centralisé
  - Intègration et «historisation» de l'ensemble des données utiles pour les prises de décisions.
  - Son organisation doit faciliter la gestion des données et la conservation des évolutions.

> Un entrepôt de données est une collection de données orientées sujet, integrées, non volatiles, historisées, organisées pour le support d'un processus d'aide a la décision.»
>
> (Bill Inmon, 1996)

Architecture des systèmes décisionnels

- ✓ Entrepôt de données (DataWarehouse)
  - Orientées sujet :
    - L'entrepôt renferme des informations de différents services de l'entreprise

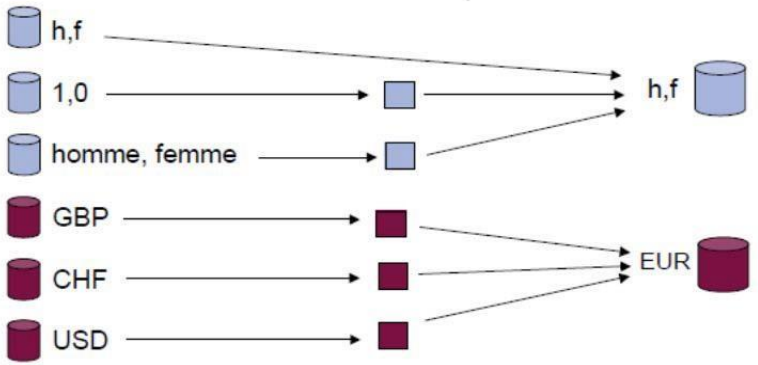
    Les informations de l'entrepôt sont organisées par sujet avant d'être intégrées dans l'entrepôt



  - Intégrées :
    - Le contenu d'un entrepôt est le résultat de l'intégration des données

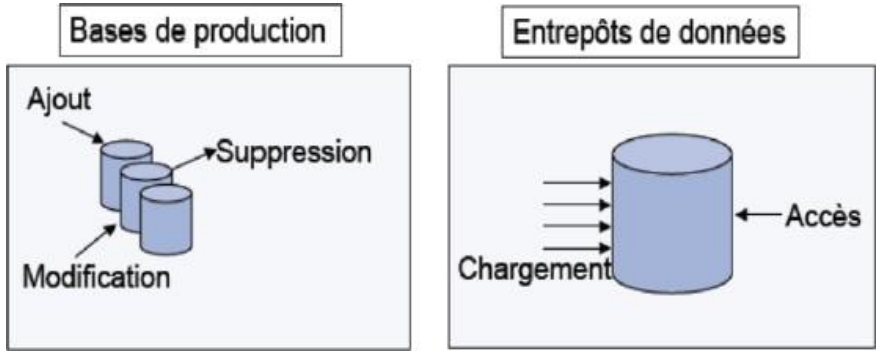
    en provenance de multiples sources.
    - L'intégration nécessite une bonne maîtrise de la sémantique des

    données.



Architecture des systèmes décisionnels

- ✓ Entrepôt de données (DataWarehouse)
  - Non volatiles :
    - Les données stockées dans un ED sont en mode consultation
    - Elles ne peuvent être ni supprimées ni modifiées



  - Historisés :
    - L'historisation des données permet de suivre l'évolution des différentes valeurs dans le temps

Base de production

Image de la base en Avril 2015

Répertoire

Nom	Ville
Karim	Tunis
Ahmed	Sfax

Image de la base en Janvier 2016

Répertoire

Nom	Ville
Karim	Sousse
Ahmed	Sfax

Entrepôt de données

Calendrier

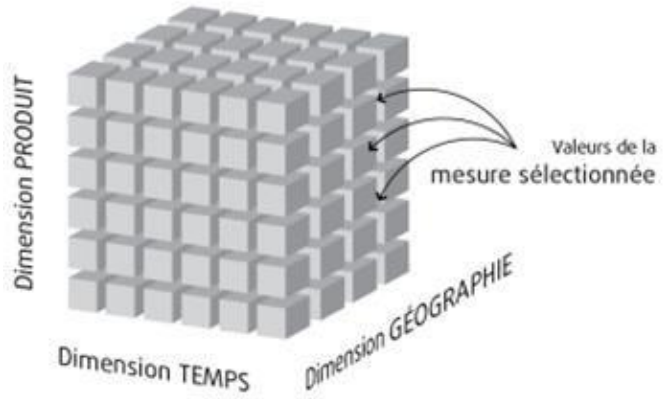
Code	Année	Mois
1	2015	Avril
2	2016	Janvier

Répertoire

Code	Nom	Ville
1	Karim	Tunis
1	Ahmed	Sfax
2	Karim	Sousse

Architecture des systèmes décisionnels

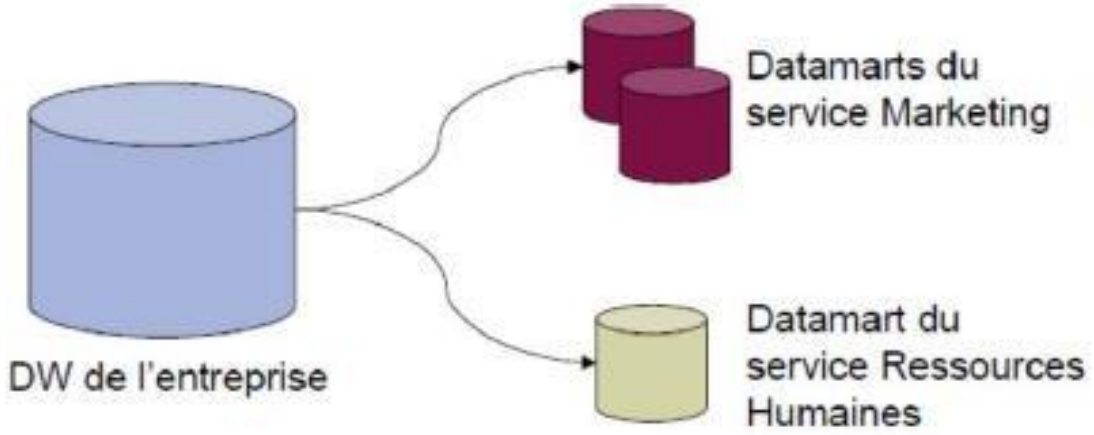
- ✓ Entrepôt de données (DataWarehouse)
  - Organisées pour le support d'un processus d'aide à la décision :
    - Les utilisateurs peuvent consulter les données réorganisées de façon multidimensionnelle à travers des outils d'aide à la manipulation et l'analyse.





Architecture des systèmes décisionnels

- ✓ Entrepôt de données (DataWarehouse)
  - ✓ Magasins des données (DataMarts)
    - Contiennent une portion du contenu de l'entrepôt de données;
    - Se concentrent sur un seul sujet d'analyse (ex: les ventes OU l'inventaire, mais pas les deux);
    - Servent à faire des analyses simples et spécialisées (ex: Suivi des ventes par catégorie de produits);

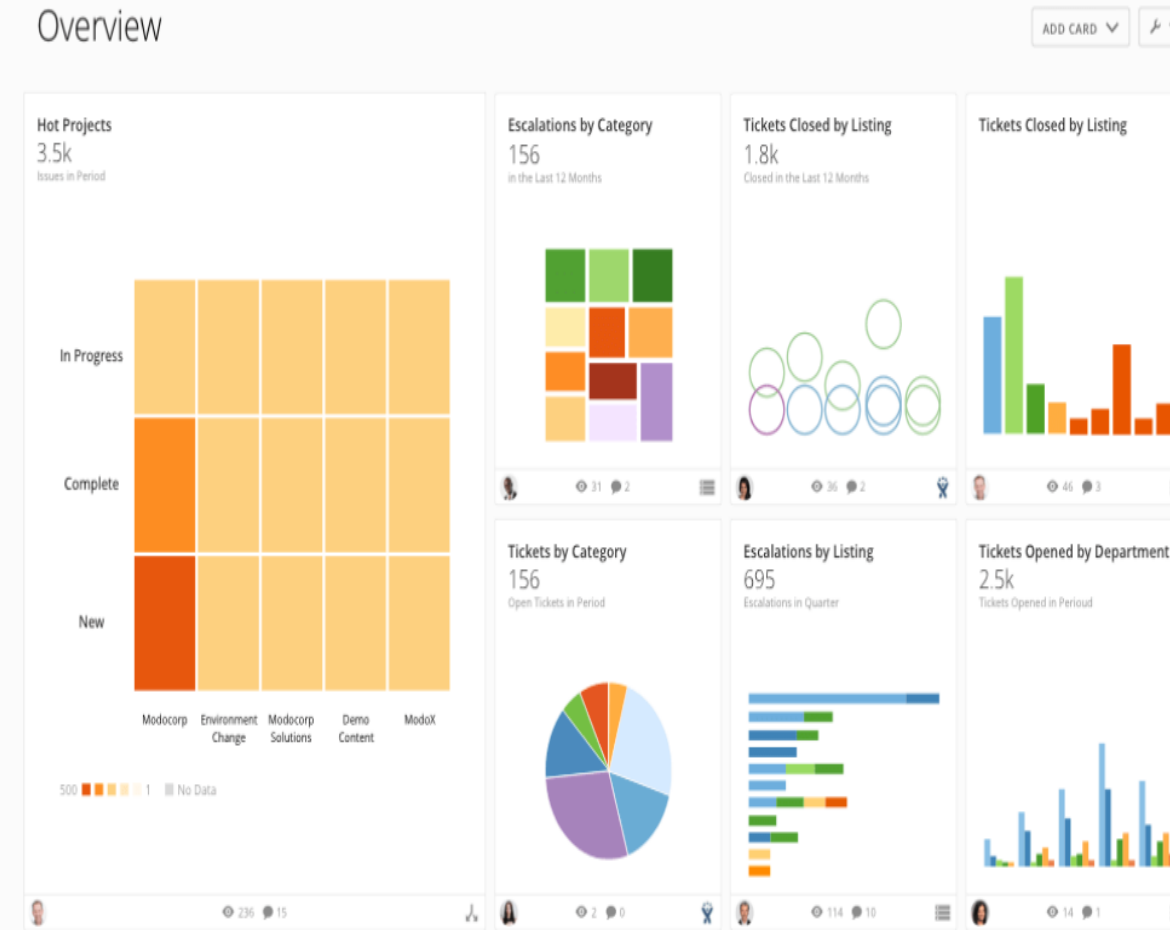


Architecture des systèmes décisionnels

- ✓ Entrepôt de données (DataWarehouse): Deux approches de conception
  - ✓ Approche descendante (top-down)
    - Conception intégrale de l'ED.
    - ED le dépôt centralisé de toutes les données
    - Les Data Marts des différents secteurs sont ensuite créés sur la base du modèle de l'entrepôt.
  - ✓ Approche Ascendantes (bottom-up)
    - Conception incrémentale de l'ED.
    - Le Data Warehouse est simplement une combinaison (union) de différents Data Marts qui facilite le reporting et l'analyse.

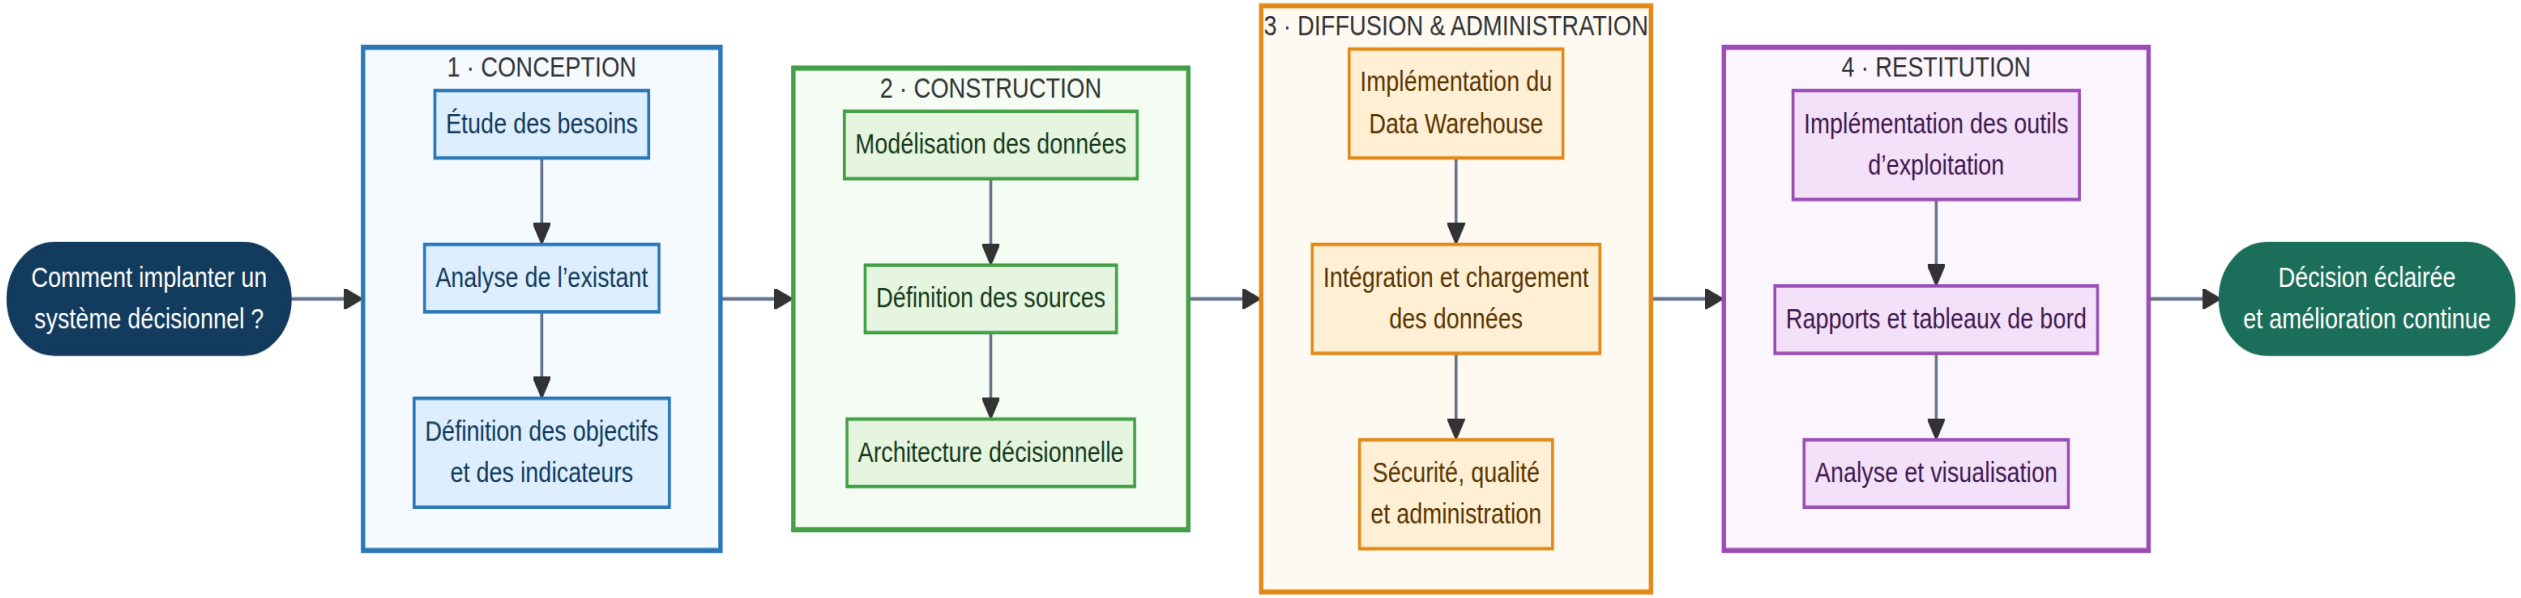
Architecture des systèmes décisionnels

- ✓ Les Outils d'analyse
  - La production de rapport récurrents (reporting)
    - Rapports, tableaux de bords, visualisation graphiques diverses, …
  - L'exploration manuelle
    - Analyse et l'exploration des données entreposées (OLAP)
  - L'analyse de données (descriptive ou prédictive)
    - Requêtes complexes pour analyse de tendance, découverte de connaissance, Fouille de données…



Comment implanter un système décisionnel

Comment implanter un Système décisionnel



Comment implanter un Système décisionnel

✓ Conception: Définir la finalité de l'ED

- Piloter quelle activité de l'entreprise ;
- Déterminer et recenser les données à entreposer ;
- Définir les aspects techniques de la réalisation ;
- Modèle de données ;
- Démarches d'alimentation ;
- Mode de restitution…

Comment implanter un Système décisionnel

✓ Construction: Travail technique

- Extraction des données des différentes BD de production (internes ou externes)
- Transformation des données: Nettoyage, filtrage…
- Techniques d'alimentation :
  - Chargement des données dans l'ED
  - Stockage des données dans les Eds et les magasins de données
  - Rafraîchissement

Comment implanter un Système décisionnel

- ✓ Diffusion et Administration: constituée de plusieurs tâches pour assurer :

  - La qualité et la pérennité des données aux différents applicatifs
  - La gestion des droits d'accès selon le profil métier de chacun
  - Interdire l'accès direct à l'ED
  - Segmenter les données collectées en contextes qui soient cohérents, simples à utiliser et qui correspondent à une activité décisionnelle particulière (par exemple aux besoins d'un service particulier).
  - Modéliser sous la forme d'un hypercube et à disposition via un outil OLAP.

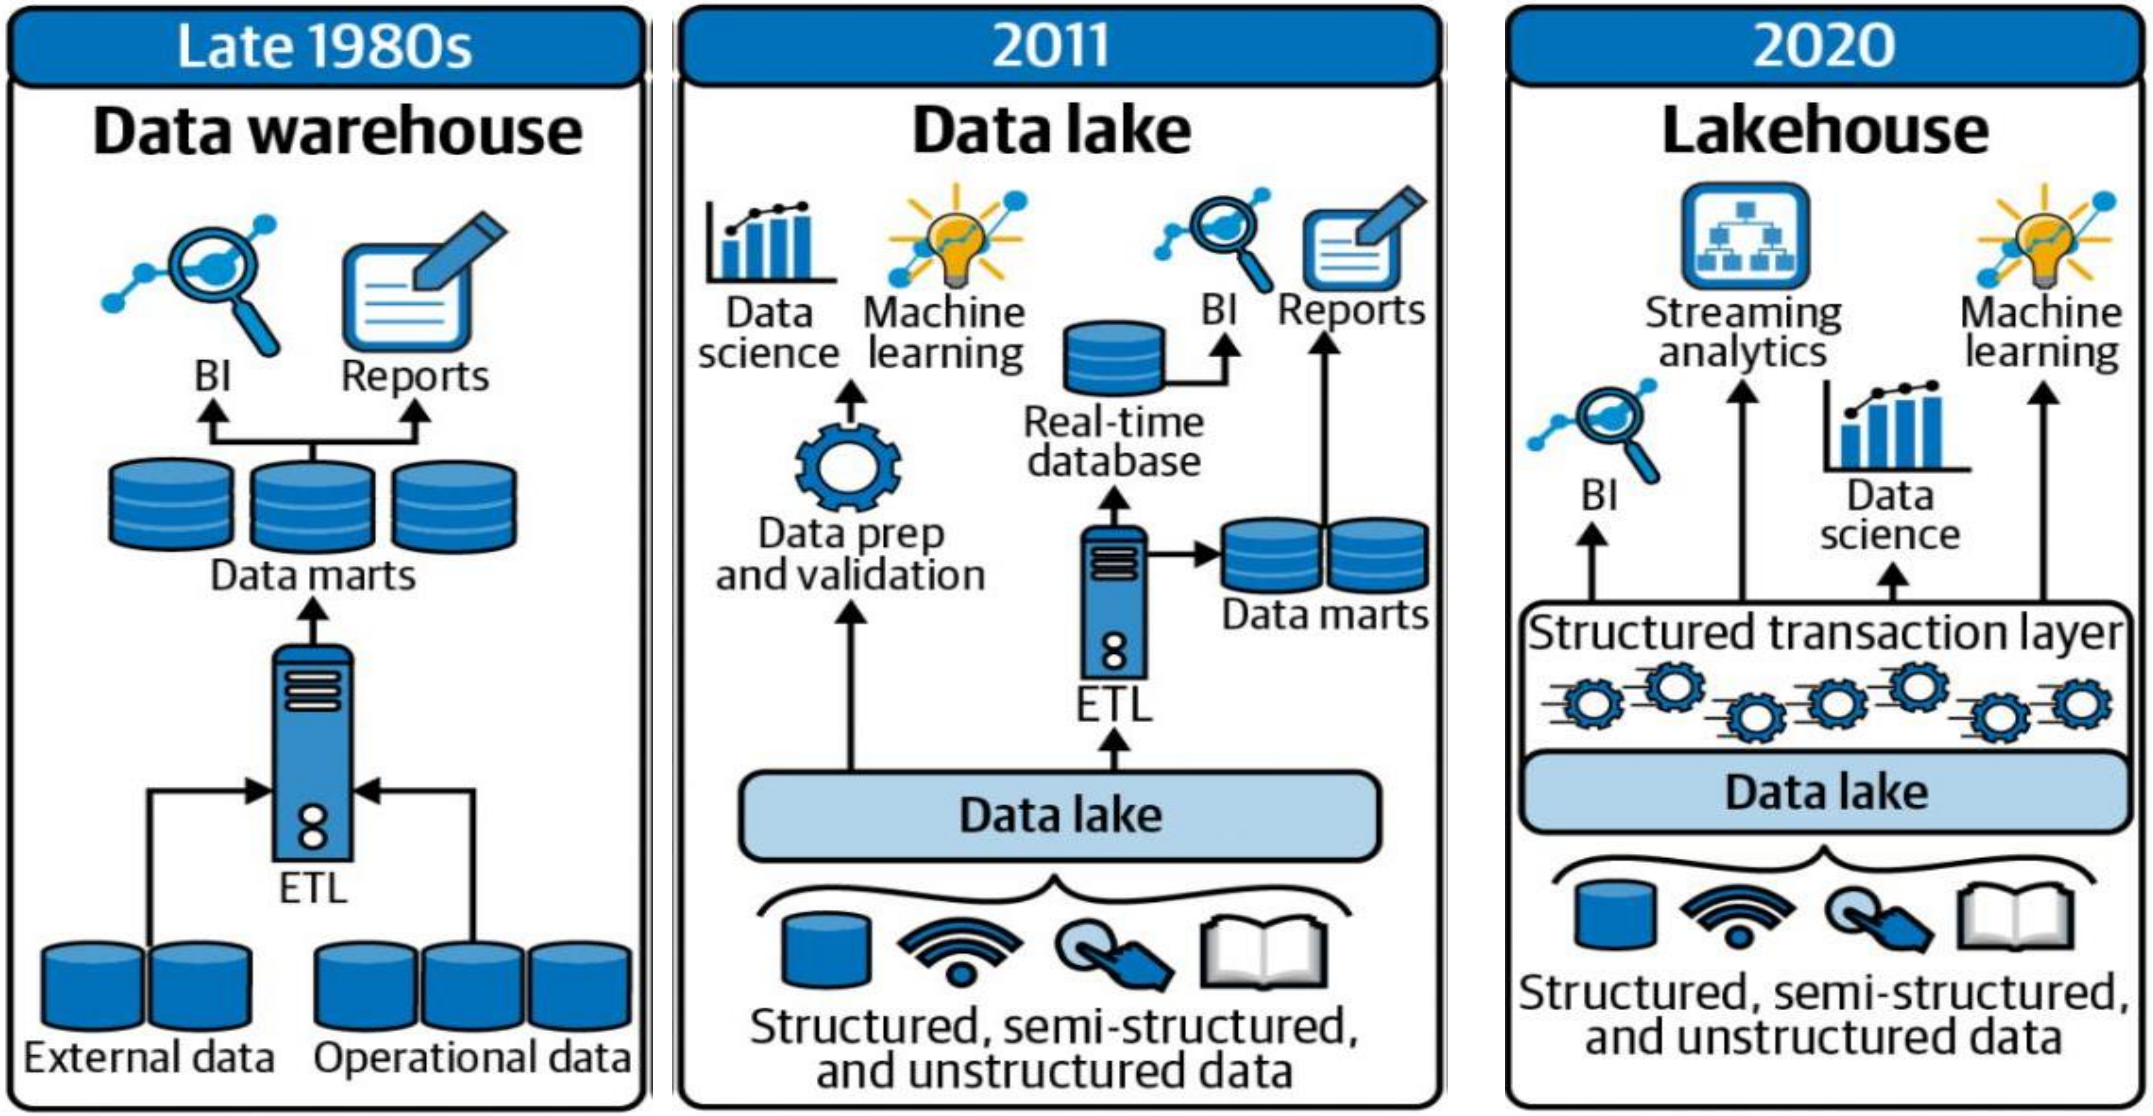
Comment implanter un Système décisionnel

✓ Restitution :

- C’est le but du processus d’entreposage des données.
- Reporting: présenter les informations de façon plus lisible dans le cadre d’aide à la décision.
- Les données sont principalement modélisées par des représentations à base de requêtes afin de constituer des tableaux de bord ou des rapports via des outils d'analyse décisionnelle.
- Des instruments de type tableau de bord équipés de fonctions d'analyses multidimensionnelles de type Olap sont aussi utilisés.

Evolution des entrepôts de données

Evolution des entrepôts de données



Evolution des entrepôts de données

- ✓ Data Lake
  - ✓ Émergence : avec l'essor du Big Data et l'apparition d'Hadoop en 2006.
  - ✓ Principe : stockage des données dans leur format d'origine, sans transformation préalable et sans schéma prédéfini (Schema-on-Read).
  - ✓ Un référentiel unique pour tous les types de données :
    - 📊 Structurées : bases de données relationnelles
    - 📄 Semi-structurées : CSV, JSON, XML, logs…
    - 🎥 Non structurées : e-mails, PDF, images, vidéos, fichiers audio…

Evolution des entrepôts de données

- ✓ Data Lake
  - ✓ Exploitation : les données sont préparées et analysées selon les besoins pour :
    - Analytics
    - Data Science
    - Intelligence Artificielle
    - Machine Learning

Data Lake = Stocker d'abord, structurer et exploiter ensuite.

Evolution des entrepôts de données

- ✓ Data Lake
  - ☺ Volume de stockage important : une solution idéale pour les entreprises qui génèrent des quantités importantes de données de toute sorte.
  - ☹ Intégration difficile : La nécessité de manipuler des données brutes peut rendre plus difficile l'intégration des données avec des outils de BI ou d'analyse.

Evolution des entrepôts de données

- ✓ Lake house
  - ✓ Principe : le Data Lakehouse combine les avantages du Data Warehouse et du Data Lake au sein d'une plateforme unifiée.

    → Pour la BI et le reporting : il permet d'exploiter efficacement les données structurées, comme dans un entrepôt de données.

    → Pour la Data Science et l'IA : il permet également de travailler sur des données brutes, volumineuses et hétérogènes, comme dans un Data Lake.

  - ✓ Une plateforme pour différents usages :

    📊 Business Intelligence & Reporting

    🔎 Data Analytics

    🧠 Machine Learning & IA

    🧪 Data Science

Evolution des entrepôts de données

- ✓ Lake house
  - ✓ Objectif : offrir une plateforme unique, flexible et performante répondant aux besoins d'utilisateurs ayant des profils et des compétences variés.

Data Lakehouse = Le meilleur du Data Warehouse et du Data Lake.

  - ✓ Stocke les données dans du stockage distribué (Amazon S3, Azure Blob Storage, Google Cloud Storage)
  - ✓ Allie la flexibilité d'un lac de données à la structuration d'un entrepôt de données, offrant ainsi une plateforme unifiée pour le stockage et l'analyse de divers types de données structurées et non structurées.
  - ✓ Lancé par Databricks , il est différent des autres solutions de cloud de données car c'est le Data Lake qui est au centre de tout, pas l'entrepôt de données.

Nouvelles tendances

Critère	Data Warehouse	Data Lake	Data Lakehouse
Génération	**1ère génération**	**2ème génération**	**3ème génération**
Période d'émergence	Années 1990	À partir de 2006	À partir de la fin des années 2010
Objectif	Analyse & Reporting	Stockage massif des données	Analyse + Stockage + IA
Types de données	Structurées	Structurées, semi-structurées & non structurées	Tous types
État des données	Nettoyées & transformées	Brutes, non transformées	Brutes + transformées
Schéma	**Schema-on-Write**	**Schema-on-Read**	**Flexible**
Technologies / traitements	ETL, OLAP, SQL	Big Data, ELT	SQL, ELT, Big Data, ML
BI & Reporting	★★★★★	★★	★★★★★
Data Science & ML	★★	★★★★★	★★★★★
Flexibilité	★★	★★★★★	★★★★★
Utilisateurs principaux	Analystes BI, décideurs	Data Engineers, Data Scientists	Analystes, Data Engineers, Data Scientists & équipes IA
Limite principale	Peu adapté aux données hétérogènes	Risque de **Data Swamp**	Architecture plus complexe

Bibliographie

- Entrepôts de données: guide pratique de modélisation dimensionnelle. Kimball, Ralph, and Margy Ross. Vuibert informatique, 2003.
- Concevoir et déployer un data warehouse. Kimball, R., Reeves, L., Ross, M., & Thornthwaite, W, Eyrolles (2000).
- https://learn.microsoft.com/en-us/sql/?view=sql-server-ver16