IIT
INSTITUT INTERNATIONAL TECHNOLOGIE
Université Nord Américaine Privée

Cours Entrepôt de données

Dr. Salma DAMMAK & Dr. Taher LAABIDI

2ème année GLID & SDIA

damak.salma@iit.ens.tn & taher.laabidi@iit.ens.tn

Chapitre2

Modélisation multidimensionnelle

Objectif du cours

- Découvrir le modèle multidimensionnel et ses différents nouveaux concepts
- Maitriser la modélisation multidimensionnelle
- Avoir une idée sur les différents schémas multidimensionnels

Contenu

1) **Modélisation des EDs**

2) **Les concepts de base**

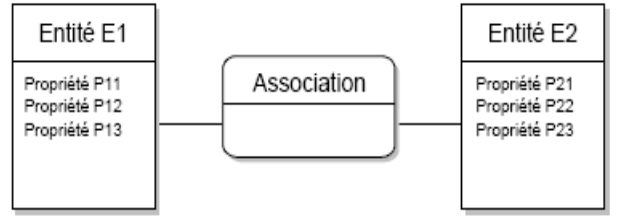
3) **Les schémas multidimensionnels**

4) **La modélisation logique**

1) Modélisation des EDs

Modélisation des EDs

- **Modélisation entité-association: adapté aux systèmes OLTP**



  - Représenter les données d'un système opérationnel de manière **structurée et cohérente**.
  - **Réduire la redondance des données** et à garantir leur **intégrité**.
  - Données réparties entre plusieurs **entités liées entre elles** par des associations.
  - Adapté au **traitement transactionnel (OLTP)**, où l'objectif principal est de **gérer les opérations quotidiennes** : ajout, modification et suppression de données.

Modélisation des EDs

- ✓ Un élément fondamental dans la démarche de spécification d'un système d'information.
- ✓ Les données doivent être organisées d'une manière qui soit à la fois conforme au point de vue de l'utilisateur et compatible avec les contraintes techniques de mise en œuvre.

Modélisation entité-relation??????

Modélisation des EDs

- ✓ Pour DW, l'objectif n'est plus principalement de gérer les transactions quotidiennes, mais de **faciliter l'analyse et la prise de décision**.
  - ✓ Quel est le **chiffre d'affaires** réalisé par mois ?
  - ✓ Quel produit génère le **plus de ventes** ?
  - ✓ Quelle est l'évolution des ventes **par région et par période** ?
  - ✓ Quelle est la quantité totale vendue pour chaque catégorie de produits ?

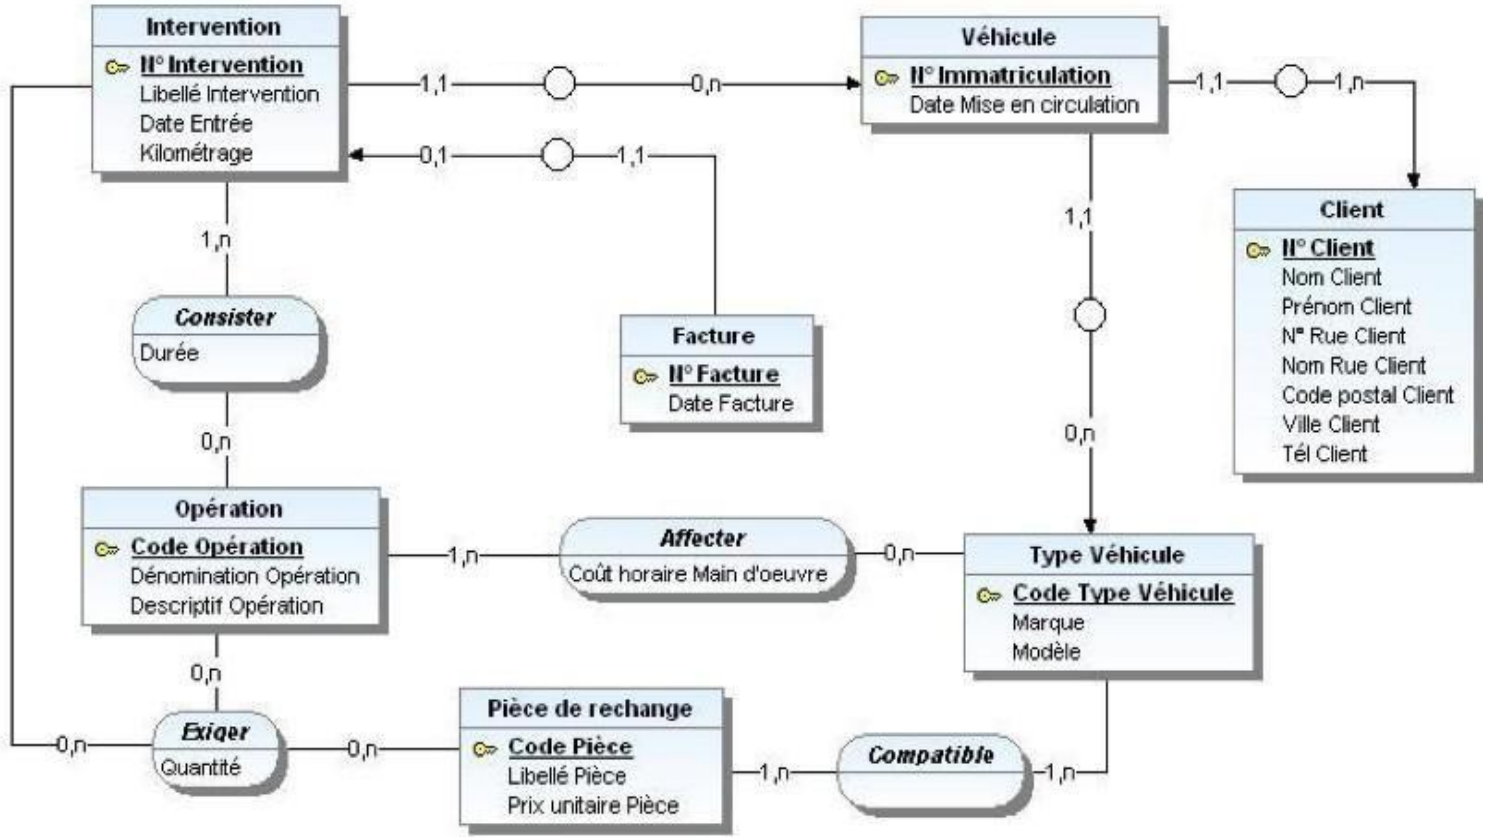
☹ le modèle Entité-Association, conçu pour l'OLTP, peut devenir **complexe et moins adapté aux analyses multidimensionnelles**.

Modélisation des EDs

- ✓ Modélisation E/R



Exemple : Application d'administration de réparation



Modélisation des EDs

✓ Modélisation E/R

- Avantages du modélisation E/R:

☺ Normalisation : Eliminer les redondances, Préserver la cohérence des données

☺ Optimisation des transactions

☺ Réduction de l'espace de stockage

- Limites du modèle ER:

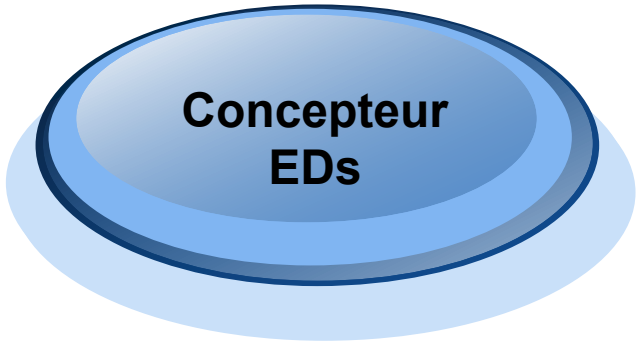
☹ Schéma trop complet: plusieurs tables.

☹ Données historiques difficilement représentées.

☹ Inadapté pour l'analyse.

Modélisation des EDs

- ✓ Modélisation E/R



Stocker les données des systèmes d'information



Rendre les données accessibles pour une prise de décision facile

→ Besoin d'une modélisation spécifique aux Entrepôts des données

Modélisation des EDs

✓ Cette modélisation doit être:

☺ Compréhensible :

- Les données sont regroupées selon des catégories d'affaires

☺ Performante

- Offre un modèle dimensionnel qui est le résultat :
  - d'une analyse des besoins : **ce que je souhaite étudier**.
  - d'une analyse des données disponibles : **ce que je peux étudier.**

Modélisation des EDs

✓ Une modélisation multidimensionnelle

- Une modélisation orientée vers l'analyse et les besoins du décideur.
- Organise les données selon des sujets d'analyse correspondant aux principaux centres d'intérêt décisionnels.
- Permet d'examiner un même sujet selon plusieurs axes d'analyse : temps, produit, client, région, etc.
- Représente les données comme des points dans un espace multidimensionnel, chaque dimension correspondant à un axe d'analyse.
- Offre des accès rapides et performants aux données, facilitant ainsi le reporting et la prise de décision.

👉 Exemple : analyser les ventes selon plusieurs dimensions : Temps × Produit × Client × Région.

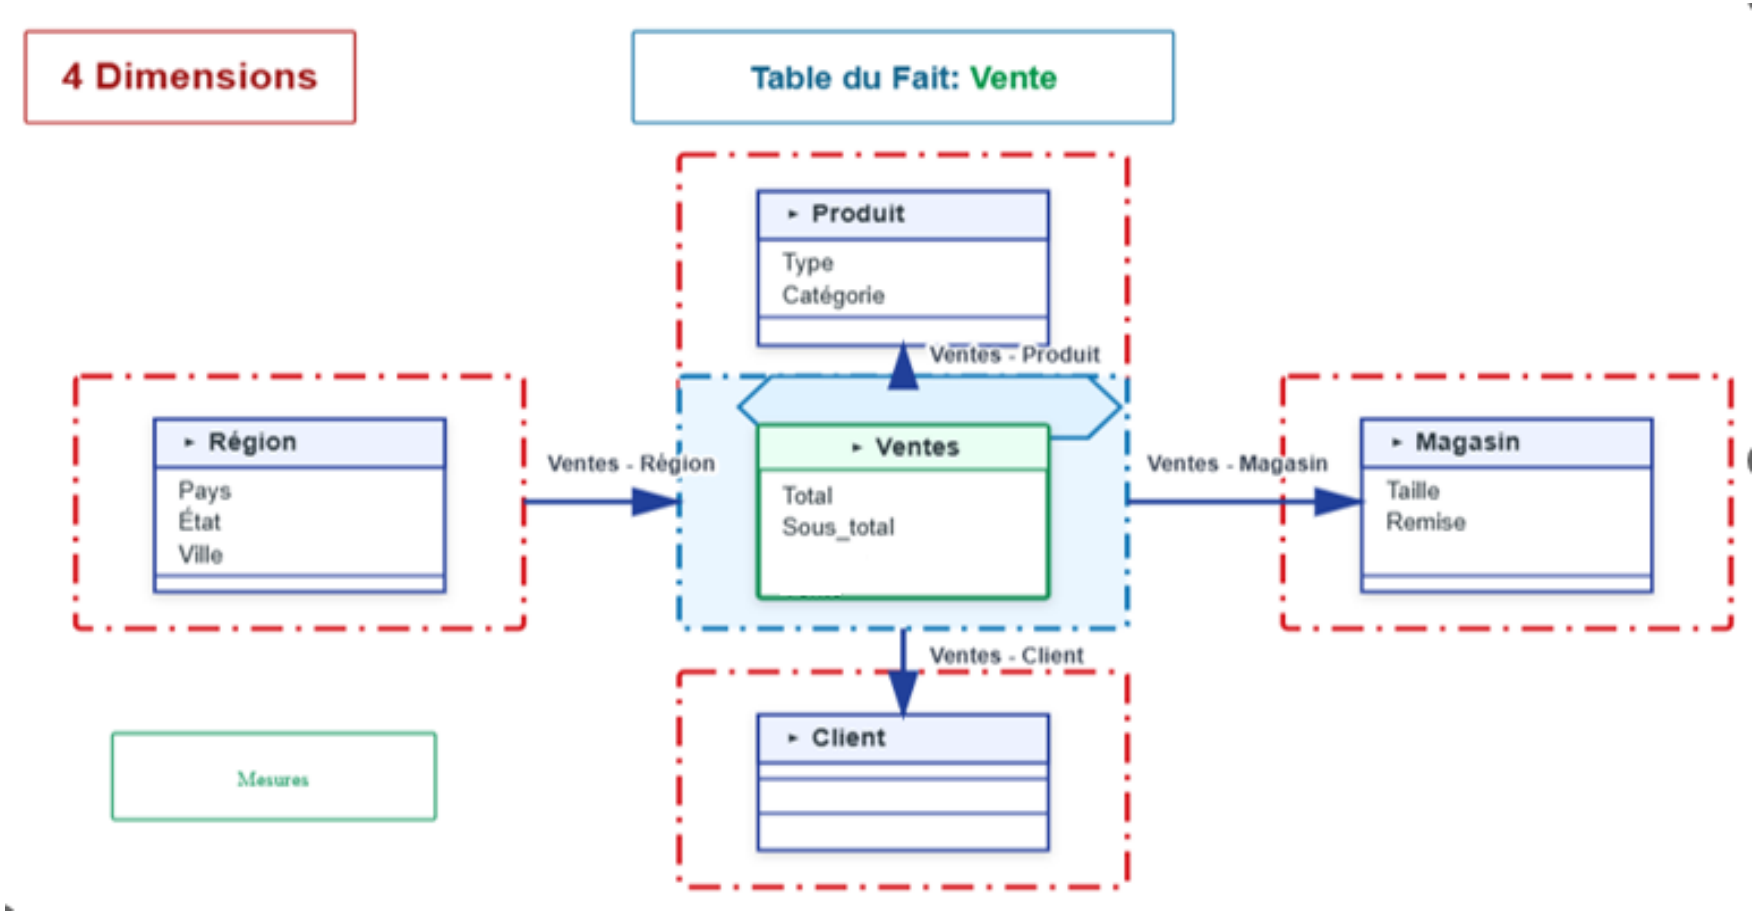
Modélisation des EDs

- ✓ Définition d'un modèle multidimensionnel
  - Le modèle multidimensionnel consiste à considérer un sujet d'analyse comme un point dans un espace à plusieurs dimensions
  - Les données sont organisées de manière à mettre en évidence le sujet d'analyse, les dimensions et les perspectives d'analyses.
  - La modélisation multidimensionnelle a donné naissance aux concepts de fait *et de* dimension

2) Les concepts de base

Les concepts de base

- ✓ Modèle multidimensionnel



Les concepts de base

- ✓ Les concepts d’un modèle multidimensionnel
  - Fait: Sujet d’analyse
  - Mesure: indicateur d’analyse
  - Dimension: axes d’analyse
  - Hiérarchie: perspective d’analyse

Les concepts de base

✓ Table de Fait

✓ Le **sujet principal que l'on souhaite analyser** dans un Data Warehouse.

👉 Elle répond à la question : **« Qu'est-ce que je veux mesurer ou analyser ? »**

Exemples :

Ventes → analyser les quantités vendues, les montants et le chiffre d'affaires.

Stocks → analyser les quantités disponibles et les niveaux de stock.

Commandes → analyser le nombre de commandes, leur montant, leur quantité, etc.

👉 **En résumé :**

Table de faits = Événements à analyser + Dimensions d'analyse + Mesures quantitatives

Les concepts de base

- ✓ Mesure
  - ✓ Représente une **valeur numérique** qui permet de **quantifier l'activité étudiée** dans une table de faits.

👉 Elle répond à la question : **« Quelle valeur souhaite-t-on mesurer ? »**

- ✓ Généralement d'une **valeur numérique** associée à un événement ou une activité.
- ✓ **Agrégée** afin de produire des indicateurs utiles à l'analyse.
  - ✓ Son agrégation dépend des **axes d'analyse (dimensions)** : temps, produit, client, région, etc
  - ✓ Les principales fonctions d'agrégation sont :
    - **SUM** → calculer un total
    - **AVG** → calculer une moyenne
    - **MIN / MAX** → rechercher une valeur minimale ou maximale
    - **COUNT** → compter le nombre d'occurrences

Les concepts de base

✓ Mesure

- **Additivité :** additionnable suivant toutes les dimensions

  Exemple : CA ; Quantité vendue, coût, …

- **Semi-additivité :** additionnable suivant certaines dimensions

  Exemple : « solde de compte » est agrégeable selon la dimension «Client », mais pas selon la dimension « Temps »

- **Non-additivité :** non additionnable quelque soit la dimension

  Exemple : plus grand CA pour l'ensemble des magasins

Les concepts de base

✓ Dimension

- Une **dimension** représente un **axe d'analyse** selon lequel les données de la table de faits vont être étudiées.

👉 Elle répond à la question : **« Selon quel critère souhaite-t-on analyser les mesures ?»**

Client → analyser les ventes selon le client.

Produit → analyser les ventes selon le produit.

Temps → analyser l'évolution des ventes par jour, mois, trimestre ou année.

Les concepts de base

- ✓ Dimension
  - **Que contient une dimension ?**
    - **Clé primaire unique** permettant d'identifier chaque élément de la dimension.
      - Utilisée dans la **table de faits comme clé étrangère** pour établir le lien entre les faits et les axes d'analyse.
    - **Attributs descriptifs** permettant de détailler l'analyse.

      Exemple – Dimension Produit :

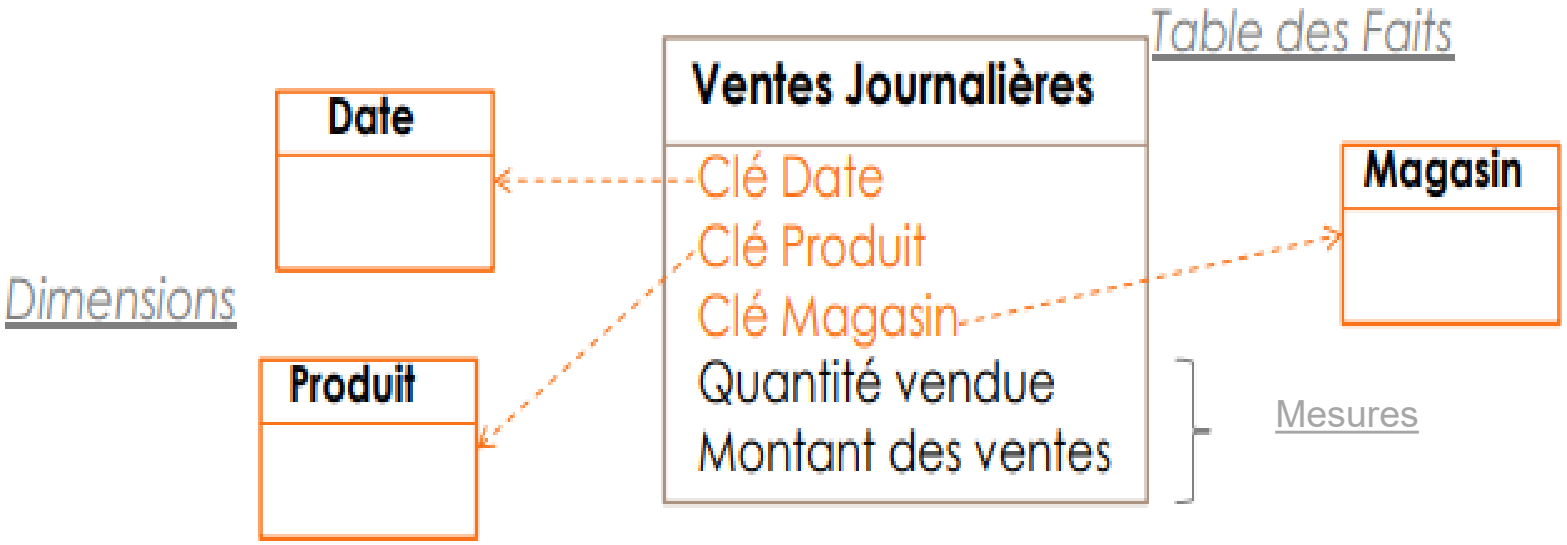
      id_Produit → clé primaire; Nom_Produit → attribut; Catégorie → attribut; Marque → attribut

      👉 **En résumé :**

      Dimension = Axe d'analyse + Attributs descriptifs + Clé d'identification

Les concepts de base

- ✓ Dimension
  - Exemple



Les concepts de base

✓ Hiérarchie

- Un **niveau d'analyse** représente une **perspective ou un degré de détail** selon lequel une dimension peut être étudiée.

  👉 Il permet de passer d'une analyse **détaillée** à une analyse **plus globale**.

  Exemple – Dimension Temps :

  Jour → Mois → Trimestre → Semestre → Année

- On peut ainsi analyser le chiffre d'affaires :

  par jour pour une analyse détaillée ;

  par mois pour suivre l'évolution mensuelle ;

  par trimestre ou semestre pour une vision intermédiaire ;

  par année pour une vision globale.

Les concepts de base

- ✓ Hiérarchie
  - ✓ Une **dimension** est constituée d'un ensemble de **membres** (valeurs) qui peuvent être organisés selon **une ou plusieurs hiérarchies**.



👉 **En résumé :**

Dimension = ensemble de membres organisés éventuellement selon une ou plusieurs hiérarchies permettant différents niveaux d'analyse.

Les concepts de base

✓ Hiérarchie

- Un **paramètre**
  - **Attribut d'une dimension** qui permet de définir un **niveau de détail pour l'analyse**.

  👉 Il répond à la question : **« À quel niveau de détail souhaite-t-on analyser les mesures ? »**

  Exemple – Dimension Temps :

  Année → Semestre → Trimestre → Mois → Jour

  - Chaque élément constitue un **niveau d'analyse (paramètre)** permettant d'étudier les mesures à un niveau de détail différent.

Les concepts de base

✓ Hiérarchie

- **Attribut faible**
  - Une information **descriptive associée à un paramètre**.
  - Apporte des informations complémentaires sur le paramètre.
    - Un **rôle informatif** et facilite la compréhension et l'interprétation des données.
    - **Pas utilisé pour effectuer les regroupements ou les agrégations**.

      Exemple – Dimension Agence :
      Code_Ag → Paramètre permettant d'identifier l'agence
      Nom_Agence → Attribut faible apportant une information descriptive

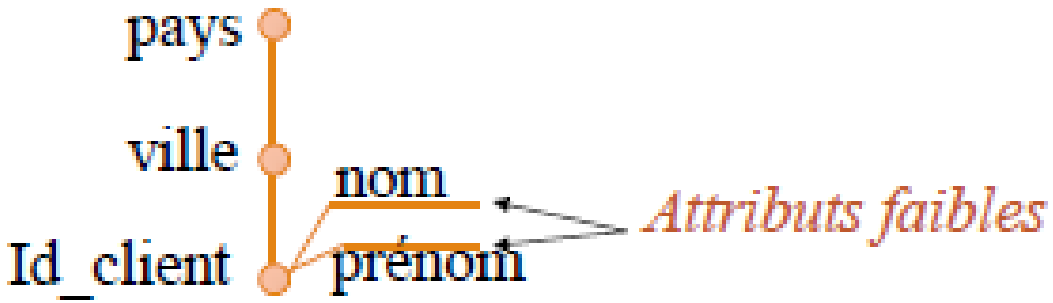
👉 **En résumé :**

Paramètre = niveau d'analyse

Attribut faible = information descriptive complémentaire

Les concepts de base

- ✓ Hiérarchie
  - Exemple



Les concepts de base

✓ Hiérarchie

- plusieurs **niveaux d'analyse**, chacun correspondant à un degré de détail.
- Reliés entre eux par des **relations hiérarchiques**, permettant de passer d'un niveau détaillé à un niveau plus général.
- Certaines hiérarchies sont **naturelles et connues**.

  Exemple – Dimension Temps :

  Jour → Mois → Année
- D'autres hiérarchies doivent être identifiées à partir des **besoins métier et du vocabulaire utilisé par les utilisateurs**.

  Exemple – Dimension Produit :

  Id-Produit → Gamme → Marque

Les concepts de base

✓ Hiérarchie

- **Le grain d'une dimension**
  - **niveau d'analyse le plus fin** auquel les données peuvent être sélectionnées dans une dimension.
  - le **niveau de détail maximal** qu'il est possible d'obtenir lors d'une analyse.
  - Plus le grain est fin, plus l'analyse permet d'obtenir des informations **détaillées et précises**.

Exemple :

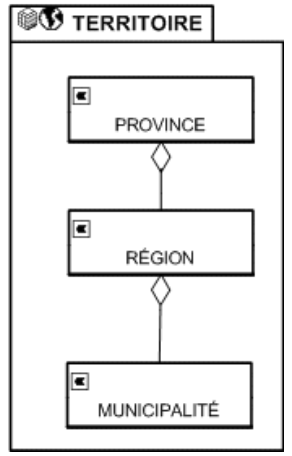
Si le grain de la dimension Temps est le **jour**, il est possible d'analyser les ventes jour par jour, puis de les regrouper par mois ou par année.

👉 **À retenir :**

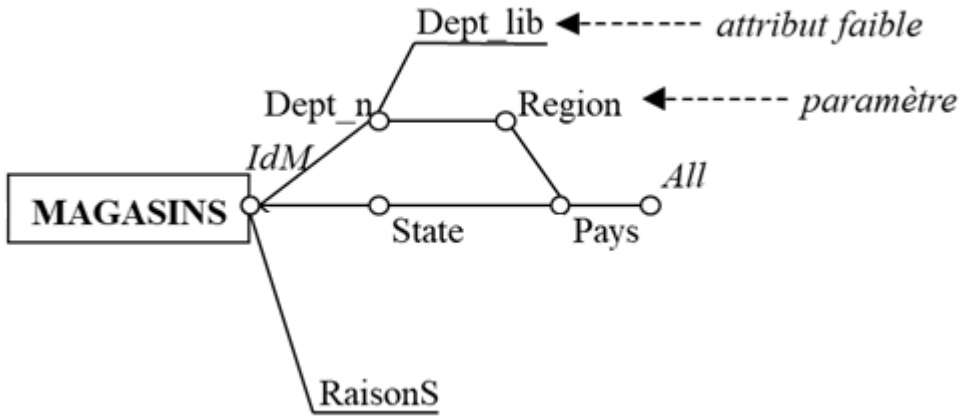
Grain = niveau de détail le plus fin disponible pour l'analyse.

Les concepts de base

- ✓ Hiérarchie
  - Type d'hiérarchie:
    - **Simple:** présente une relation 1-N entre les membres. L'enfant a un seul parent.
      - C'est une hiérarchie à 3 niveau.



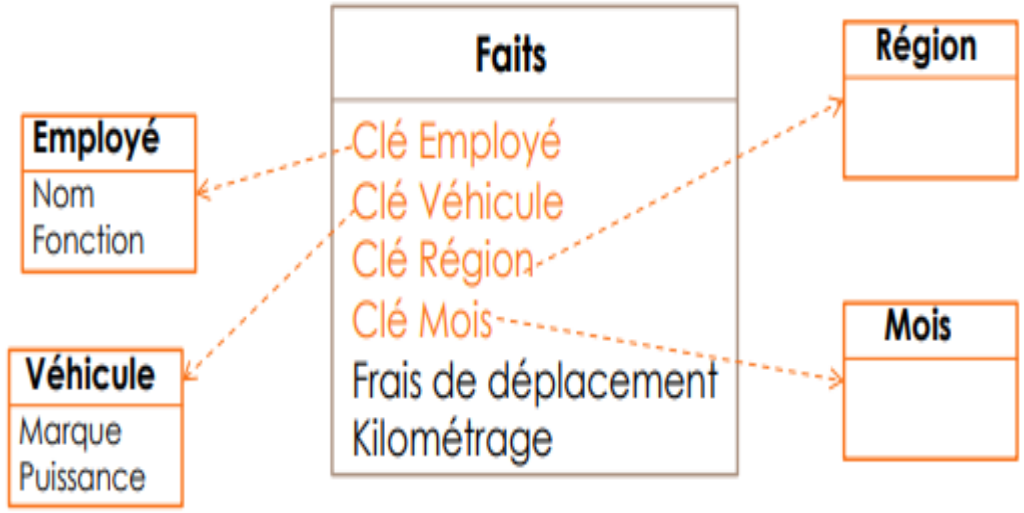
    - **Multiple** : partage plusieurs niveaux d'une dimension.



Les concepts de base

- ✓ Exemple 1:
  - ✓ Requête: Quels sont les frais de déplacement et le kilométrage des commerciaux de la région nord ayant des véhicules de 10 à 14 CV en avril 2004?

- **Fait:** Gestion des déplacement
- **Mesure:** Frais de déplacement et Kilométrage
- **Dimension:**
  - Par Employé (fonction)
  - Par Région
  - Par Véhicule (puissance)
  - Par Date (Mois)



Les concepts de base

- ✓ Exemple 2:
  - ✓ Requête: Quelles ont été les marges sur les ventes du produit ‘P023’ pour le client Ben Salah Ahmed à Hammamet durant le mois de Janvier?
  - **Fait:** Vente
  - **Mesure:** Marge
  - **Dimension:**
    - Par Produit
    - Par Client
    - Par Ville
    - Par Date (Mois)

Les concepts de base

- ✓ Exemple 3:
  - ✓ Requête: Quels ont été les revenus sur les achats de la marque ‘Teams’ en Tunisie durant l’année 2011?
  - **Fait:** Achats
  - **Mesure:** Revenus
  - **Dimension:**
    - Par Marque de produit
    - Par Pays
    - Par Date (Année)

Les concepts de base

- ✓ Exemple 4:
  - ✓ Requête: Quel est le nombre de consultation des orthopédistes durant le Trimestre 3 pour les cliniques de sfax ?

- **Fait:** Consultation
- **Mesure: Nombre**
- **Dimension:**
  - Par spécialité de médecins
  - Par Date (trimestre)
  - Par ville clinique

Les concepts de base

- ✓ Exemple 5:
  - ✓ Requête: Quels ont été les quantités vendues de la gamme ‘G006’ durant le Trimestre 2 pour la région du nord ?

- **Fait:** Vente
- **Mesure:** Quantité
- **Dimension:**
  - Par Gamme
  - Par Trimestre
  - Par Région

4) Les Schémas multidimensionnels

Les schémas multidimensionnels

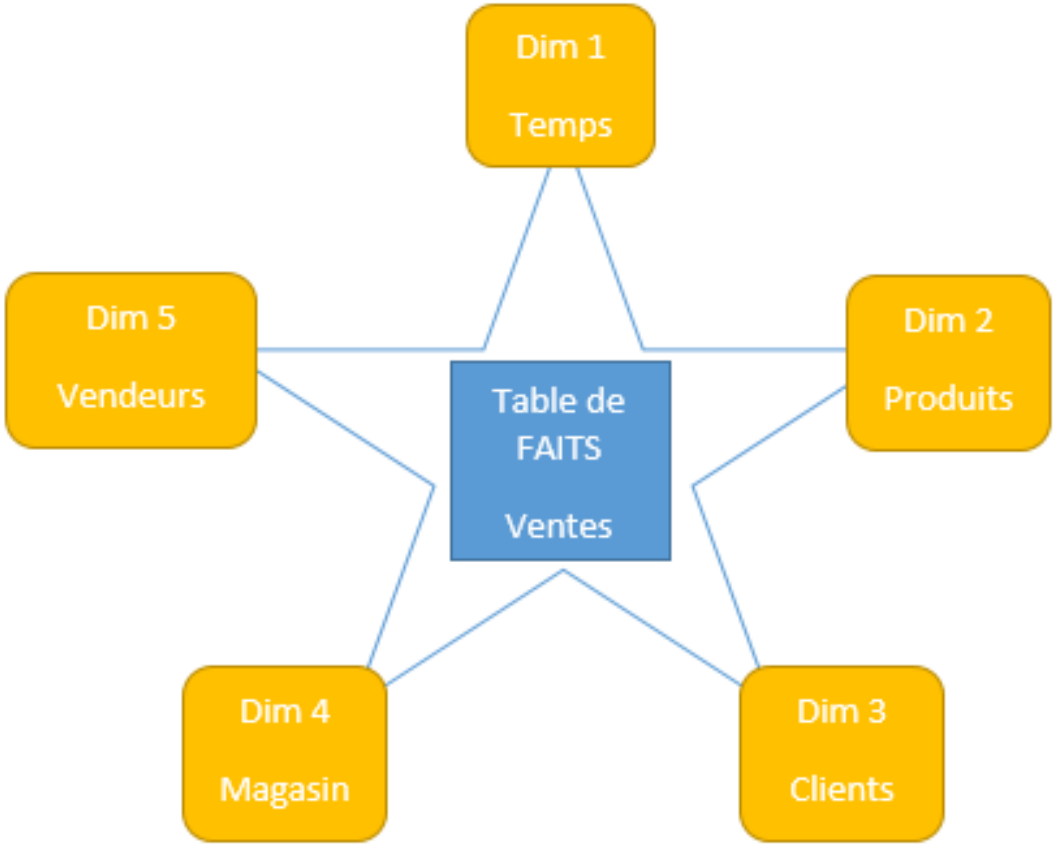
- ✓ Schéma en étoile
- ✓ Schéma en flocon de neige
- ✓ Schéma en constellation

Les schémas multidimensionnels

- ✓ **Schéma en étoile**
  - 1 sujet d'analyse (Table de Fait) comportant un ou plusieurs indicateurs (mesures)
  - n axes d'analyse (Dimensions), comportant les descripteurs des dimensions (paramètres)
    - Les dimensions n'ont pas de liaison entre elles
  - m perspectives d'analyse (Hiérarchies) organisant les paramètres en différentes granularités

Les schémas multidimensionnels

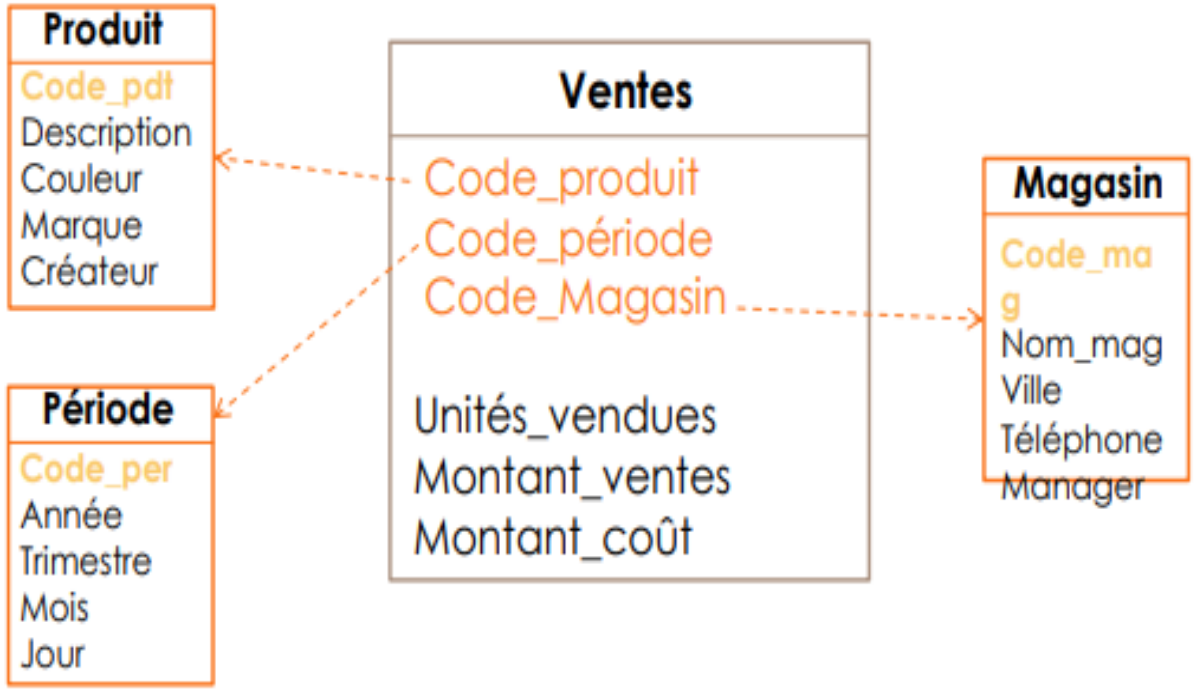
- ✓ **Schéma en étoile**



Les schémas multidimensionnels

✓ Schéma en étoile

- Exemple : « *Analyse des ventes en fonction du temps, de produits et de magasins* »



Les schémas multidimensionnels

✓ **Schéma en étoile**

☺ Facilité de navigation

☺ Performances : nombre de jointures limité ;

☺ Gestion des agrégats

☹ Redondances dans les dimensions.

☹ Alimentation complexe.

Les schémas multidimensionnels

✓ Schéma en étoile

Exercice 1:

Soit une agence de voyage (voyage aérien) qui voulait construire un entrepôt de données en utilisant le modèle en étoile. Construire le modèle en étoile de cet entrepôt sachant que : Le modèle résultat doit répondre à la requête suivante :

Quel est le chiffre d'affaires (CA) par client, par date de voyage (et par mois, trimestre et année), par compagnie aérienne et par ville de destination.

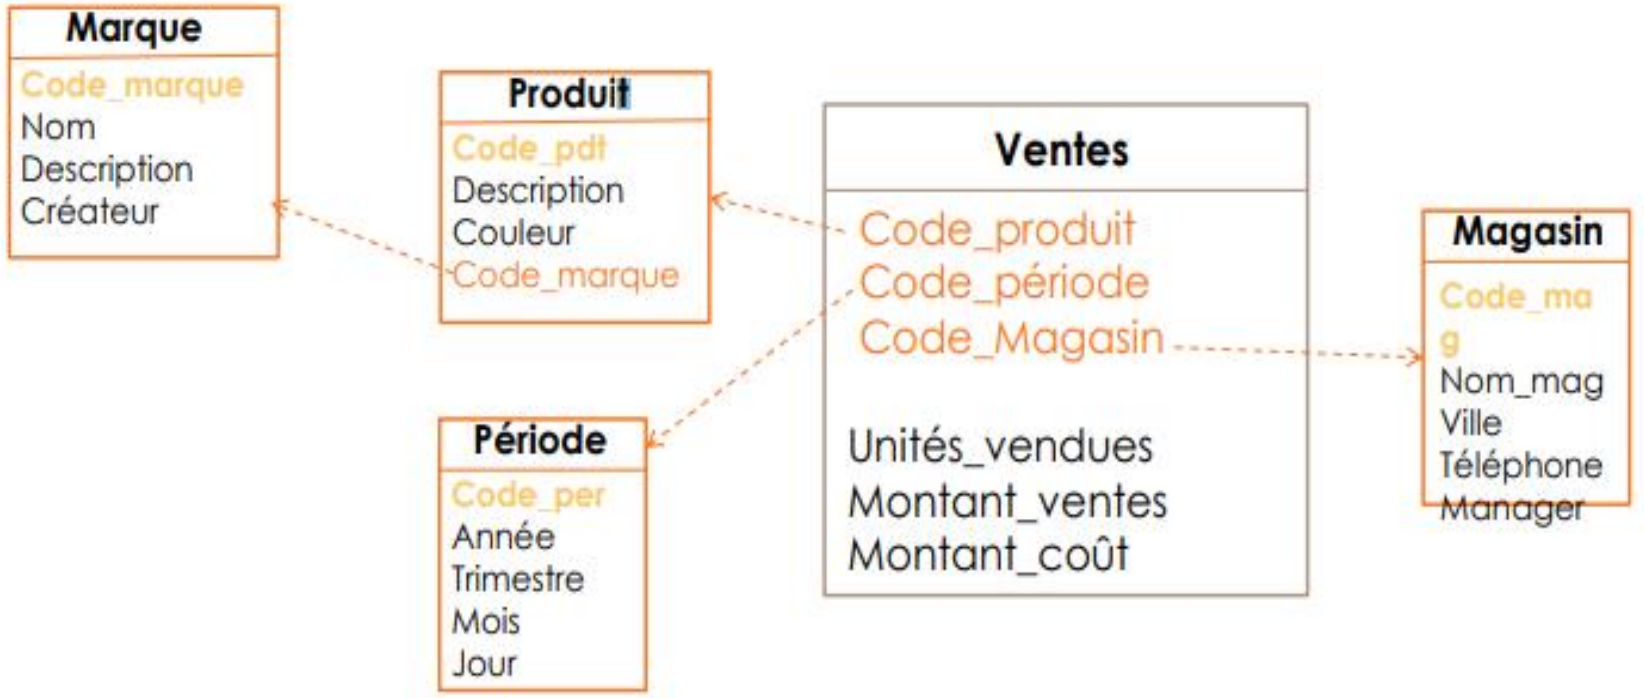
Donner le schéma en étoile convenable.

Les schémas multidimensionnels

- ✓ **Schéma en flocon de neige**
  - = Modèle en étoile + normalisation des dimensions
  - Utilisé lorsque les tables sont très volumineuses
  - La table des faits reste inchangée
  - Chacune des dimensions est décomposée selon sa (ou ses) hiérarchie(s)
  - Exemple : Région, Pays, Continent

Les schémas multidimensionnels

- ✓ **Schéma en flocon de neige**
  - Exemple



Les schémas multidimensionnels

✓ **Schéma en flocon de neige**

☺ Réduction du volume

☺ Permettre des analyses par pallier (drill down) sur la dimension hiérarchisée

☹ Navigation difficile

☹ Nombreuses jointures

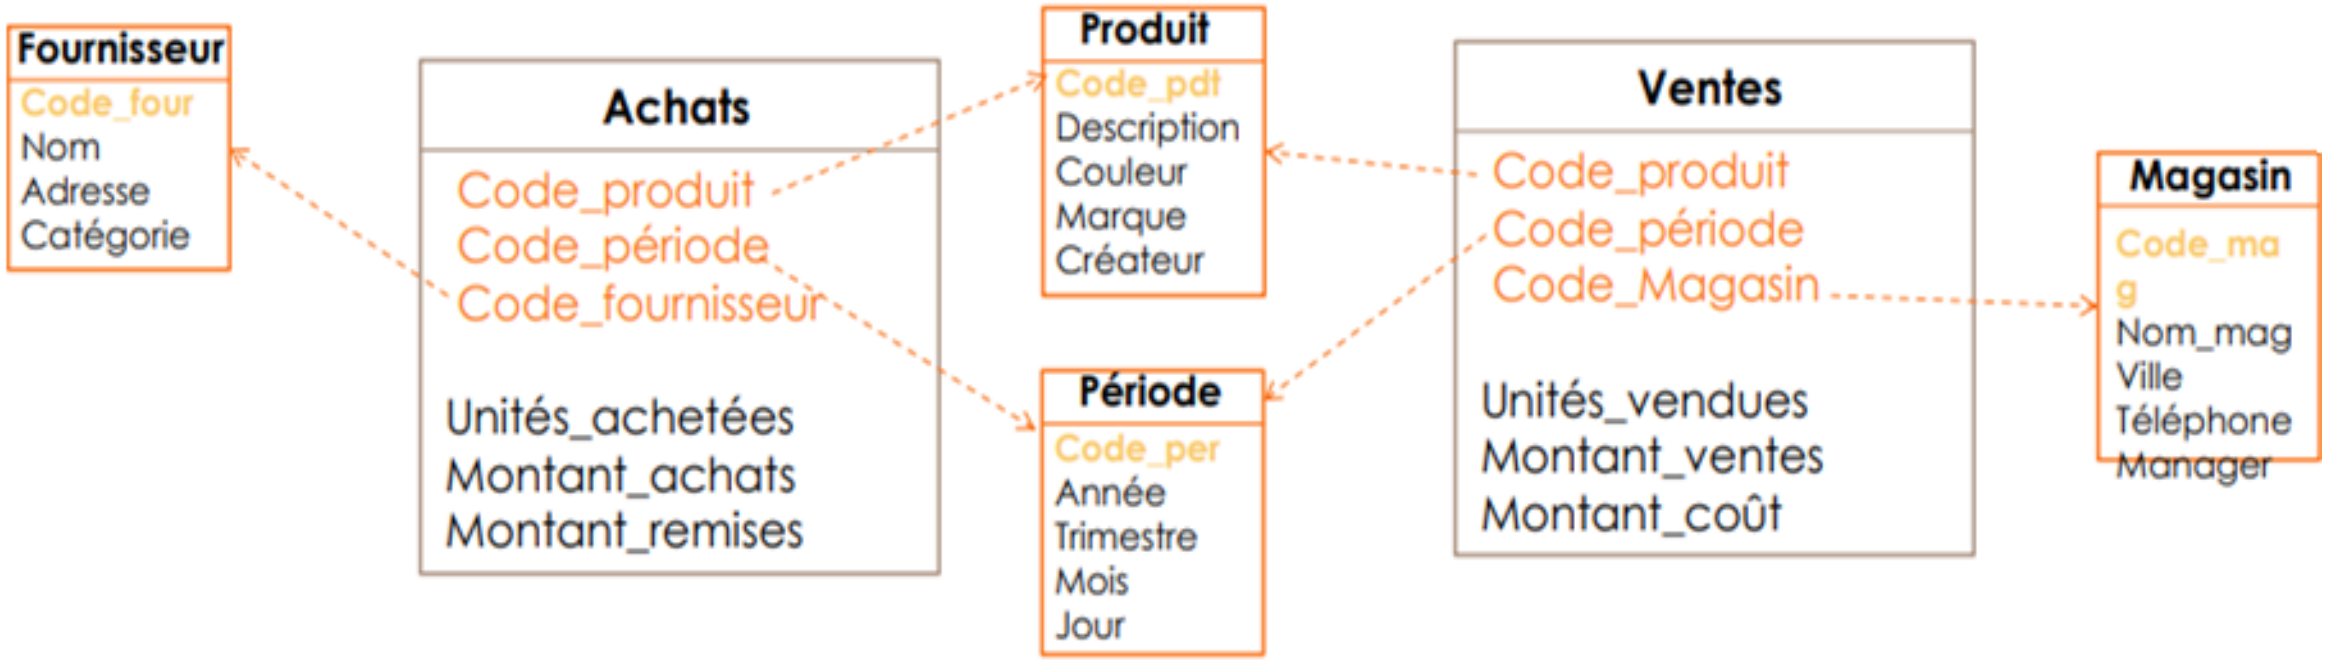
Les schémas multidimensionnels

✓ Schéma en constellation

- Fusionner plusieurs modèles en étoile qui utilisent des dimensions communes
- Un modèle en constellation comprend donc :
  - Plusieurs tables de faits
  - Des tables de dimensions communes ou non à ces tables de faits.

Les schémas multidimensionnels

- ✓ **Schéma en constellation**



Les schémas multidimensionnels

- ✓ **Schéma en constellation**

  - ☺ Facilite les corrélations entre les différents sujets d'analyse.
  - ☺ Simplifie la modélisation avec la possibilité de partager les dimensions.

Les schémas multidimensionnels

✓ Schéma en constellation

- Un modèle en constellation constitué de deux modèles en étoile
  - Modèle en étoile 1: fait *Location des véhicules*

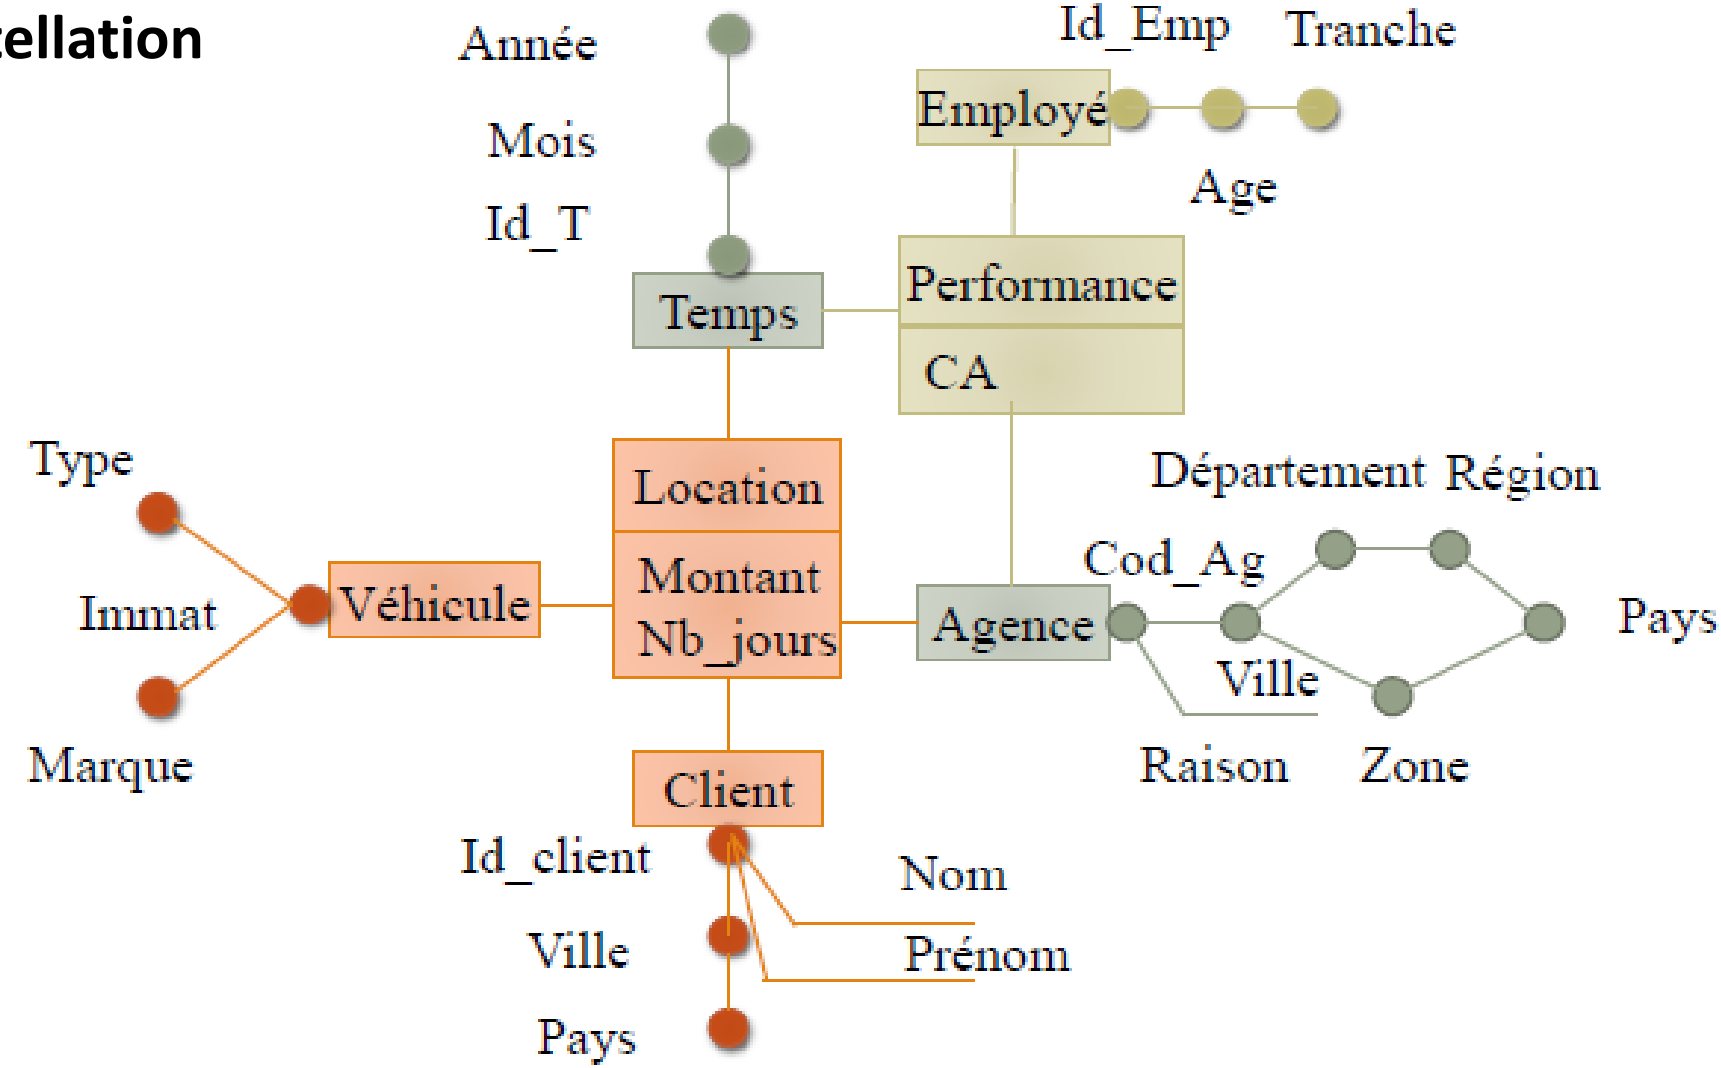
    Montant et nombre de jour par temps, véhicule, agence et client
  - Modèle en étoile 2 : fait *Performance des employés*

    Chiffre d'affaire par temps, employé et agence

=> Les deux modèles partagent les deux dimensions ***Temps et Agence***

Les schémas multidimensionnels

- ✓ **Schéma en constellation**



Les schémas multidimensionnels

✓ Exercice 2

Une entreprise souhaite analyser la somme des dépenses et la moyenne des quantités en matières premières achetées par produit, par fournisseur, par atelier, et par mois.

1) Déterminer le (ou les) sujet d'analyse
2) Déterminer le (ou les) indicateur(s) d'analyse.
3) Déterminer les axes d'analyse
4) Présenter le schéma convenable

4) Les Modèles logiques

Les modèles logiques

Description de la base multidimensionnelle suivant la technologie utilisée :

- ROLAP (Relational-OLAP)
- MOLAP (Multidimensional-OLAP)
- HOLAP (Hybrid-OLAP)

Les modèles logiques

- ✓ **ROLAP**
  - « Relationnel On-line Analytical Processing »

« Ensemble d'interfaces utilisateurs et d'applications qui donnent une vision dimensionnelle à des bases de données relationnelles » [Kimball, 2005].

  - Les données sont stockées dans une BD relationnelle
  - Un moteur OLAP permet de simuler le comportement d'un SGBD multidimensionnel

Les modèles logiques

✓ ROLAP

- Le modèle multidimensionnel est traduit ainsi :
  - chaque fait correspond à une table, appelée table de fait
  - chaque dimension correspond à une table, appelée table de dimension.
- Ainsi : la table de fait est constituée :
  - d'attributs représentant les mesures d'activité et
  - les attributs clés étrangères de chacune des tables de dimension.
- les tables de dimension contiennent :
  - les paramètres et
  - une clé primaire permettant de réaliser des jointures avec la table de fait.

Les modèles logiques

- ✓ **ROLAP**

  ☺ Facile à mettre en place

  ☺ Peu couteux

  ☺ Evolution facile

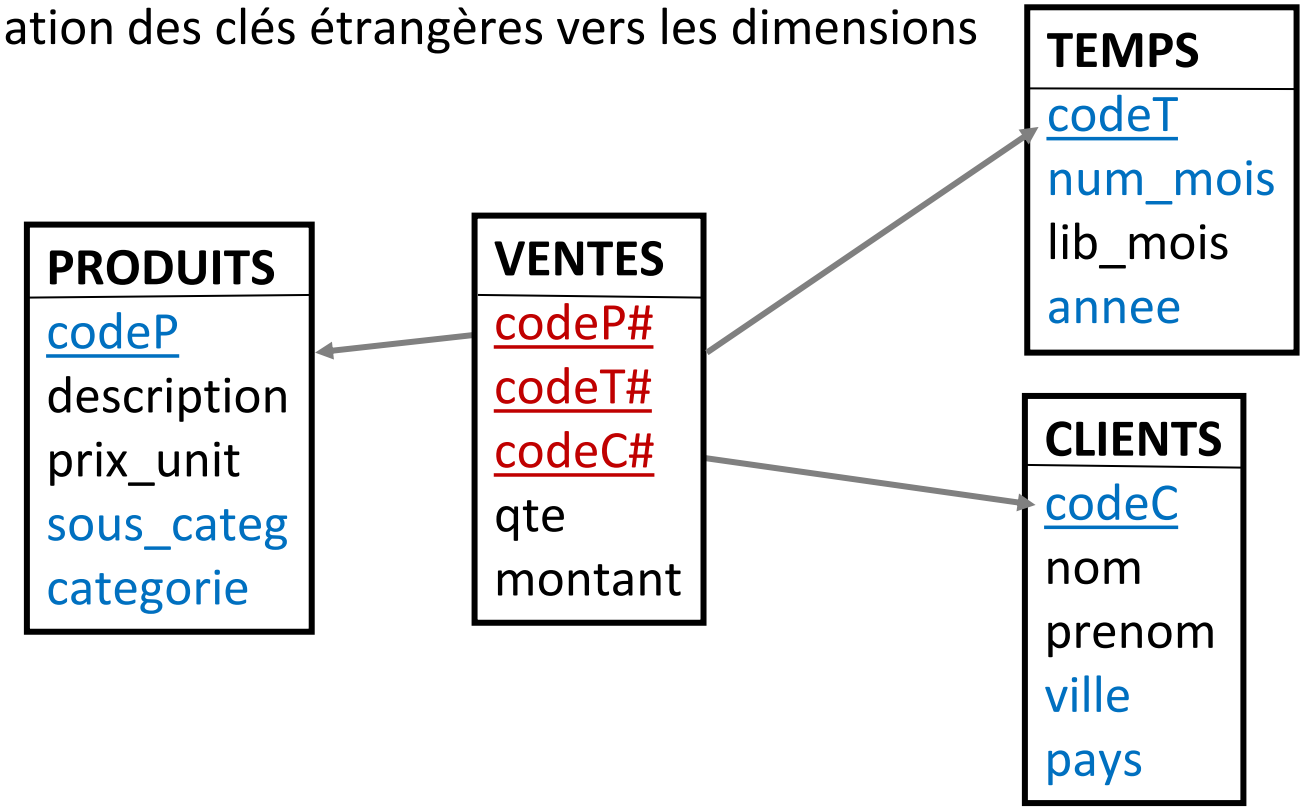
  ☺ Stockage de gros volumes

  ☹ Moins performant lors des phases de calculs

  Exemple de moteur ROLAP : Mondrian

Les modèles logiques

- ✓ **ROLAP**
  - Caractéristique:
    - Clé primaire du fait: Concaténation des clés étrangères vers les dimensions
    - Hiérarchies non explicites



Les modèles logiques

- ✓ **MOLAP**
  - « Multidimentional On-line Analytical Processing »
  - conçus exceptionnellement pour l'analyse multidimensionnelle.
  - « Ensemble d'interfaces utilisateur, d'applications et de technologies de bases de données propriétaire dont l'aspect dimensionnel est prépondérant » .
  - Accès direct aux données dans le cube

.

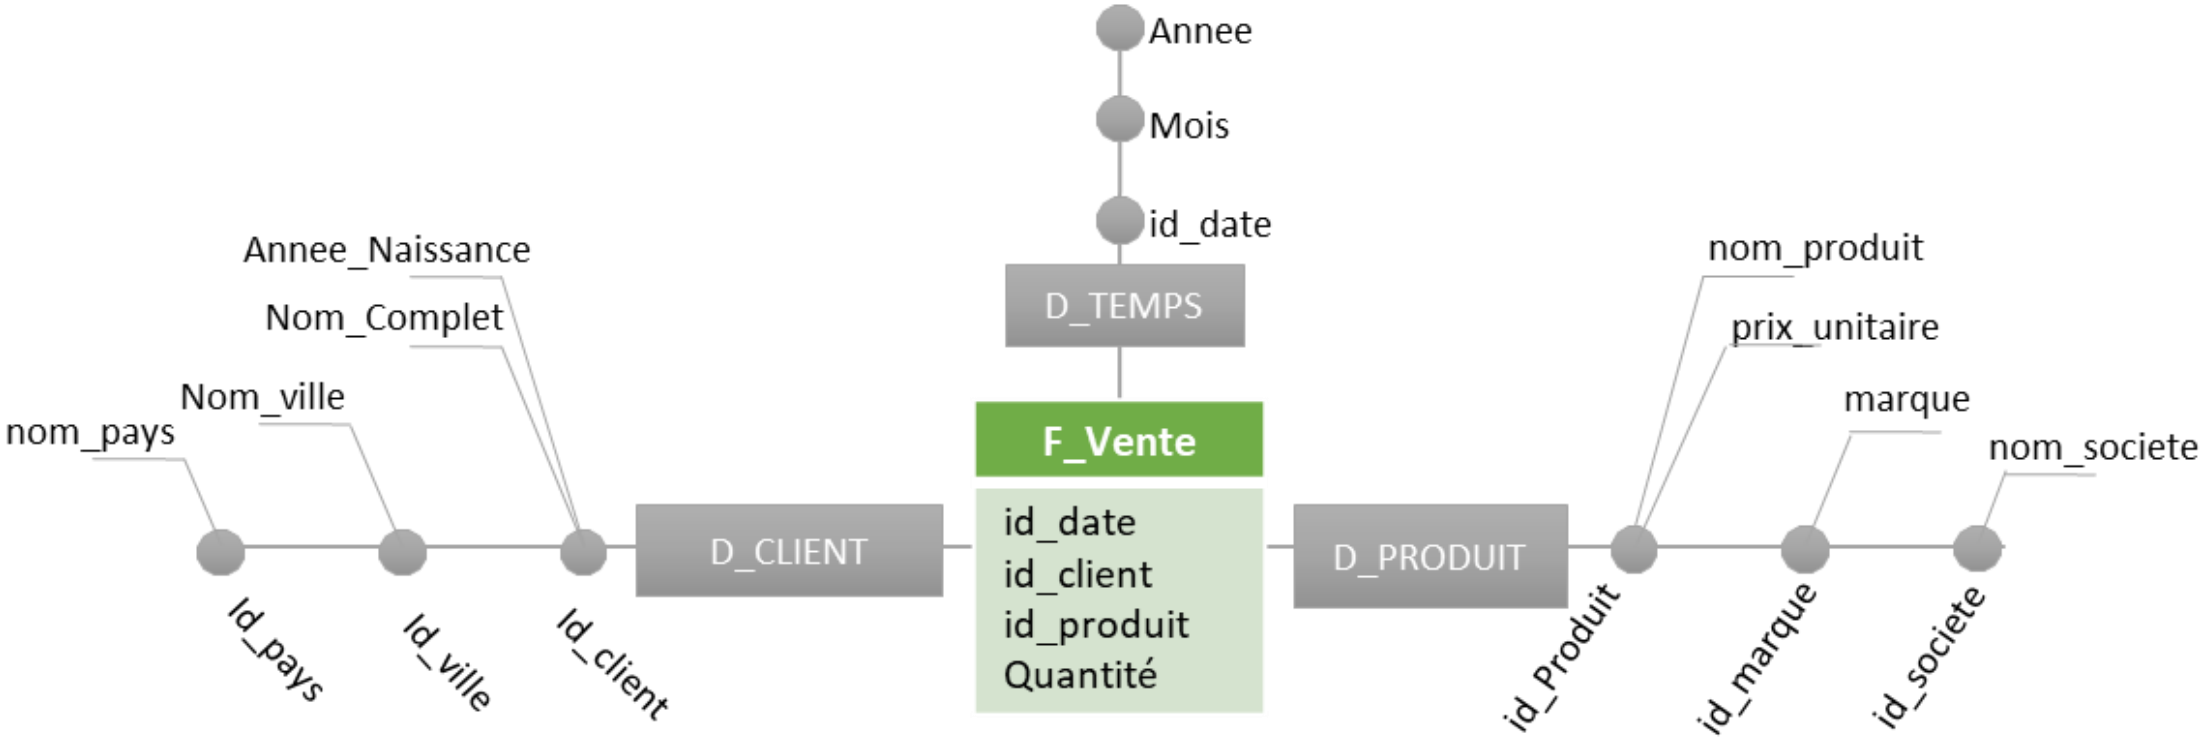
Les modèles logiques

✓ MOLAP

- Utilisation d'un SGBD Multidimensionnel (SGBDM) capable de stocker et traiter des données multidimensionnelles
- Absence de cadre technologique commun pour ces systèmes :
  - chaque produit a sa version du modèle multidimensionnel et ses stratégies de stockage
- Caractérisé par des bonnes performances
  - Effectuer la pré-agrégation et le pré-calcul des données sur tous les niveaux des hiérarchies du modèle de l'entrepôt
- Adapté à de petits ED (quelques Go) et lorsque le modèle multidimensionnel ne change pas beaucoup

Les modèles logiques

- ✓ **MOLAP**



Les modèles logiques

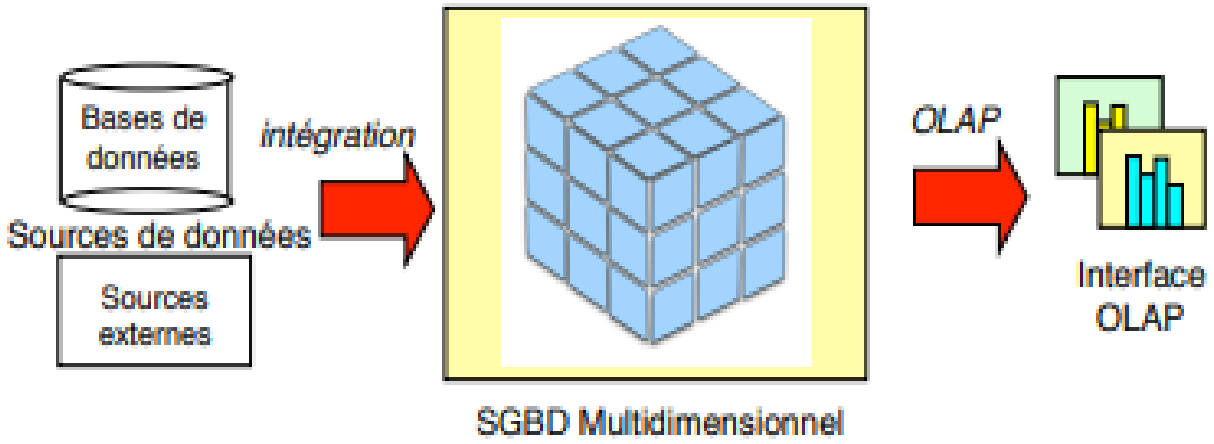
✓ MOLAP

- Des temps d'accès optimisés et cela en prédéfinissant les opérations de manipulation et de chemin d'accès prédéfinis.
- Agrège tout par défaut, pénalisant du couple système lorsque la quantité de données à traiter augmente.

☺ Rapidité

☹ Difficile à mettre en place

☹Formats souvent propriétaires



Les modèles logiques

- ✓ **HOLAP**
  - « Hybride On-line Analytical Processing »
  - Solution hybride entre ROLAP et MOLAP

Données de base stockées dans un SGBD relationnel
(tables de faits et de dimensions)
+
Données agrégées stockées dans un cube

Bon compromis au niveau des coûts et des performances (les requêtes vont chercher les données dans les tables et le cube) selon le besoin

☺ Equilibre entre la facilité d'évolution et la rapidité de traitement des requêtes

Les modèles logiques

✓ HOLAP

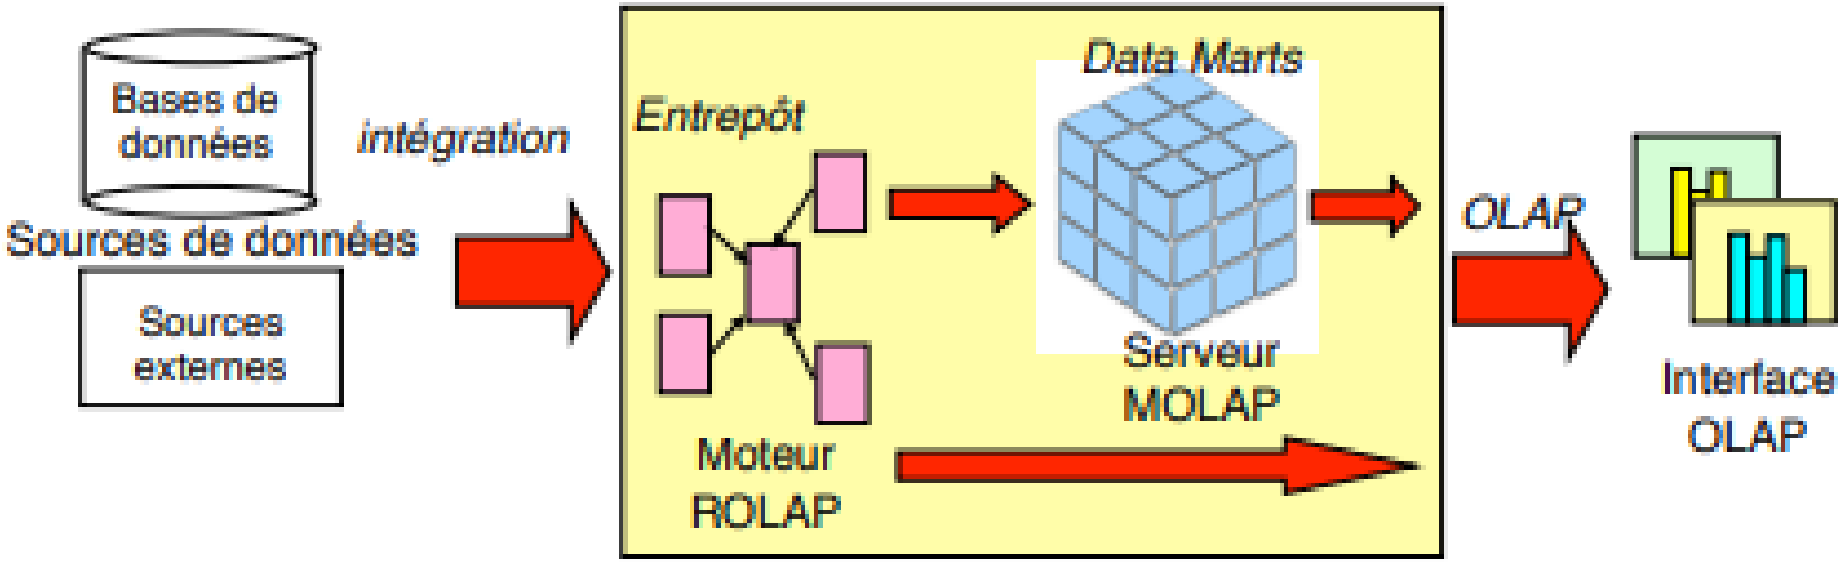
- « Hybride On-line Analytical Processing » Les systèmes HOLAP essaient de combiner les bons cotés des systèmes ROLAP et MOLAP :
  - En stockant les données détaillées de l'ED dans un SGBD Relationnel - ROLAP
  - En stockant les données agrégées, souvent des magasins de données (data marts) de l'ED dans un SGBD Multidimensionnel – MOLAP

- Ils permettent ainsi d'avoir des ED de taille importante tout en ayant des temps de réponse satisfaisants.

- Produits : Express d'Oracle, Media/MR de Speedware, …

Les modèles logiques

- ✓ **HOLAP**
  - L'approche HOLAP (Hybride OLAP) :
    - consiste à utiliser les tables comme structure permanente de stockage des données
    - et les tableaux comme structure pour les requêtes.



Exercice

On considère un entrepôt de données permettant d'observer les ventes de produits d'une entreprise. Le schéma des tables est le suivant :

CLIENT (id-client, nomclient, région, ville, pays)

PRODUIT (id-prod, couleurprod,sous_categorie, lib_souscat, catégorie, lib_cat,nom-prod)

TEMPS (id-tps, mois, nom-mois, trimestre, année)

VENTE (id-prod, id-tps, id-client, qté_vendue, frais-de-livraison)

Questions

1. Indiquer quelles sont la (les) table(s) de fait et les tables de dimension de cet entrepôt.
2. Donner pour chaque dimension, sa (multi-) hiérarchie.
3. Donner la représentation du schéma en étoile de l'entrepôt
4. On veut transformer ce schéma en schéma en flocon. Donner la nouvelle représentation de la table Produit (ajouter des attributs, si nécessaire)

Exercice

Un centre culturel offre à sa clientèle deux types d'accès : un accès à la demande ou un accès adhérent. Le montant de l'adhésion varie selon le besoin demandé (accès salle et/ ou emprunt des livres de la bibliothèque du centre) avec d'autre offres tel qu'utilisation kitchenette, matériel…

Le directeur de ce centre souhaite faire un système décisionnel pour l'analyse des activités : gestion des adhésions, gestion des emprunts. Il veut faire l'analyse du **chiffre d'affaire** de la gestion des adhésions validées par profession des clients cibles et leurs établissements, le **nombre des livres empruntés** écrits par certains auteurs (on suppose qu'un Livre est écrit par un seul auteur) et édités par une telle maison d'édition.

Le schéma des tables est le suivant :

- **Personne :** NumPersonne, NomPersonne, Profession, Etablissement, VillePersonne
- **DemandeAdhésion :** NumAdhésion, #PackAdhésion
- **PackAdhésion :** NumPack, LibelléPack, descriptifPack
- **Adhésion :** NumDemande, NumPersonne, Montant
- **Livre :** NumISBN, LivelleLivre, Etat, SousCatégorie, CatégorieLivre
- **MaisonEdition :** NumMaisonEdition, LibelleMaisonEdition, OrigineMaisonEdition
- **Auteur :** NumAuteur, NomAuteur, VilleAuteur, PaysAuteur
- **EmpruntLivre** : NumPersonne, NumISBN, NumMaisonEdition, NumAuteur, Durée, DateEmprunt