IIT
INSTITUT INTERNATIONAL TECHNOLOGIE
Université Nord Américaine Privée

Cours Entrepôt de données

Dr. Salma DAMMAK & Dr. Taher LAABIDI

2ème année GLID

damak.salma@iit.ens.tn & taher.laabidi@iit.ens.tn

Chapitre3

Les méthodes de conception d'un entrepôt de données

Objectif du cous

- Découvrir les différentes méthodes de conception des entrepôts de données.
- Renforcer les compétences de modélisation multidimensionnelle

Contenu

1) Introduction

2) Méthode Descendante

3) Méthode Ascendante

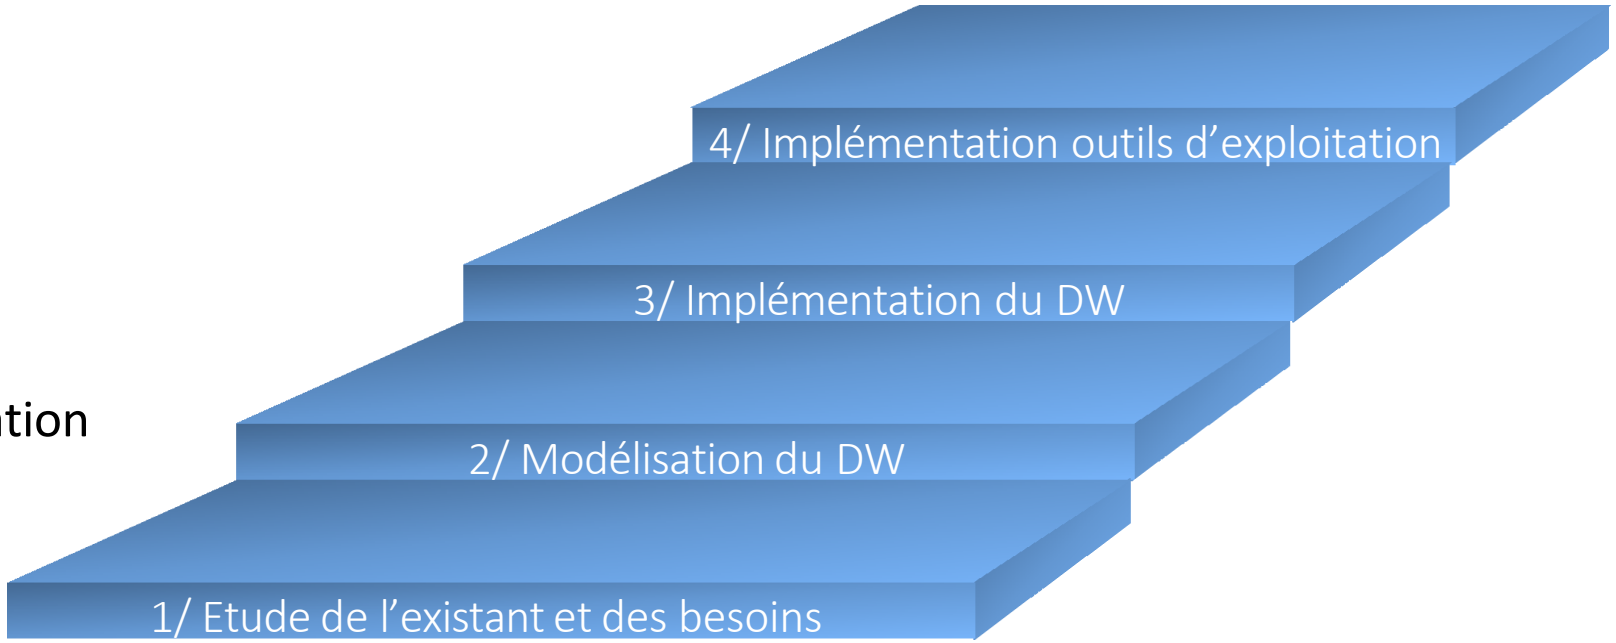
4) Méthode Mixte

1) Introduction

Introduction

✓ Les quatre grands axes pour le développement d'un système décisionnel :

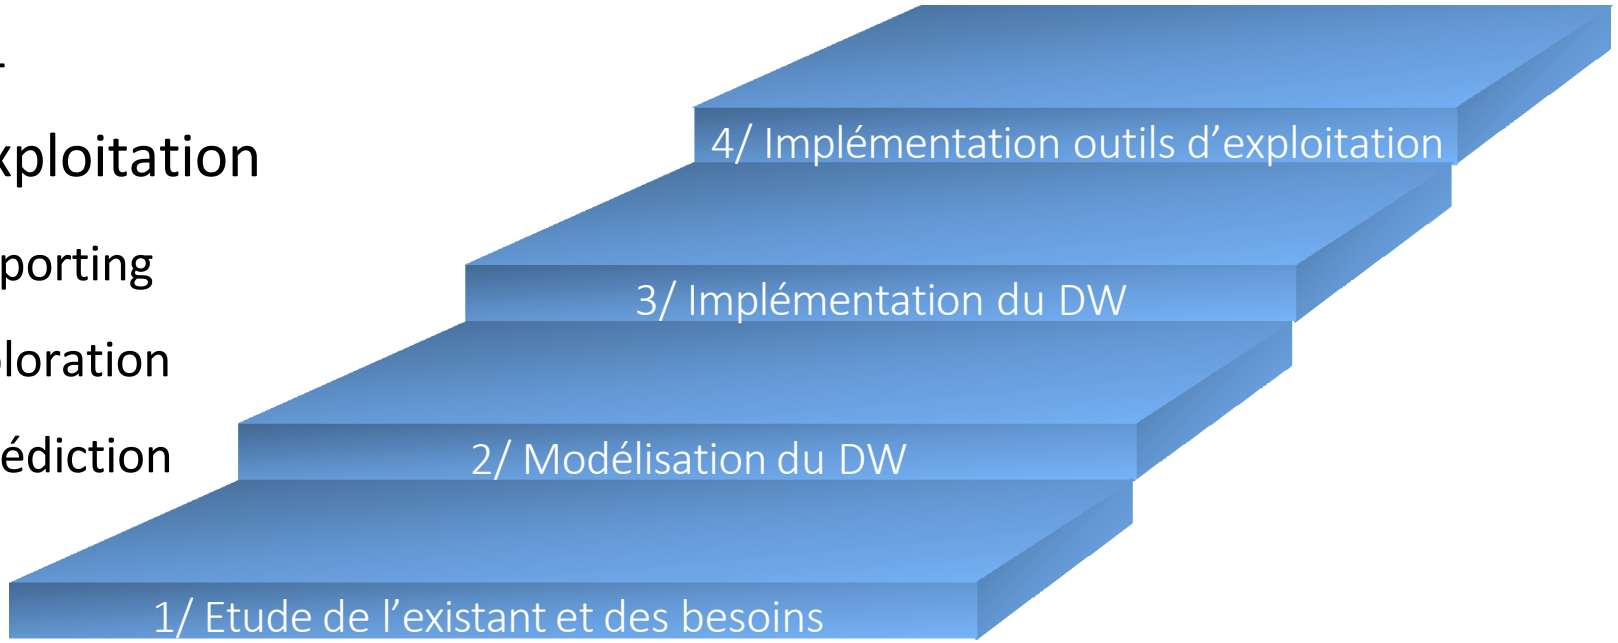
1. Étude des besoins et de l'existant
    1. Étude des besoins utilisateurs
    2. Étude des données existantes
2. Modélisation et conception
    1. Modélisation dimensionnelle
    2. Architecture technique
    3. Spécification des outils d'exploitation



Introduction

✓ Les quatre grands axes pour la réalisation d'un système décisionnel :

3. Implémentation du data warehouse
    1. Implémentation du DW et des data marts
    2. Mise en Place des processus ETL
4. Implémentation des outils d'exploitation
    1. Implémentation des outils de reporting
    2. Implémentation des outils d'exploration
    3. Implémentation des outils de prédiction



Introduction

- « *Un ED ne s'achète pas, il se construit* »
- **Trois types de conception :**

  Approche descendante : *Requirement-driven approach*

  Approche ascendante : *Data-driven approach*

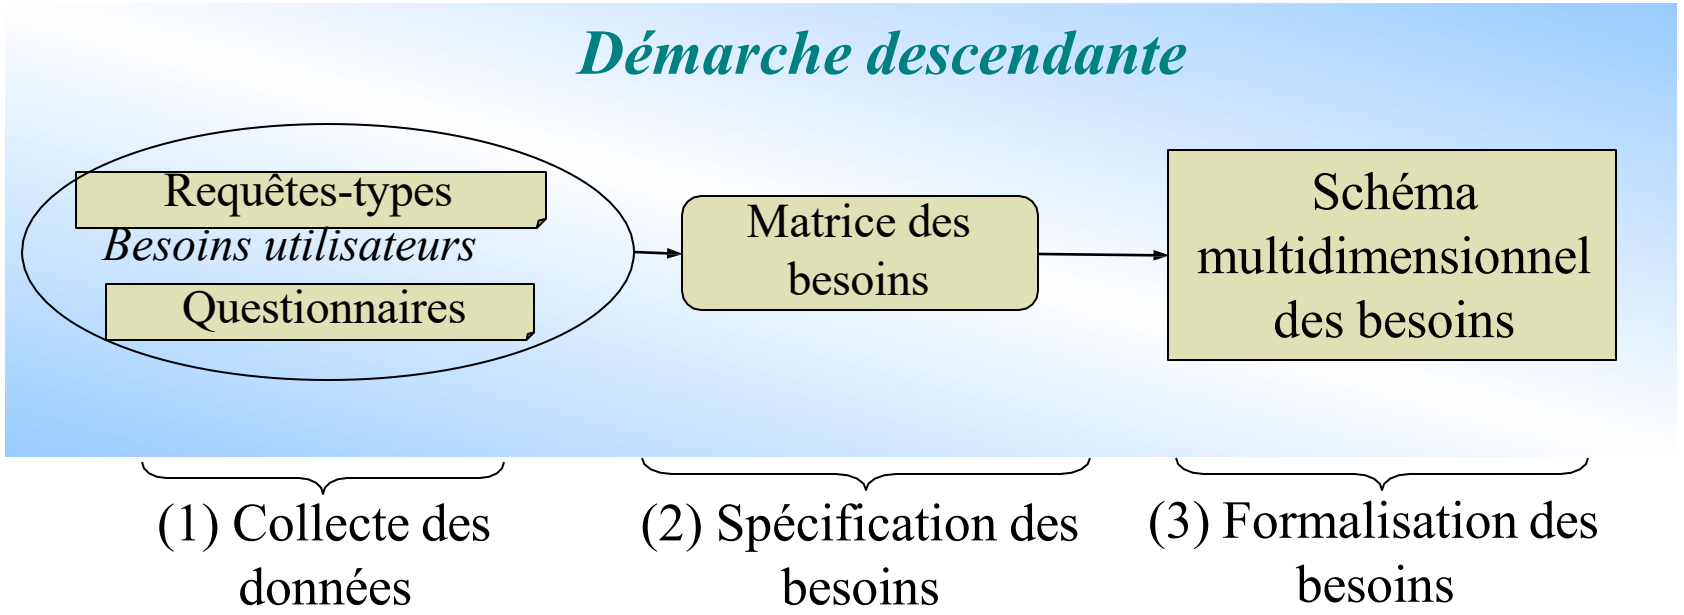
  Approche mixte: *Hybrid approach*

3) Méthode Descendante

Méthode Descendante

- ✓ Top Down
  - Concevoir tout l'entrepôt de données intégralement
  - Il faut donc connaître à l'avance toutes les dimensions et tous les faits.
  - Objectif :
    - Livrer une solution technologiquement saine basée sur des méthodes et technologies éprouvées des bases de données.

Méthode Descendante



Méthode Descendante

- ✓ La collecte des données
  - Déterminer les besoins décisionnels initiaux en définissant les types d'informations susceptibles d'intéresser chaque groupe de décideurs
    - La collecte des **requêtes-types pertinentes**
    - La mise au point d'un **questionnaire**
    - L'analyse des données décisionnelles et des résultats des interviews et des questionnaires pour dégager les **règles de gestion**

Méthode Descendante

- ✓ La collecte des données
  - *Requêtes-types*
    - Pseudo-langage avec trois clauses:
      - Clause ***Analyser*** répond à la question ***Quoi?***
      - Clause ***En fonction*** répond aux questions ***Qui? Où? Et Quand?***
      - Clause ***Pour*** répond à la question ***Pour Qui ou Quelles données?***

Méthode Descendante

- ✓ La collecte des données
  - *Requêtes-types*

R1: *Analyser le montant des locations*

En fonction des mois et des véhicules Pour les

véhicules de type sport.

R2: *Analyser le montant des locations*

En fonction des mois et des agences

R3*: Analyser la durée de location*
En fonction des clients

R4: *Analyser le chiffre d'affaire des employés*

En fonction des mois

Pour l'employé Paul et l'année2002.

R5: *Analyser la durée de location*
En fonction des marques et des états
Pour l'année 2022

R6 *: Analyser les montants des locations*
En fonction des marques et des régions

R7 : *Analyser le montant de locations*

En fonction des clients et des villes

Pour l'année 2022

Méthode Descendante

- ✓ La collecte des données
  - *Questionnaires:*
    - Outil de collecte de données dans lequel le décideur est guidé à travers d'un ensemble de questions pour obtenir des informations pour la modélisation
  - *Règles de gestion:*
    - Sont souvent représentées sous forme de contraintes qui doivent être respectées pour permettre le bon fonctionnement du système opérationnel

Méthode Descendante

✓ Spécification des besoins

- Construction de la matrice des besoins

  -définir la liste de propriétés extraite des requêtes obtenues de l'étape de collecte de données

  -Construire une matrice carrée. Les entêtes des lignes et des colonnes sont les propriétés

- Remplissage de la matrice

  -Répondre aux questions, quelles sont les données analysées et en fonction de quelles données (requêtes types) // dans la matrice, chaque case cochée (☑) indique que la propriété en ligne est analysée en fonction de celle en colonne

- Simplification de la matrice

  -chaque colonne ou ligne vide est supprimée de la matrice

Méthode Descendante

- ✓ Spécification des besoins
  - Analyser les données collectées afin de spécifier les besoins des décideurs
  - Construire la matrice des besoins

	Mt locations	Ville	Région	Etat	Année	Mois	Nb jours	CA	Id_Emp	Id_Client	Immat	Type	Marque
Mt locations		√	√	√	√	√				√	√	√	√
Ville													
Région													
Etat													
Année													
Mois													
Nb jours		√	√	√	√	√				√	√	√	√
CA					√	√			√				
Id_Emp													
Id_Client													
Immat													
Type													
Marque													

Méthode Descendante

✓ Spécification des besoins

- Simplifier la matrice en définissant les indicateurs d'analyse.

	Code_ Ag	Ville	Région	Etat	Année	Mois	Id_Emp	Id_ Client	Immat	Type	Marque
Mt_locations	√	√	√	√	√	√		√	√	√	√
Nb jours	√	√	√	√	√	√		√	√	√	√
CA					√	√	√				

Remarques

D'après les règles de gestion régissant la compagnie de location de véhicules, la compagnie admet plusieurs filiales en France et aux Etats-Unis.

- Les villes françaises sont regroupées dans des départements et les départements sont regroupés dans des régions
- Les villes aux Etats-Unis sont regroupées en états

Méthode Descendante

✓ Formalisation des besoins

☞ En se basant sur la matrice des besoins

1- Définition des faits (sujets d'analyse)

- regrouper les mesures dans des faits. Déterminer les fonctions d'agrégation compatibles avec chaque mesure en se basant sur les questionnaires

2 Définition des dimensions

a. regrouper les paramètres dans des dimensions

b. enrichir ces dimensions à travers de nouvelles propriétés

c. définir la granularité d'analyse

3 Définition des hiérarchies

- organiser les paramètres de chaque dimension dans des hiérarchies

4- Définition du schéma multidimensionnel

- affecter les dimensions aux faits

Méthode Descendante

1) Définition des faits (sujets d'analyse)

- regrouper les mesures analysées au travers de paramètres identiques.
- définir les fonctions d'agrégation compatibles avec chaque mesure en se basant sur les questionnaires

Location ((Montant_Loc, {sum, avg}), (Nb_jours, {count, sum, avg}))
Performance ((CA, {sum, avg, max, min}))

2) Définition des dimensions

- regrouper les paramètres dans des dimensions (dégager les groupes de paramètres qui caractérisent la même dimension d'un point de vue sémantique)
- enrichir ces dimensions à travers de nouvelles propriétés (se baser sur les questionnaires)
- définir la granularité de l'analyse (le niveau d'analyse le plus fin pour chaque dimension)

Méthode Descendante



3) Définition des hiérarchies: organiser les paramètres de chaque dimension dans des hiérarchies (se baser sur le questionnaire et les règles de gestion définies dans l'étape de collecte de données)

H^{Temps} : Id_Temps → Mois→Année

H^{Ag}_1 : Code_Ag → Ville → Département → Région →Pays

H^{Ag}_2 : Code_Ag →Ville→Etat→Pays

H^{Client} : Id_Client→Ville

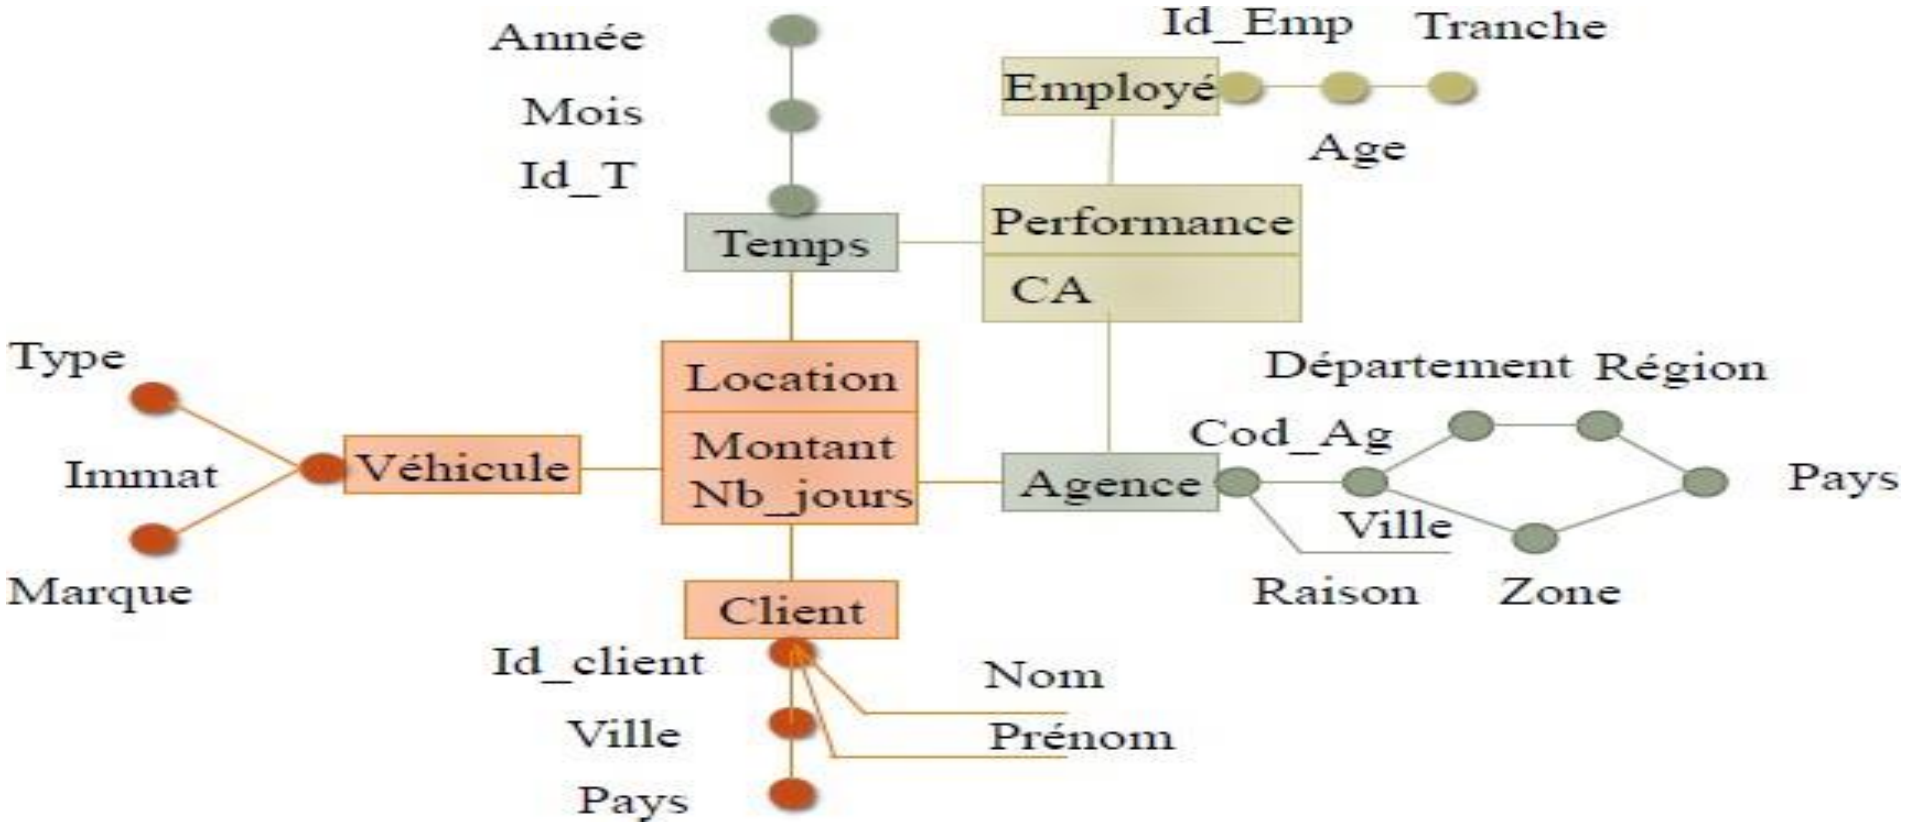
$H^{Véh}_1$: Immat →Type

$H^{Véh}_2$: Immat → Marque

$H^{Employé}$: Id_Emp→Age→Tranche

Méthode Descendante

4) Définition du schéma multidimensionnel: affecter les dimensions aux faits (selon la matrice des besoins, chaque dimension comportant des paramètres qui ont des intersections avec une mesure d'un fait, est affectée à ce fait)



Méthode Descendante

✓ Top-Down

- Avantages :

☺ Offrir une architecture intégrée : méthode complète

☺ Réutilisation des données

☺ Vision claire et conceptuelle des données de l'entreprise et du travail à réaliser

- Inconvénients :

☹ Méthode lourde

☹ Méthode contraignante

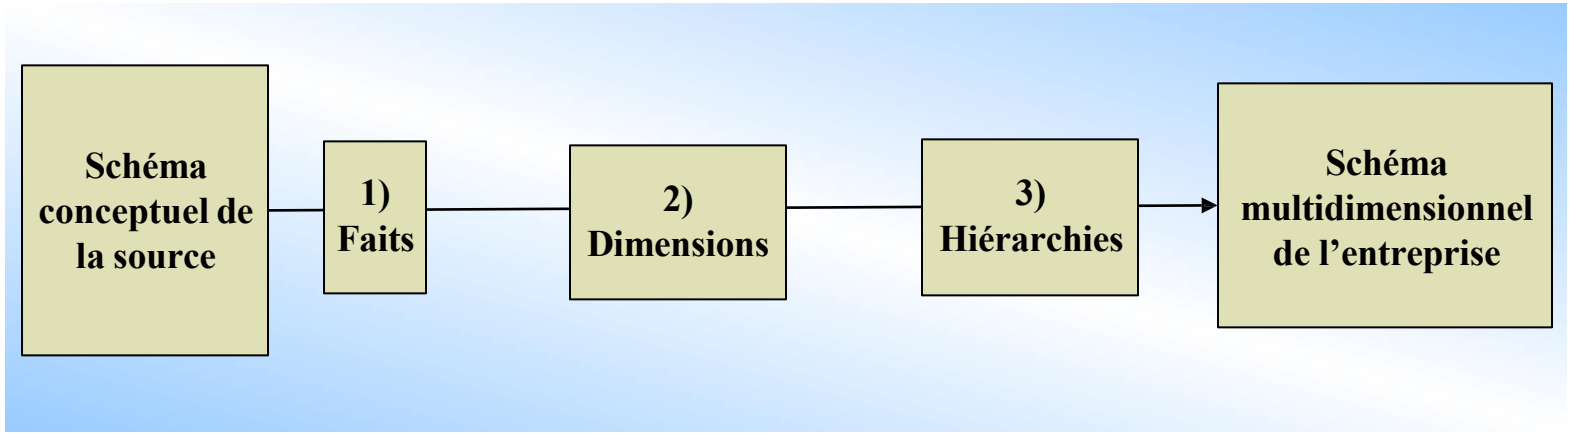
☹ Nécessite du temps

2) Méthode Ascendante

Méthode Ascendante

Caractéristiques de l'approche ascendante

- Se base sur les données des sources pour concevoir les schémas multidimensionnels: Considère que les informations pertinentes pour l'analyse se trouvent dans la source. Les besoins des utilisateurs sont évolutifs et difficile à définir d'où le risque d'obtenir un schéma instable en se basant sur ces besoins.
- Néglige le rôle du décideur dans la construction de l'ED



Méthode Ascendante

- ✓ Exemple: Concevoir un schéma multidimensionnel d'un ED à partir d'un diagramme de classe
  - *Étape1 : Définition des faits*
    - **Analyse du schéma de la source globale (diagramme de classe)**
    - **Détection des classes représentatives de l'analyse (Déterminer le sujet d'analyse)**
      - *Une **Classe Représentative** (CR)*
        - *décrit un événement qui se produit à un instant donné (généralement une activité de l'entreprise) ;*
        - *contient les mesures d'analyse*
        - Les faits sont définis parmi les classes (entités, relations) ou les associations n-aires qui sont fréquemment mises à jour.
    - **Choix des mesures d'activités à analyser**

Méthode Ascendante

- ✓ Bottom-up: Concevoir un schéma multidimensionnel d'un ED à partir d'un diagramme E/R
  - *Étape2: Définition des dimensions:*
    - **Détection des classes déterminantes des classes représentatives (les axes d'analyses)**
      - *Une classe Ci est **déterminante** d'une classe CR si :*
        - *Cr est relié à Ci par un lien de dépendance fonctionnelle directement ou indirectement*
    - **Choix des paramètres d'analyse**
    - **Définition de la dimension temporelle**

Méthode Ascendante

- ✓ Bottom-up: Concevoir un schéma multidimensionnel d'un ED à partir d'un diagramme E/R
  - *Étape 3 : Hiérarchisation des dimensions*
    - Définir le niveau le plus détaillé d'analyse dans la source.
    - Définir les paramètres les plus détaillés de chaque dimension.
    - Détecter les dépendances hiérarchiques entre les paramètres et les organiser en une structure hiérarchique

Méthode Ascendante

- ✓ Bottom-up:
  - Avantages :

☺ Simple à réaliser,

☺ Résultats rapides

☺ Efficace à court terme

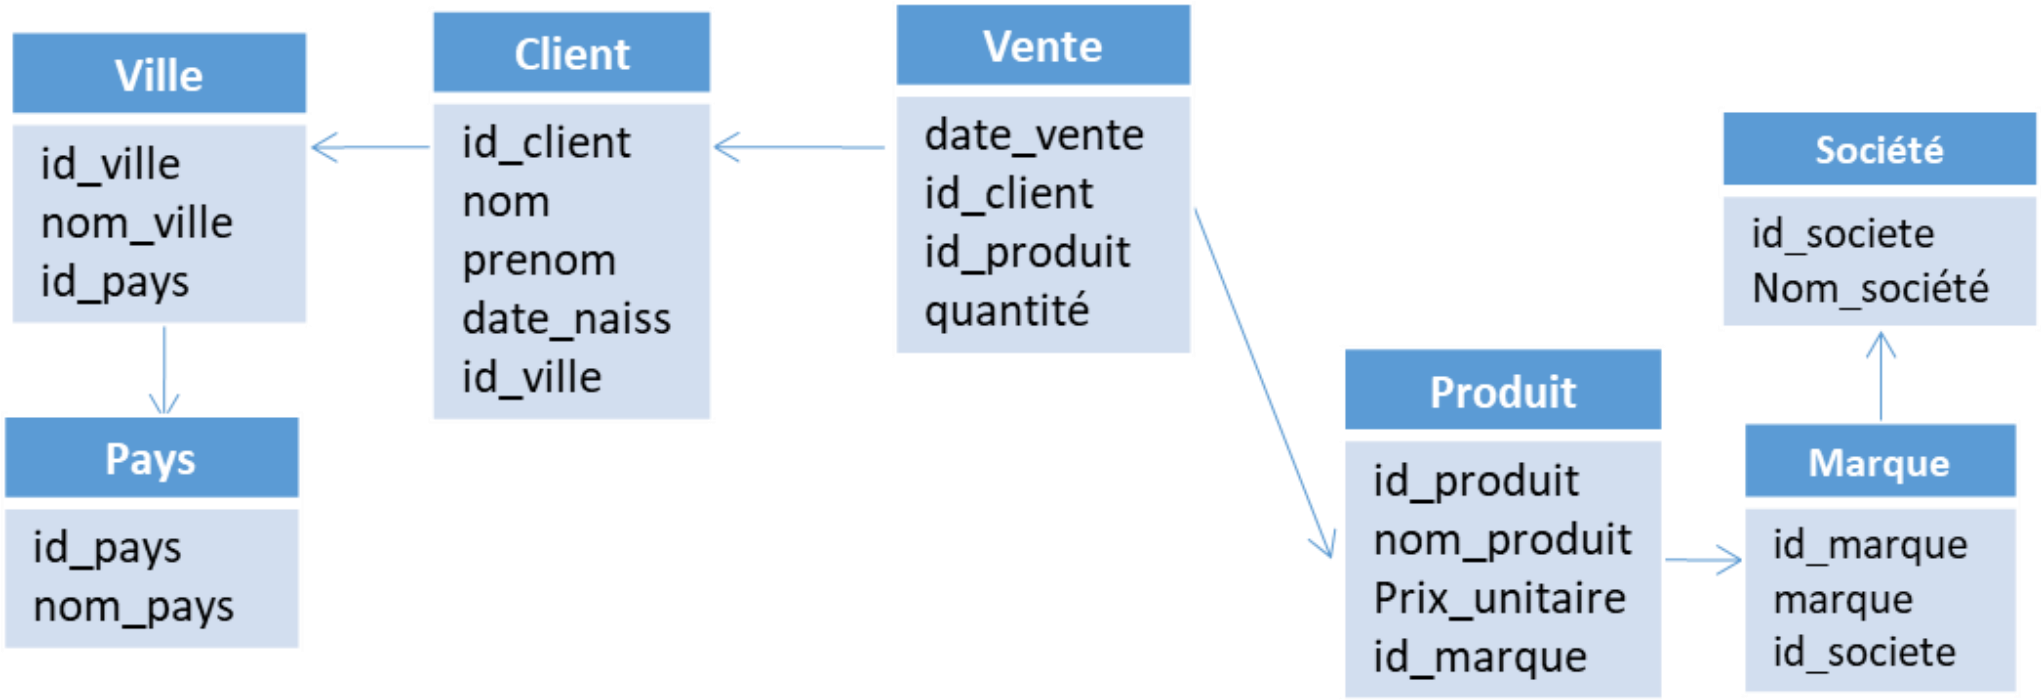
- Inconvénients :

☹ Pas efficace à long terme

☹ Le volume de travail d'intégration pour obtenir un entrepôt de données

Méthode Ascendante

✓ Exemple: Déterminer les concepts multidimensionnels à partir de ce schéma source



Méthode Ascendante

Dans le domaine commercial, l'analyse du schéma permet de détecter une classe représentative qui comporte des indicateurs d'analyse ; la classe **Vente** comportant la quantité de vente.

CR = {Vente}

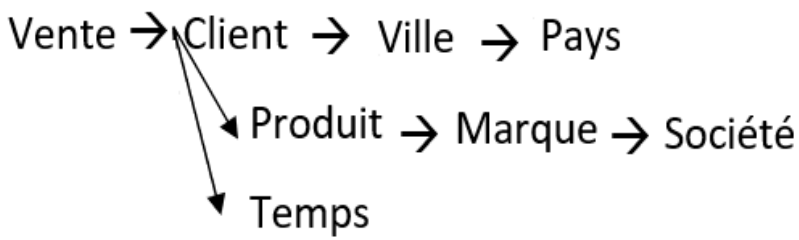
1) Définition des faits :

Nous souhaitons définir un fait analysant la quantité des ventes.

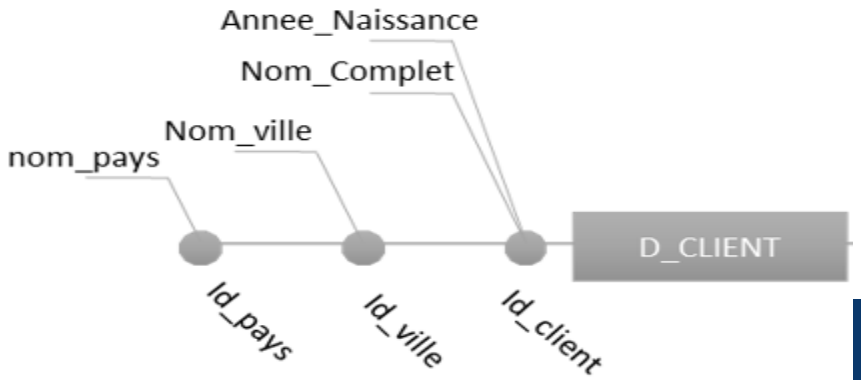
Fait_Vente =((Quantité_V = Source.Vente.Quantité, {SUM,AVG})

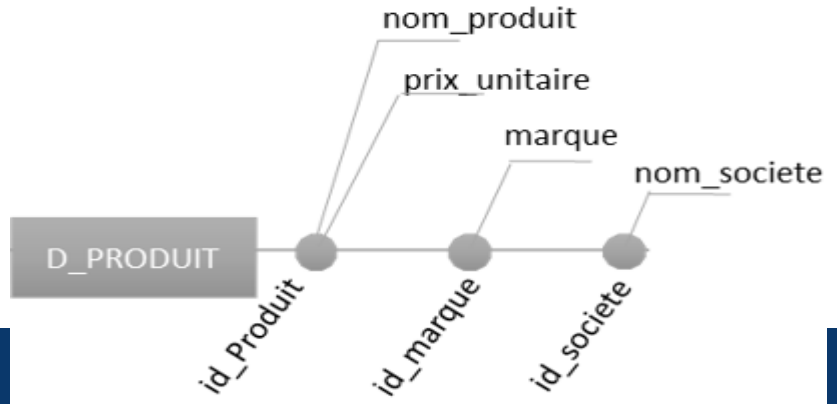
2) Définitions des dimensions :

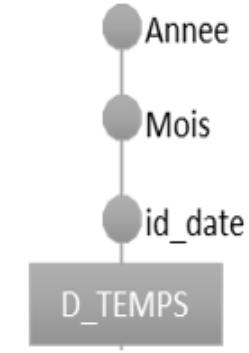
Graphe de dépendances fonctionnelles entre classes



3) Définition des hiérarchies

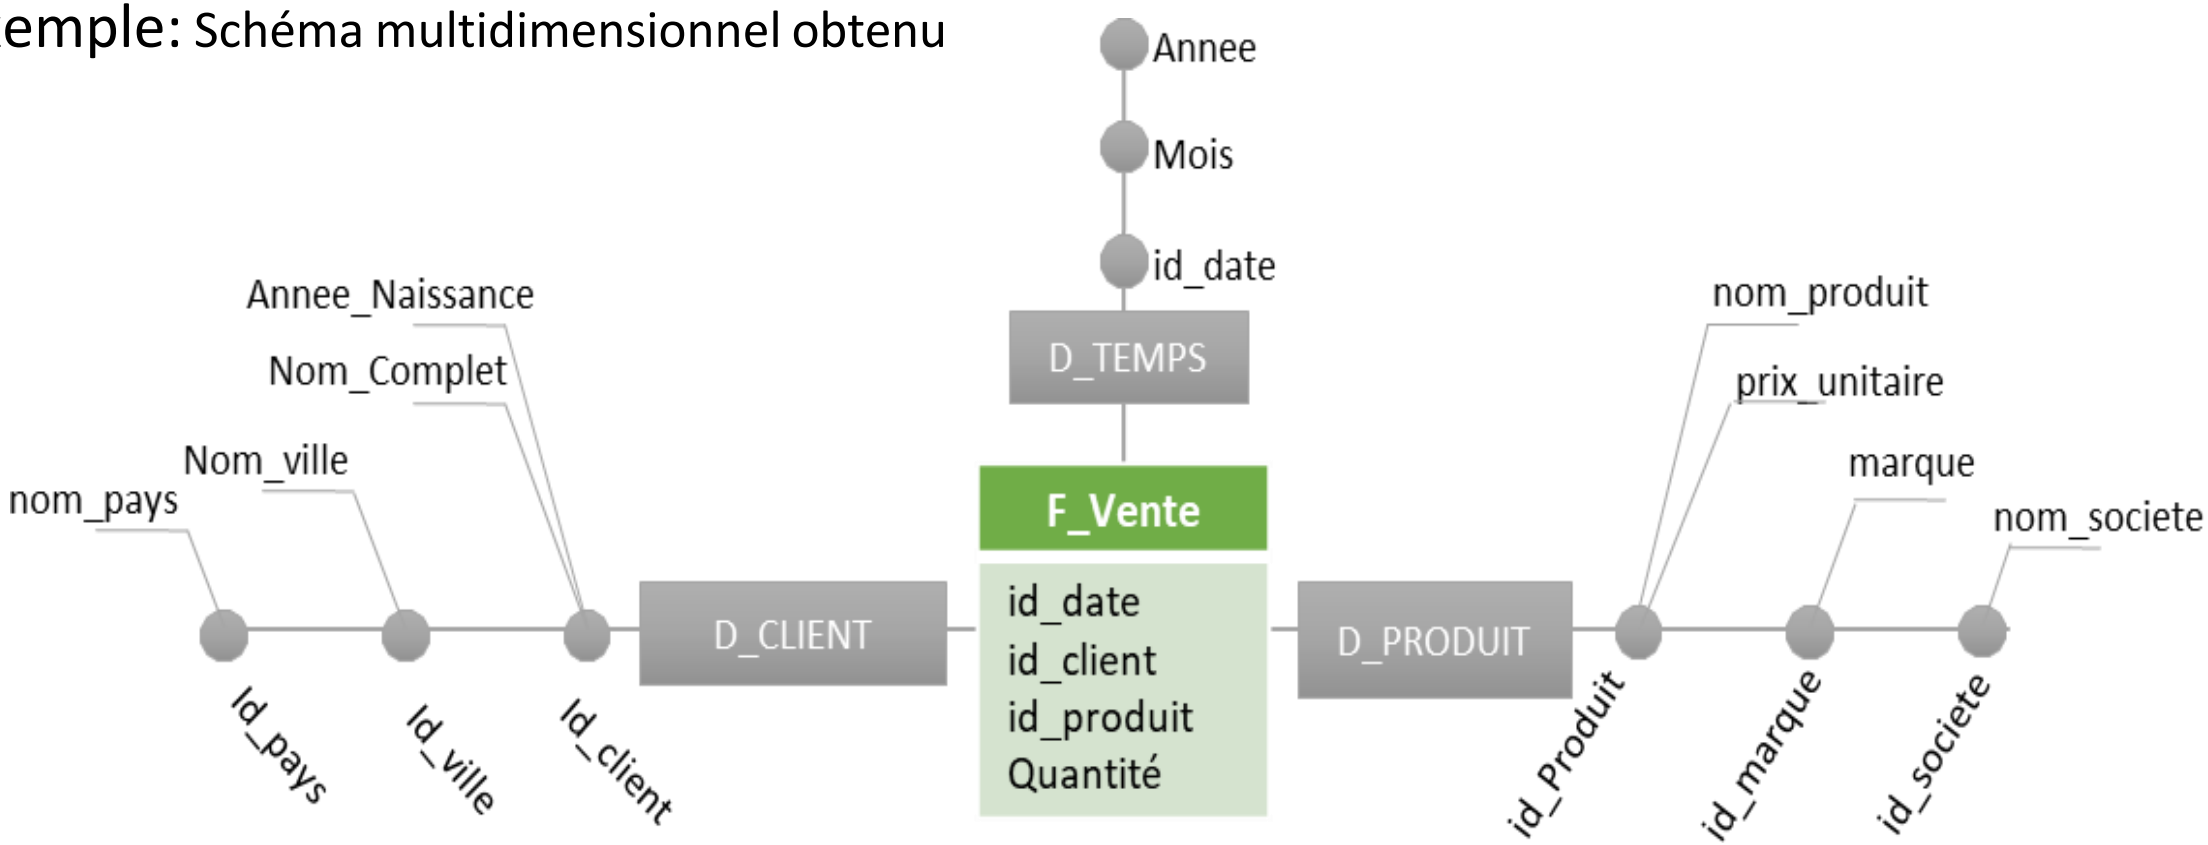






Méthode Ascendante

✓ Exemple: Schéma multidimensionnel obtenu



4) Méthode Mixte

Méthode Mixte

- ✓ **Middle-Out** (approche hybride)
  - Concevoir intégralement l'entrepôt de données (toutes les dimensions, tous les faits, toutes les relations), puis créer des divisions plus petites et plus gérables.
  - Une combinaison des deux approches: Appelée hybride ou mixte
  - Prend en considération les sources de données et les besoins des utilisateurs.
  - Construit des schémas dimensionnels à partir des structures des données du système opérationnel, et les valider par rapport aux besoins analytiques
  - Cumule les avantages et quelques inconvénients des deux approches déjà citées, telles que la complexité des sources de données et la difficulté quant à la détermination des besoins analytiques.

Méthode Mixte

- ✓ **Middle-Out** (approche hybride)
  - **Input :**
    - Un diagramme de classes UML
    - Des besoins des décideurs
  - **Output :**
    - Modèle(s) multidimensionnel(s)

Méthode Mixte

- ✓ **Middle-Out** (approche hybride)
  - **Deux étapes:**
    - Étape1:
      - Obtenir un ensemble de modèles multidimensionnels à partir d'un diagramme de classes UML
    - Étape2:
      - Affiner le modèle multidimensionnel par les besoins des utilisateurs

Méthode Mixte

- ✓ **Middle-Out** (approche hybride)
  - *Etape 1:* Obtenir un ensemble de modèles multidimensionnels à partir d'un diagramme de classes UML

1) Identification des faits

- Une classe *H est classée comme une classe de fait si :*
- Elle a au moins un attribut numérique non clé
- Elle est liée au moins à une classe *E1 avec une cardinalité «un à plusieurs »*

Méthode Mixte

✓ **Middle-Out** (approche hybride)

- *Etape 1:* Obtenir un ensemble de modèles multidimensionnels à partir d'un diagramme de classes UML

2) Définition des dimensions et des hiérarchies

- Toutes les entités du diagramme de classes UML qui ne sont pas des faits sont candidates pour représenter des dimensions.
- Une dimension peut être connectée à plusieurs entités de fait.
- S'il y a une relation entre deux entités de faits, l'entité enfant héritera toutes les dimensions de l'entité mère.
- La dimension temporelle est ajoutée à l'ensemble des dimensions extraites.

Méthode Mixte

- ✓ **Middle-Out** (approche hybride)
  - *Etape 2:* Affiner le modèle multidimensionnel par les besoins des utilisateurs

    i) Sous-étape1:

    - Effectuer des interviews avec un nombre d'utilisateurs pour établir une liste de processus
    - Un processus contient un ensemble des besoins (exigences) des utilisateurs

    ii) Sous-étape2:

    - Analyser les processus pour choisir et affiner les modèles multidimensionnels.
    - Évaluer le modèle multidimensionnel obtenu avec les exigences des utilisateurs

Méthode Mixte

✓ **Middle-Out** (approche hybride)

- Avantages

☺ Prendre le meilleur des deux approches

☺ Développement d'un modèle de données d'entreprise de manière itérative

- Inconvénients

☹ Implique, parfois, des compromis de découpage (dupliquer des dimensions identiques pour des besoins pratiques).

Exercice

Une entreprise tunisienne de location de véhicules possède plusieurs agences dans différentes villes. Le directeur vous demande de lui concevoir un entrepôt de données, dans le but d'analyser le montant des locations des véhicules dans chacune de ses agences.

Une agence comporte un code, une région, une ville, et un numéro de téléphone

Les clients peuvent réserver un véhicule à travers trois façons de réservation : au guichet, par téléphone et par internet. Une réservation comporte un numéro et une durée.

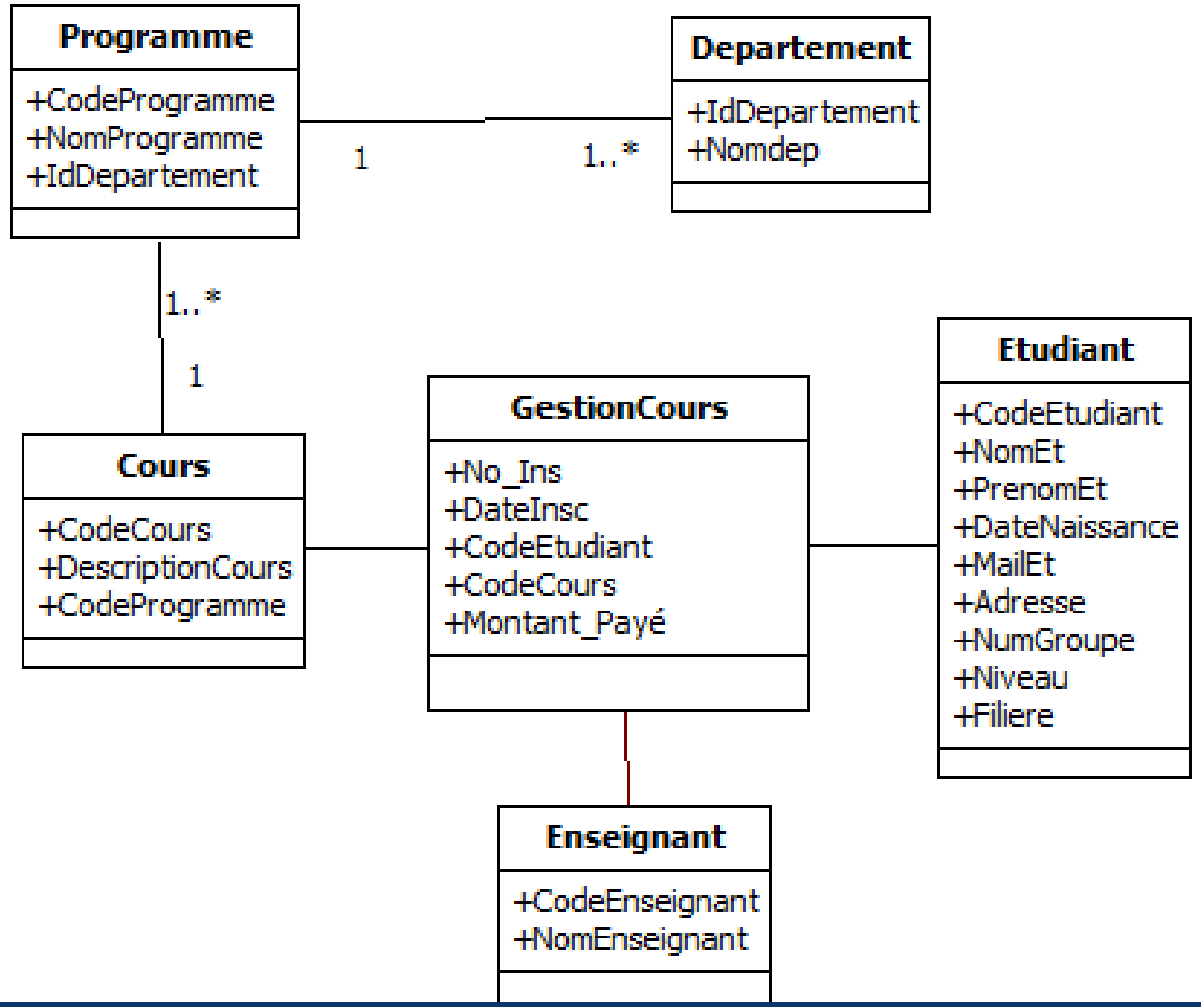
Chaque client est identifié par son numéro de carte d'identité, son nom, prénom, une ville et un pays.

Chaque véhicule est caractérisé par son matricule, son kilométrage au dernier relevé, sa puissance, son modèle et sa marque.

Et pour chaque opération de location, on enregistre la date de début et de retour.

Définir le modèle en étoile adéquat pour la conception du data warehouse de cette entreprise

Exercice

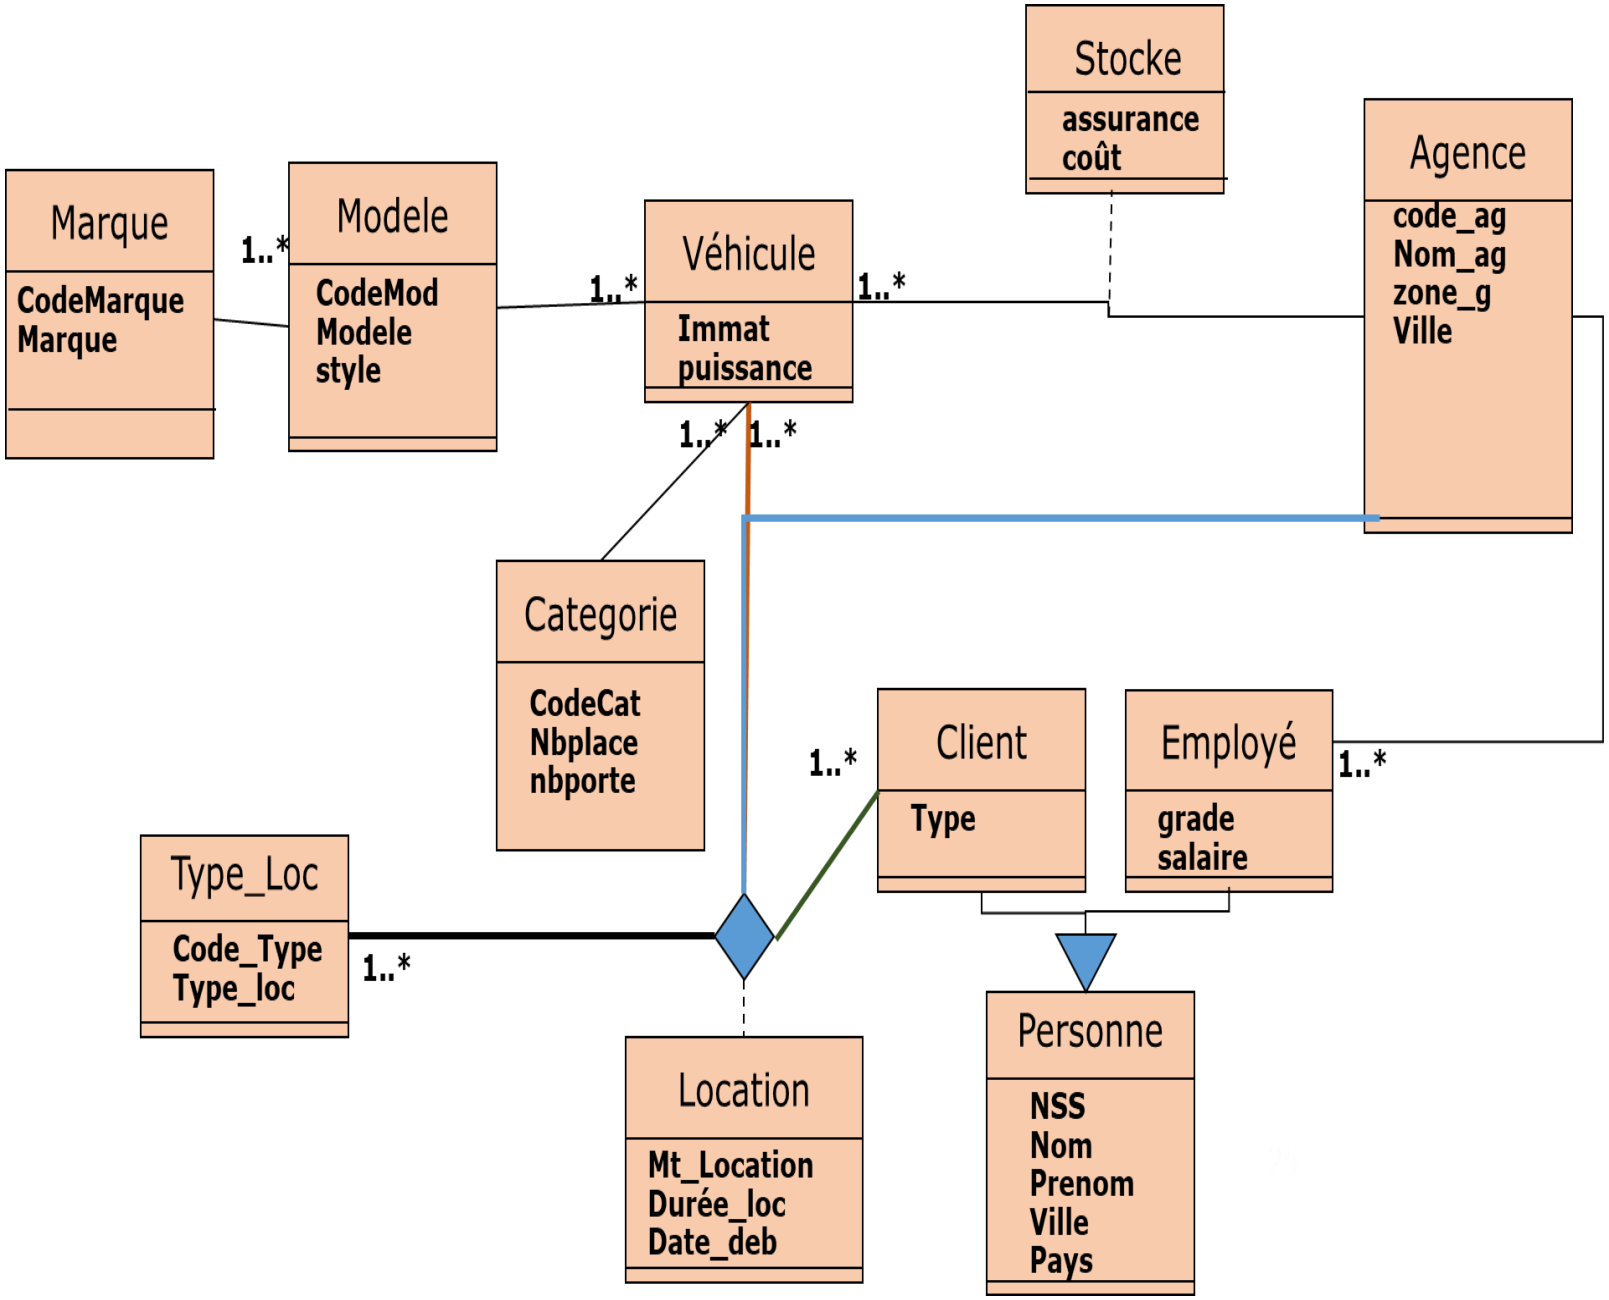


Un centre de formation désire développer un magasin de données afin d'améliorer la gestion de ses programmes de formation. La principale source d'informations serait la base de données dont le schéma relationnel est fourni. Le magasin de données devrait permettre de répondre, entre autres, aux questions analytiques suivantes

- Quels sont les cours d'un certain programme ayant le plus (le moins) d'inscriptions ?
- Quel est le nombre moyen d'inscription par groupe ?
- Quelle est la proportion d'étudiants ayant suivi les cours d'un certain programme, qui habitent à l'extérieur de Sfax ?

Exercice

Le directeur de la société nous demande de créer le magasin de donnée permettant d'analyser **l'activité principale** de sa société.



Exercice

Le directeur de magasin de distribution de produits alimentaire et d'hygiène souhaite créer les magasins des données convenables afin de pouvoir faire les analyses nécessaires pour améliorer ses services.

1/ En se basant sur le modèle fournit modéliser la ou les magasins des données en dégageant le ou (les) **sujet(s) d'analyse** convenable en spécifiant **les mesures** et les **axes d'analyses.**

Pour chaque axe d'analyse spécifier la ou les **hiérarchies** respectives.

2/ Présenter le **schéma** convenable pour **chaque magasin**.

3/ Est-ce qu'on peut présenter une **simplification** pour la modélisation de ces magasins des données?

